BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT VĨNH LONG

KHÓA LUẬN TỐT NGHIỆP
ĐẠI HỌC KHOA HỌC MÁY TÍNH

PHÁT HIỆN VÙNG BỆNH VÀ PHÂN LOẠI BỆNH TIM BẰNG HỌC SÂU CÓ KHẢ NĂNG GIẢI THÍCH

Explainable Deep Learning for Detection of Affected Regions and Classification of Heart Diseases

CBHD : **ThS. Nguyễn Thị Mỹ Nga**
SV : **Nguyễn Đức Trọng**
Mã số SV : **22022012**

Vĩnh Long, Năm 2026

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT VĨNH LONG

KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP
ĐẠI HỌC KHOA HỌC MÁY TÍNH

PHÁT HIỆN VÙNG BỆNH VÀ PHÂN LOẠI BỆNH TIM BẰNG HỌC SÂU CÓ KHẢ NĂNG GIẢI THÍCH

Sinh viên thực hiện	:	Nguyễn Đức Trọng
MSSV	:	22022012
Lớp	:	ĐH KHMT 2022
Khóa	:	2022 - 2026
Người hướng dẫn	:	ThS. Nguyễn Thị Mỹ Nga

Vĩnh Long, Năm 2026

NHẬN XÉT VÀ ĐÁNH GIÁ CỦA NGƯỜI HƯỚNG DẪN

- Ý thức thực hiện . . . . . .

. . . . . .

. . . . . .

- Nội dung thực hiện . . . . . .

. . . . . .

. . . . . .

- Hình thức trình bày . . . . . .

. . . . . .

. . . . . .

- Tổng hợp kết quả . . . . . .

. . . . . .

. . . . . .

☐ **Tổ chức báo cáo trước hội đồng**

☐ **Tổ chức chấm thuyết trình**

Vĩnh Long, ngày . . . . . tháng . . . . . năm 2026

Giảng viên hướng dẫn

ThS. Nguyễn Thị Mỹ Nga

NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN

- Nhận xét . . . . . .

. . . . . .

. . . . . .

. . . . . .

- Đánh giá . . . . . .

. . . . . .

. . . . . .

. . . . . .

Vĩnh Long, ngày . . . . . tháng . . . . . năm 2026

Giảng viên phản biện

(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Lời đầu tiên, em xin chân thành cảm ơn đến tất cả những người đã giúp đỡ và hỗ trợ em trong suốt quá trình thực hiện đề tài khóa luận tốt nghiệp này.

Trước hết, em xin gửi lời cảm ơn sâu sắc đến ThS. Nguyễn Thị Mỹ Nga, người đã trực tiếp hướng dẫn và hỗ trợ em một cách nhiệt tình, tận tâm. Cô đã chia sẻ kiến thức chuyên môn, truyền đạt những khái niệm quan trọng và hướng dẫn em trong quá trình nghiên cứu, triển khai đề tài. Những đóng góp của cô đã giúp em hiểu rõ hơn về cách xây dựng hệ thống phát hiện vùng bệnh và phân loại bệnh tim từ ảnh MRI 3D bằng học sâu có khả năng giải thích, đồng thời giúp em phát triển các kỹ năng chuyên môn cần thiết.

Em cũng muốn gửi lời cảm ơn đến Ban giám hiệu Nhà trường cùng các giảng viên Khoa Công nghệ thông tin. Sự đồng thuận và hỗ trợ từ phía Quý thầy cô đã tạo điều kiện thuận lợi về cơ sở vật chất, thiết bị cũng như tài liệu để em có thể hoàn thành nghiên cứu một cách toàn diện. Em vô cùng biết ơn sự tận tình truyền đạt kiến thức của các giảng viên để em có đủ nền tảng hoàn thành đề tài này.

Cuối cùng, em trân trọng mọi ý kiến đóng góp và phản hồi từ Hội đồng. Em sẽ tiếp thu những ghi nhận đó để tiếp tục hoàn thiện công trình nghiên cứu và rút ra những kinh nghiệm quý báu cho chặng đường tương lai.

Em xin chân thành cảm ơn!

LỜI CAM ĐOAN

Em tên là Nguyễn Đức Trọng, sinh viên lớp ĐH KHMT 2022, mã số sinh viên 22022012. Em xin cam đoan rằng nội dung trình bày trong khóa luận tốt nghiệp với đề tài "Phát hiện vùng bệnh và phân loại bệnh tim bằng học sâu có khả năng giải thích" là kết quả nghiên cứu độc lập của cá nhân em dưới sự hướng dẫn trực tiếp của ThS. Nguyễn Thị Mỹ Nga.

Mọi kết quả thu được và các số liệu được trình bày trong khóa luận này là trung thực và chưa từng được công bố trong bất kỳ công trình nghiên cứu nào khác trước đây. Trong suốt quá trình thực hiện, em đã tuân thủ nghiêm túc các quy định về trích dẫn tài liệu tham khảo, các nguồn dữ liệu, lý thuyết và hình ảnh được sử dụng từ các tác giả khác đều được chỉ rõ nguồn gốc và liệt kê đầy đủ trong danh mục tài liệu tham khảo.

Em xin hoàn toàn chịu trách nhiệm trước Nhà trường và pháp luật về tính trung thực cũng như bản quyền của các nội dung được trình bày trong khóa luận này. Nếu có bất kỳ sự gian lận nào, em xin chịu mọi hình thức kỷ luật theo quy định của Trường Đại học Sư phạm Kỹ thuật Vĩnh Long.

Mục lục

1 GIỚI THIỆU **1**
1.1 Lý do chọn đề tài . . . 1
1.2 Mục tiêu nghiên cứu . . . 2
1.3 Đối tượng và phạm vi nghiên cứu . . . 2
1.4 Các nghiên cứu liên quan . . . 3

2 CƠ SỞ LÝ THUYẾT **6**
2.1 Tổng quan về Trí tuệ nhân tạo . . . 6
2.2 Học máy, học sâu và học có giám sát trong ảnh y tế . . . 7
2.3 Mạng nơ-ron tích chập (CNN) . . . 8
2.4 Dữ liệu ảnh MRI tim mạch và bài toán nghiên cứu . . . 9
2.5 Tiền xử lý và tăng cường dữ liệu . . . 10
2.5.1 Tiền xử lý dữ liệu . . . 10
2.5.2 Tăng cường dữ liệu . . . 11
2.6 Các mô hình phân đoạn ảnh y tế . . . 11
2.6.1 Kiến trúc mạng U-Net++ . . . 12
2.6.2 Kiến trúc mạng Attention U-Net . . . 13
2.6.3 Kiến trúc mạng SegResNet . . . 15
2.6.4 Kiến trúc mạng DynUNet . . . 18
2.7 Các thuật toán học máy cho phân loại bệnh tim . . . 20
2.7.1 Random Forest (RF) . . . 20
2.7.2 Support Vector Machine (SVM) . . . 21
2.7.3 Multi-Layer Perceptron (MLP) . . . 23
2.7.4 Ensemble Soft Voting . . . 24
2.8 Hàm mất mát, thuật toán tối ưu và chỉ số đánh giá . . . 26
2.8.1 Thuật toán tối ưu AdamW . . . 26
2.8.2 Lịch trình tốc độ học Cosine Annealing . . . 26
2.8.3 Dice Loss . . . 26
2.8.4 DiceCELoss . . . 27
2.8.5 DiceFocalLoss . . . 27
2.9 Phương pháp trích xuất đặc trưng lâm sàng . . . 29
2.9.1 Chuẩn hóa theo diện tích bề mặt cơ thể . . . 29
2.9.2 Các đặc trưng lâm sàng sử dụng trong phân loại . . . 30
2.10 Trí tuệ nhân tạo giải thích . . . 31

2.10.1 Grad-CAM 32
2.10.2 Monte Carlo Dropout 32
2.10.3 SHAP 33

3 PHƯƠNG PHÁP ĐỀ XUẤT 34
3.1 Thiết lập thực nghiệm 34
3.1.1 Thiết lập môi trường phần cứng và phần mềm 34
3.1.2 Chiến lược phân chia dữ liệu 35
3.1.3 Thiết lập siêu tham số 35
3.1.4 Hàm mất mát và chỉ số đánh giá 36
3.2 Sơ đồ tổng quát hệ thống 37
3.2.1 Thu thập và phân tích dữ liệu 40
3.2.2 Tiền xử lý và tăng cường dữ liệu 41
3.2.3 Phân đoạn ảnh MRI tim mạch 43
3.2.4 Phát hiện và phân tích vùng nhồi máu cơ tim 45
3.2.5 Trích xuất đặc trưng và phân loại bệnh lý 46
3.2.6 Giải thích mô hình bằng Explainable AI 48

4 KẾT QUẢ THỰC NGHIỆM 49
4.1 Kết quả phân đoạn ảnh MRI tim mạch 49
4.1.1 Kịch bản thực nghiệm 49
4.1.2 Đánh giá quá trình huấn luyện và hiệu quả phân đoạn 50
4.1.3 So sánh kết quả các mô hình phân đoạn trên bộ dữ liệu ACDC 2017 và EMIDEC 2020 62
4.1.4 Lựa chọn mô hình phân đoạn chính 63
4.1.5 Đánh giá độ bất định và giải thích mô hình phân đoạn 63
4.2 Kết quả phát hiện và phân đoạn vùng nhồi máu cơ tim 66
4.2.1 Kết quả phát hiện và định lượng vùng nhồi máu cơ tim 67
4.2.2 Giải thích mô hình bằng Explainable AI 67
4.3 Kết quả phân loại bệnh lý tim mạch 69
4.3.1 Kịch bản thực nghiệm 70
4.3.2 So sánh kết quả các mô hình phân loại 71
4.3.3 Đánh giá hiệu quả phân loại 72
4.3.4 Ví dụ kết quả chẩn đoán 77
4.4 Thảo luận và so sánh với các nghiên cứu liên quan 78
4.4.1 So sánh kết quả với các nghiên cứu liên quan 78

4.4.2 So sánh điểm mới của nghiên cứu đề xuất với các nghiên cứu liên quan 79

5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 80

5.1 Kết luận 80

5.2 Hạn chế của nghiên cứu 81

5.3 Hướng phát triển 81

Tài liệu tham khảo 83

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu	**Tiếng Anh**	**Tiếng Việt**
ACDC	Automated Cardiac Diagnosis Challenge	Thử thách chẩn đoán tim tự động
AI	Artificial Intelligence	Trí tuệ nhân tạo
BSA	Body Surface Area	Diện tích bề mặt cơ thể
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
DCM	Dilated Cardiomyopathy	Bệnh cơ tim giãn
Dice	Dice Similarity Coefficient	Hệ số tương đồng Dice
DL	Deep Learning	Học sâu
DynUNet	Dynamic U-Net	Kiến trúc U-Net động
EDVi	End-Diastolic Volume Index	Chỉ số thể tích cuối tâm trương
EF	Ejection Fraction	Phân suất tống máu
EMIDEC	Automatic Evaluation of Myocardial Infarction from Delayed-Enhancement Cardiac MRI	Đánh giá tự động nhồi máu cơ tim từ ảnh MRI tăng cường muộn
Grad-CAM	Gradient-weighted Class Activation Mapping	Bản đồ kích hoạt lớp có trọng số theo gradient
HCM	Hypertrophic Cardiomyopathy	Bệnh cơ tim phì đại
HD95	95th Percentile Hausdorff Distance	Khoảng cách Hausdorff phân vị 95%
IoU	Intersection over Union	Chỉ số giao trên hợp
LGE-MRI	Late Gadolinium Enhancement MRI	MRI tăng cường tương phản muộn bằng Gadolinium
LV	Left Ventricle	Thất trái

Ký hiệu	**Tiếng Anh**	**Tiếng Việt**
MC Dropout	Monte Carlo Dropout	Ước lượng độ bất định bằng Dropout Monte Carlo
MI	Myocardial Infarction	Nhồi máu cơ tim
MINF	Myocardial Infarction	Nhóm nhồi máu cơ tim trong ACDC 2017
MLP	Multi-Layer Perceptron	Mạng Perceptron nhiều lớp
MONAI	Medical Open Network for AI	Nền tảng mã nguồn mở AI cho ảnh y tế
MRI	Magnetic Resonance Imaging	Chụp cộng hưởng từ
MYO	Myocardium	Cơ tim
NOR	Normal	Nhóm bình thường trong ACDC 2017
RF	Random Forest	Rừng ngẫu nhiên
ROC-AUC	Area Under the ROC Curve	Diện tích dưới đường cong ROC
ROI	Region of Interest	Vùng quan tâm
RV	Right Ventricle	Thất phải
SegResNet	Segmentation Residual Network	Mạng phân đoạn dựa trên Residual Network
SHAP	SHapley Additive exPlanations	Phương pháp giải thích dựa trên giá trị Shapley
SVM	Support Vector Machine	Máy véc-tơ hỗ trợ
U-Net	U-shaped Network	Mạng U-Net
XAI	Explainable Artificial Intelligence	Trí tuệ nhân tạo có khả năng giải thích

Danh sách hình vẽ

1.1 Hình ảnh mô phỏng cấu trúc giải phẫu và hệ thống mạch máu của tim [4] 1

2.1 Giới thiệu về Trí tuệ nhân tạo [8] 6
2.2 Phân loại AI [32] 7
2.3 Kiến trúc mô hình U-Net++ [37] 13
2.4 Kiến trúc mô hình Attention U-Net [26] 15
2.5 Kiến trúc mô hình SegResNet [25] 17
2.6 Kiến trúc mô hình DynUNet [14] 19

3.1 Sơ đồ tổng quát hệ thống hỗ trợ chẩn đoán bệnh tim mạch 38
3.2 Quy trình phân đoạn ảnh MRI tim mạch 44
3.3 Quy trình phân tích và phát hiện vùng tổn thương nhồi máu cơ tim . . 45
3.4 Quy trình trích xuất đặc trưng và phân loại bệnh lý 46

4.1 Kết quả huấn luyện của kịch bản 1 (SegResNet) 50
4.2 Kết quả huấn luyện của kịch bản 2 (U-Net++) 51
4.3 Kết quả huấn luyện của kịch bản 3 (Attention U-Net) 51
4.4 Kết quả huấn luyện của kịch bản 4 (DynUNet) 51
4.5 Kết quả huấn luyện của kịch bản 5 (SegResNet) 52
4.6 Kết quả huấn luyện của kịch bản 6 (U-Net++) 52
4.7 Kết quả huấn luyện của kịch bản 7 (Attention U-Net) 52
4.8 Kết quả huấn luyện của kịch bản 8 (DynUNet) 53
4.9 Dice Score trên bộ dữ liệu ACDC 2017 54
4.10 Dice Score trên bộ dữ liệu EMIDEC 2020 55
4.11 Chỉ số IoU của bốn mô hình trên bộ dữ liệu ACDC 2017 56
4.12 Chỉ số IoU của bốn mô hình trên bộ dữ liệu EMIDEC 2020 57
4.13 Chỉ số HD95 của bốn mô hình trên bộ dữ liệu ACDC 2017 58
4.14 Chỉ số HD95 của bốn mô hình trên bộ dữ liệu EMIDEC 2020 59
4.15 Thời gian huấn luyện của bốn mô hình trên bộ dữ liệu ACDC 2017 . . 60
4.16 Thời gian huấn luyện của bốn mô hình trên bộ dữ liệu EMIDEC 2020 61
4.17 Kết quả phân đoạn của mô hình U-Net++ 64
4.18 Kết quả Grad-CAM của mô hình U-Net++ 64
4.19 Sự tiến hóa đặc trưng qua các tầng của mô hình U-Net++ 65
4.20 Bản đồ độ bất định của mô hình U-Net++ 65

4.21 Kết quả phát hiện và phân đoạn vùng nhồi máu cơ tim bằng mô hình U-Net++ 66
4.22 Ví dụ kết quả phát hiện và định lượng vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020 67
4.23 Grad-CAM trên kết quả phát hiện vùng nhồi máu cơ tim của mô hình U-Net++ 68
4.24 Grad-CAM theo từng tầng của mô hình U-Net++ 68
4.25 Bản đồ độ bất định của mô hình U-Net++ 69
4.26 Kết quả phân loại của kịch bản 9 (Random Forest trên bộ dữ liệu ACDC 2017) 72
4.27 Kết quả phân loại của kịch bản 10 (SVM trên bộ dữ liệu ACDC 2017) 72
4.28 Kết quả phân loại của kịch bản 11 (MLP trên bộ dữ liệu ACDC 2017) 73
4.29 Kết quả phân loại của kịch bản 12 (Ensemble Voting trên bộ dữ liệu ACDC 2017) 73
4.30 Kết quả phân loại của kịch bản 13 (Random Forest trên bộ dữ liệu EMIDEC 2020) 74
4.31 Kết quả phân loại của kịch bản 14 (SVM trên bộ dữ liệu EMIDEC 2020) 74
4.32 Kết quả phân loại của kịch bản 15 (MLP trên bộ dữ liệu EMIDEC 2020) 75
4.33 Kết quả phân loại của kịch bản 16 (Ensemble Voting trên bộ dữ liệu EMIDEC 2020) 75
4.34 Biểu đồ SHAP Summary của mô hình Ensemble Voting trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020 76
4.35 Ví dụ kết quả chẩn đoán bệnh cơ tim phì đại (HCM) 77

Danh sách bảng

3.1 Cấu hình phần cứng và phần mềm 34
3.2 Các siêu tham số chính được sử dụng trong thực nghiệm 36

4.1 Các kịch bản thực nghiệm cho bài toán phân đoạn ảnh MRI tim mạch 50
4.2 So sánh kết quả các mô hình phân đoạn trên ACDC 2017 và EMIDEC 2020 62
4.3 Kịch bản thực nghiệm cho bài toán phân loại 70
4.4 Kết quả phân loại trên bộ dữ liệu ACDC 2017 và EMIDEC 2020 . . . 71
4.5 So sánh kết quả của nghiên cứu đề xuất với các nghiên cứu liên quan . 78
4.6 So sánh điểm mới của nghiên cứu đề xuất với các nghiên cứu liên quan 79

Chương 1. GIỚI THIỆU

1.1 Lý do chọn đề tài

Bệnh lý tim mạch hiện đang là nguyên nhân gây tử vong hàng đầu trên toàn thế giới. Để chẩn đoán và điều trị hiệu quả, hình ảnh cộng hưởng từ tim (Cardiovascular Magnetic Resonance – CMR) được xem là một trong những phương pháp không xâm lấn có độ chính xác cao trong đánh giá hình thái và chức năng tim mạch [12]. Thông qua ảnh MRI tim, bác sĩ có thể quan sát cấu trúc giải phẫu của thất trái (LV), thất phải (RV), cơ tim (MYO), đồng thời phát hiện các bất thường liên quan đến bệnh cơ tim giãn (DCM), bệnh cơ tim phì đại (HCM) hay nhồi máu cơ tim (MI) [29, 34].

Trong thực tế lâm sàng, việc phân đoạn cấu trúc tim và xác định vùng tổn thương trên ảnh MRI thường được thực hiện thủ công bởi các chuyên gia tim mạch. Tuy nhiên, quá trình này tốn nhiều thời gian, phụ thuộc vào kinh nghiệm của bác sĩ và dễ xảy ra sai sót giữa các chuyên gia. Sự phát triển của học sâu (Deep Learning), đặc biệt là các mô hình học sâu 3D, đã mở ra khả năng tự động hóa quá trình phân đoạn và hỗ trợ chẩn đoán bệnh tim với độ chính xác cao. Hình 1.1 minh họa cấu trúc giải phẫu và hệ thống mạch máu của tim, là đối tượng chính được phân tích trong nghiên cứu này.



Hình 1.1: Hình ảnh mô phỏng cấu trúc giải phẫu và hệ thống mạch máu của tim [4]

Mặc dù nhiều mô hình học sâu đạt kết quả tốt trong bài toán phân đoạn và phân loại, phần lớn các hệ thống hiện nay vẫn gặp hạn chế về khả năng giải thích. Các mô hình thường hoạt động như một "hộp đen", chỉ đưa ra kết quả dự đoán mà không cho biết cơ sở hình ảnh hoặc đặc trưng nào dẫn đến quyết định đó [31]. Điều này làm giảm mức độ tin cậy khi triển khai trong môi trường y tế thực tế.

Xuất phát từ những vấn đề trên, đề tài lựa chọn hướng nghiên cứu hệ thống hỗ trợ

phân đoạn cấu trúc tim, phát hiện vùng nhồi máu cơ tim và phân loại bệnh tim từ ảnh MRI 3D bằng học sâu có khả năng giải thích. Hệ thống không chỉ tập trung nâng cao độ chính xác phân đoạn và phân loại mà còn cung cấp các cơ chế trực quan hóa và giải thích mô hình nhằm hỗ trợ bác sĩ hiểu rõ hơn quá trình đưa ra quyết định của AI.

1.2 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng một hệ thống học sâu 3D hỗ trợ phân đoạn cấu trúc tim, phát hiện vùng nhồi máu cơ tim và phân loại bệnh tim từ ảnh MRI, đồng thời tích hợp các phương pháp AI có khả năng giải thích nhằm tăng tính minh bạch trong chẩn đoán.

Các mục tiêu cụ thể của đề tài bao gồm:

- Xây dựng hệ thống phân đoạn cấu trúc tim 3D trên bộ dữ liệu ACDC gồm thất trái (LV), thất phải (RV) và cơ tim (MYO) bằng các mô hình học sâu như Attention U-Net, U-Net++, SegResNet và DynUNet.

- Trích xuất các chỉ số hình thái học và chức năng tim từ kết quả phân đoạn như LV_EDVi, RV_EDVi, EF, độ dày cơ tim và sử dụng các đặc trưng này để phân loại 5 nhóm bệnh tim gồm Normal, DCM, HCM, MINF và RV abnormality.

- Xây dựng hệ thống phát hiện, phân đoạn và phân loại nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020, đồng thời ước lượng thể tích vùng tổn thương dựa trên kết quả phân đoạn.

- Đánh giá và so sánh hiệu năng của nhiều kiến trúc phân đoạn khác nhau thông qua các chỉ số Dice, IoU và HD95.

- Ứng dụng các kỹ thuật Explainable AI (XAI) như Grad-CAM, SHAP và Uncertainty Estimation để trực quan hóa vùng chú ý của mô hình và giải thích kết quả phân loại.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu 3D ứng dụng trong phân đoạn ảnh MRI tim mạch, phát hiện tổn thương nhồi máu cơ tim và phân loại bệnh lý tim mạch kết hợp với các kỹ thuật AI có khả năng giải thích. Do bộ dữ liệu ACDC 2017 và EMIDEC 2020 có định nghĩa nhãn và mục tiêu lâm sàng khác nhau, nghiên cứu không gộp hai bộ dữ liệu thành một tập thống nhất mà sử dụng chúng cho hai

nhiệm vụ bổ sung. Bộ dữ liệu ACDC 2017 được sử dụng cho bài toán phân đoạn cấu trúc tim và phân loại bệnh lý tim mạch, trong khi bộ dữ liệu EMIDEC 2020 được sử dụng cho bài toán phát hiện, phân đoạn và phân loại nhồi máu cơ tim trên ảnh MRI tăng cường trễ (LGE-MRI).

Phạm vi nghiên cứu của đề tài được giới hạn về dữ liệu và kỹ thuật như sau:

Về dữ liệu:

- Bộ dữ liệu ACDC 2017 gồm 150 bệnh nhân [2] được sử dụng cho bài toán phân đoạn cấu trúc tim và phân loại bệnh lý tim mạch.
- Bộ dữ liệu EMIDEC 2020 gồm các ảnh MRI tăng cường trễ (LGE-MRI)[16] được sử dụng cho bài toán phát hiện, phân đoạn và phân loại nhồi máu cơ tim.

Về kỹ thuật:

- Nghiên cứu tập trung vào các mô hình phân đoạn ảnh MRI 3D như Attention U-Net, U-Net++, SegResNet và DynUNet.
- Hệ thống sử dụng cơ chế mặt nạ prior giải phẫu để hỗ trợ mô hình phân đoạn vùng tổn thương trên bộ dữ liệu EMIDEC.
- Bài toán phân loại bệnh tim trên ACDC được xây dựng dựa trên các chỉ số lâm sàng trích xuất từ kết quả phân đoạn thay vì phân loại trực tiếp trên ảnh MRI.
- Các phương pháp Explainable AI được giới hạn trong Grad-CAM, SHAP và đánh giá độ bất định (Uncertainty Estimation).
- Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng hình thái học liên quan đến vùng nhồi máu cơ tim được trích xuất từ kết quả phân đoạn để phục vụ bài toán phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.

1.4 Các nghiên cứu liên quan

Trong những năm gần đây, trí tuệ nhân tạo và học sâu đã được ứng dụng rộng rãi trong phân tích ảnh cộng hưởng từ tim mạch (Cardiac MRI) nhằm hỗ trợ chẩn đoán và đánh giá các bệnh lý tim mạch. Các nghiên cứu liên quan có thể được chia thành bốn hướng chính gồm: phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch, phát hiện, phân đoạn và phân loại nhồi máu cơ tim và trí tuệ nhân tạo có khả năng giải thích (Explainable AI).

Phân đoạn cấu trúc tim trên ảnh MRI

Phân đoạn cấu trúc tim là một trong những bài toán nền tảng trong phân tích ảnh MRI tim mạch. Bộ dữ liệu ACDC 2017 được Bernard và cộng sự giới thiệu đã trở thành bộ dữ liệu chuẩn cho việc đánh giá các phương pháp phân đoạn thất trái (LV), thất phải (RV) và cơ tim (MYO) [2]. Từ đó, nhiều kiến trúc học sâu như U-Net, U-Net++, Attention U-Net, SegResNet và DynUNet đã được phát triển nhằm cải thiện khả năng học đặc trưng không gian và nâng cao độ chính xác phân đoạn[30, 37, 26]. Các phương pháp này đã đạt được kết quả khả quan và được ứng dụng rộng rãi trong lĩnh vực phân tích ảnh tim mạch.

Phân loại bệnh lý tim mạch từ ảnh MRI

Bên cạnh phân đoạn, nhiều nghiên cứu tập trung vào bài toán phân loại bệnh lý tim mạch dựa trên ảnh MRI. Một số công trình sử dụng trực tiếp ảnh MRI làm đầu vào cho các mô hình học sâu để thực hiện phân loại bệnh [22]. Tuy nhiên, cách tiếp cận này thường gặp khó khăn trong việc giải thích nguyên nhân dẫn đến kết quả dự đoán. Một hướng nghiên cứu khác là sử dụng kết quả phân đoạn để trích xuất các chỉ số hình thái học và chức năng tim như thể tích thất trái, thể tích thất phải, phân suất tống máu hoặc độ dày cơ tim, sau đó kết hợp với các mô hình học máy để phân loại bệnh lý [15]. Phương pháp này cho phép liên hệ kết quả dự đoán với các chỉ số lâm sàng thực tế, từ đó tăng khả năng ứng dụng trong hỗ trợ chẩn đoán.

Phát hiện, phân đoạn và phân loại nhồi máu cơ tim

Nhồi máu cơ tim là một trong những bệnh lý tim mạch nguy hiểm với tỷ lệ tử vong cao nếu không được phát hiện và điều trị kịp thời. Bộ dữ liệu EMIDEC 2020 được Lalande và cộng sự công bố nhằm thúc đẩy nghiên cứu về phát hiện và phân đoạn vùng nhồi máu cơ tim trên ảnh MRI tăng cường trễ (Late Gadolinium Enhancement MRI - LGE-MRI) [16]. So với phân đoạn cấu trúc tim thông thường, việc phát hiện vùng nhồi máu gặp nhiều khó khăn hơn do tổn thương thường có kích thước nhỏ, hình dạng phức tạp và độ tương phản thấp. Các nghiên cứu gần đây đã áp dụng các mô hình học sâu 3D kết hợp attention mechanism hoặc thông tin giải phẫu nhằm cải thiện khả năng nhận diện vùng tổn thương.[10, 21]

Bên cạnh bài toán phân đoạn tổn thương, một số nghiên cứu cũng khai thác các đặc trưng hình thái học hoặc đặc trưng học sâu để phân loại bệnh nhân có và không có nhồi máu cơ tim. Tuy nhiên, phần lớn các nghiên cứu chỉ tập trung vào một nhiệm vụ riêng lẻ mà chưa kết hợp đồng thời phân đoạn tổn thương, phân loại bệnh nhân và giải thích kết quả dự đoán trong cùng một hệ thống.

Trí tuệ nhân tạo có khả năng giải thích

Trong các ứng dụng y tế, khả năng giải thích của hệ thống AI đóng vai trò quan trọng nhằm tăng mức độ tin cậy của kết quả dự đoán. Grad-CAM [31] là một trong những phương pháp phổ biến giúp trực quan hóa các vùng ảnh mà mô hình tập trung

khi đưa ra quyết định. Bên cạnh đó, SHAP được sử dụng để đánh giá mức độ ảnh hưởng của từng đặc trưng đầu vào đối với kết quả phân loại[20]. Ngoài ra, các phương pháp đánh giá độ bất định như Monte Carlo Dropout cũng được nghiên cứu nhằm xác định mức độ tin cậy của mô hình trong các trường hợp dự đoán khó.[9]

Khoảng trống nghiên cứu và định hướng của đề tài

Qua khảo sát các công trình liên quan có thể nhận thấy phần lớn các nghiên cứu hiện nay tập trung vào từng bài toán riêng lẻ như phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch hoặc phát hiện vùng nhồi máu cơ tim. Bên cạnh đó, nhiều nghiên cứu vẫn chưa chú trọng đến khả năng giải thích kết quả dự đoán hoặc đánh giá độ tin cậy của mô hình.[31, 20, 9]

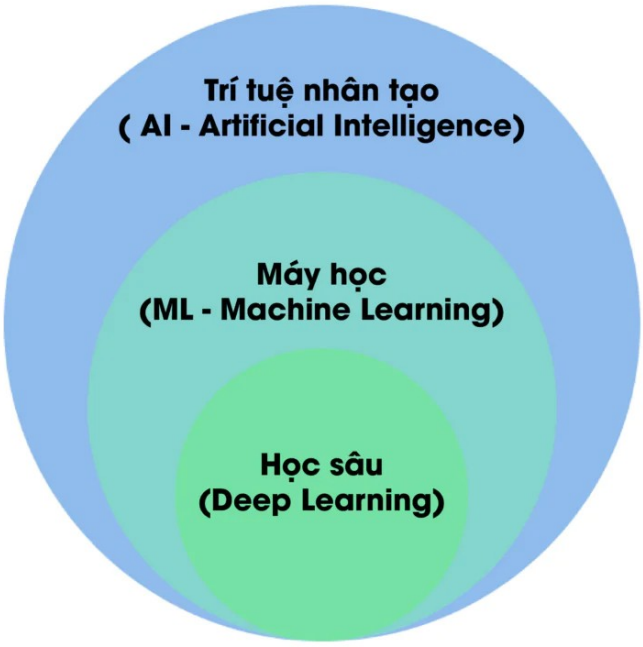
Xuất phát từ thực tế đó, đề tài hướng tới xây dựng một hệ thống hỗ trợ chẩn đoán bệnh tim mạch từ ảnh MRI theo hướng tích hợp. Trên bộ dữ liệu ACDC 2017, hệ thống thực hiện phân đoạn cấu trúc tim và phân loại bệnh lý tim mạch dựa trên các đặc trưng hình thái học và chức năng tim. Trên bộ dữ liệu EMIDEC 2020, hệ thống thực hiện phát hiện, phân đoạn và phân loại nhồi máu cơ tim dựa trên các đặc trưng hình thái học được trích xuất từ kết quả phân đoạn, đồng thời hỗ trợ ước lượng thể tích vùng tổn thương. Ngoài ra, các kỹ thuật Explainable AI như Grad-CAM, SHAP và Monte Carlo Dropout được tích hợp nhằm tăng khả năng giải thích và độ tin cậy của hệ thống. Cách tiếp cận này góp phần xây dựng một quy trình hỗ trợ chẩn đoán bệnh tim mạch toàn diện hơn trên ảnh MRI tim mạch.

Chương 2. CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về Trí tuệ nhân tạo

Trí tuệ nhân tạo (Artificial Intelligence – AI) là lĩnh vực nghiên cứu tập trung vào việc xây dựng các hệ thống máy tính có khả năng thực hiện những nhiệm vụ vốn cần đến trí thông minh của con người như nhận dạng hình ảnh, học từ dữ liệu, suy luận và hỗ trợ ra quyết định. Trong những năm gần đây, AI đã được ứng dụng rộng rãi trong nhiều lĩnh vực như tài chính, giao thông, sản xuất và đặc biệt là y tế.

Trong lĩnh vực ảnh y khoa, AI hỗ trợ bác sĩ trong nhiều bài toán như phát hiện tổn thương, phân đoạn cơ quan, phân loại bệnh lý và phân tích dữ liệu lâm sàng. Với sự phát triển của học sâu (Deep Learning), các hệ thống AI hiện nay có khả năng tự động học đặc trưng trực tiếp từ dữ liệu ảnh thay vì phụ thuộc vào các phương pháp trích xuất đặc trưng thủ công.



Hình 2.1: Giới thiệu về Trí tuệ nhân tạo [8]

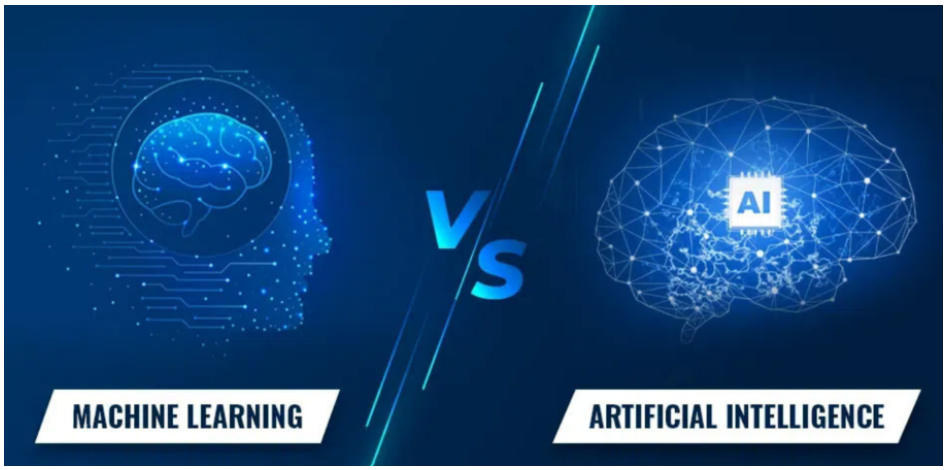
Có nhiều cách phân loại AI tùy theo khả năng xử lý hoặc phương thức học của hệ thống. Trong phạm vi đề tài này, AI được xem xét chủ yếu theo hai hướng gồm năng lực thực hiện tác vụ và phương pháp học của mô hình.

Xét theo năng lực thực hiện tác vụ, hệ thống trong nghiên cứu thuộc nhóm Trí tuệ nhân tạo hẹp (Artificial Narrow Intelligence – ANI). Đây là các hệ thống được thiết kế để giải quyết một nhiệm vụ cụ thể với hiệu quả cao. Trong đề tài này, AI được sử

dụng cho các nhiệm vụ như phân đoạn ảnh MRI tim mạch, phát hiện vùng nhồi máu cơ tim và phân loại bệnh tim. Các mô hình được huấn luyện trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020 nhằm học cách nhận diện các cấu trúc giải phẫu và đặc điểm bệnh lý từ ảnh MRI.

Bên cạnh đó, xét theo phương thức học, đề tài chủ yếu sử dụng học có giám sát (Supervised Learning). Với phương pháp này, mô hình được huấn luyện dựa trên dữ liệu đã được gán nhãn bởi các chuyên gia y tế. Các nhãn Ground-truth đóng vai trò làm dữ liệu tham chiếu để mô hình học cách dự đoán vùng tổn thương hoặc nhóm bệnh tương ứng.

Ngoài học có giám sát, AI còn bao gồm các hướng tiếp cận khác như học không giám sát (Unsupervised Learning) và học bán giám sát (Semi-supervised Learning). Tuy nhiên, trong nghiên cứu này, học có giám sát được lựa chọn do phù hợp với các bộ dữ liệu y tế đã được gán nhãn và cho phép đánh giá kết quả bằng các chỉ số định lượng rõ ràng.



Hình 2.2: Phân loại AI [32]

2.2 Học máy, học sâu và học có giám sát trong ảnh y tế

Học máy (Machine Learning – ML) là một nhánh của trí tuệ nhân tạo cho phép mô hình học quy luật từ dữ liệu thay vì được lập trình bằng các quy tắc cố định. Trong lĩnh vực y tế, học máy thường được sử dụng để phân tích các thông số lâm sàng, dữ liệu định lượng hoặc các đặc trưng hình thái học nhằm hỗ trợ phân loại và dự đoán bệnh lý.

Học sâu (Deep Learning – DL) là hướng phát triển mở rộng của học máy, sử dụng các mạng nơ-ron nhiều tầng để tự động học đặc trưng từ dữ liệu đầu vào. Đối với ảnh y khoa, đặc biệt là ảnh cộng hưởng từ tim mạch, học sâu có khả năng khai thác hiệu

quả các đặc trưng không gian phức tạp trong dữ liệu ảnh 2D và 3D.

Trong các bài toán phân đoạn ảnh y tế, mạng nơ-ron tích chập (Convolutional Neural Network – CNN) đóng vai trò quan trọng nhờ khả năng học đặc trưng cục bộ và biểu diễn cấu trúc không gian hiệu quả[30]. Nhiều kiến trúc hiện đại như Attention U-Net, U-Net++, SegResNet và DynUNet đã cho thấy hiệu quả tốt trong bài toán phân đoạn ảnh MRI tim mạch.

Trong đề tài này, học sâu được sử dụng cho nhiệm vụ phân đoạn cấu trúc tim và phát hiện vùng nhồi máu cơ tim trên ảnh MRI 3D. Các kết quả phân đoạn sau đó được sử dụng để trích xuất các đặc trưng định lượng mang ý nghĩa lâm sàng như thể tích buồng tim, phân suất tống máu và độ dày cơ tim.

Sau bước trích xuất đặc trưng, các thuật toán học máy như Random Forest, Support Vector Machine (SVM) và Multi-Layer Perceptron (MLP) được sử dụng để thực hiện phân loại bệnh tim trên bộ dữ liệu ACDC 2017 và phân loại bệnh nhân bình thường / nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020. Cách tiếp cận này giúp kết hợp ưu điểm của học sâu trong xử lý ảnh với khả năng phân tích đặc trưng định lượng của học máy truyền thống.

2.3 Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là một kiến trúc học sâu được thiết kế chuyên biệt cho dữ liệu ảnh. CNN có khả năng tự động học các đặc trưng không gian từ ảnh đầu vào thông qua các phép tích chập, giúp giảm sự phụ thuộc vào các phương pháp trích xuất đặc trưng thủ công và đạt hiệu quả cao trong các bài toán thị giác máy tính cũng như phân tích ảnh y khoa [11].

Một kiến trúc CNN cơ bản thường bao gồm ba thành phần chính:

- Convolution Layer: thực hiện phép tích chập giữa ảnh đầu vào và các bộ lọc (Kernel) nhằm trích xuất các đặc trưng như cạnh, góc, kết cấu và các mẫu hình cục bộ.

- Pooling Layer: giảm kích thước của bản đồ đặc trưng (Feature Map), loại bỏ thông tin dư thừa, giảm chi phí tính toán và góp phần hạn chế hiện tượng quá khớp (Overfitting).

- Fully Connected Layer: sử dụng các đặc trưng đã học để thực hiện nhiệm vụ phân loại hoặc dự đoán đầu ra của mô hình.

Phép tích chập trong CNN được mô tả như sau [11]:

$$S(i,j) = (X * K)(i,j) = \sum_m \sum_n X(i-m, j-n)K(m,n) \tag{2.1}$$

Trong đó:

- X là ảnh đầu vào (Input Image).
- K là bộ lọc (Kernel hoặc Filter).
- S là bản đồ đặc trưng (Feature Map) thu được sau phép tích chập.

Thông qua nhiều lớp tích chập liên tiếp, CNN có khả năng học các đặc trưng từ mức thấp đến mức cao. Các lớp đầu thường học các đặc trưng cơ bản như cạnh, góc hoặc đường viền, trong khi các lớp sâu hơn có khả năng biểu diễn các cấu trúc phức tạp mang ý nghĩa ngữ nghĩa. Đặc tính này giúp CNN trở thành nền tảng của nhiều mô hình học sâu hiện đại trong xử lý ảnh và phân tích ảnh y khoa [11].

Trong lĩnh vực ảnh y tế, CNN là nền tảng của nhiều kiến trúc phân đoạn hiện đại như U-Net, U-Net++, Attention U-Net, SegResNet và DynUNet. Các mô hình này kế thừa khả năng học đặc trưng của CNN và mở rộng theo kiến trúc Encoder–Decoder nhằm nâng cao hiệu quả phân đoạn các cấu trúc giải phẫu và vùng tổn thương trên ảnh y khoa [30, 37, 26, 25].

2.4 Dữ liệu ảnh MRI tim mạch và bài toán nghiên cứu

Ảnh cộng hưởng từ tim mạch (Cardiac Magnetic Resonance Imaging – Cardiac MRI) là một kỹ thuật hình ảnh quan trọng trong chẩn đoán và đánh giá bệnh lý tim mạch[28]. So với nhiều phương pháp hình ảnh khác, MRI có ưu điểm là không sử dụng bức xạ ion hóa, cho phép quan sát rõ cấu trúc mô mềm và cung cấp thông tin chi tiết về hình thái cũng như chức năng của tim.

Trong thực tế lâm sàng, ảnh MRI tim thường được sử dụng để đánh giá kích thước buồng tim, độ dày cơ tim, khả năng co bóp của thất trái và phát hiện các vùng tổn thương như xơ hóa hoặc nhồi máu cơ tim. Tuy nhiên, việc phân tích ảnh MRI hiện nay vẫn phụ thuộc nhiều vào thao tác thủ công của bác sĩ, gây tốn thời gian và dễ xuất hiện sai khác giữa các chuyên gia.

Trong phạm vi đề tài, hai bộ dữ liệu công khai là ACDC 2017 và EMIDEC 2020 được sử dụng cho hai mục tiêu nghiên cứu khác nhau nhưng có tính bổ sung cho nhau.

Bộ dữ liệu ACDC tập trung vào bài toán phân đoạn các cấu trúc tim gồm thất trái (Left Ventricle – LV), thất phải (Right Ventricle – RV) và cơ tim (Myocardium – MYO). Kết quả phân đoạn được sử dụng để trích xuất các đặc trưng lâm sàng như thể

tích buồng tim, phân suất tống máu và độ dày cơ tim nhằm phục vụ bài toán phân loại bệnh lý tim mạch.

Trong khi đó, bộ dữ liệu EMIDEC tập trung vào bài toán phát hiện và phân đoạn vùng nhồi máu cơ tim trên ảnh MRI tăng cường trễ (Late Gadolinium Enhancement – LGE-MRI). Bài toán này có độ khó cao hơn do vùng tổn thương thường có kích thước nhỏ và độ tương phản không ổn định.

Về tổng thể, hệ thống nghiên cứu được chia thành hai nhánh chính:

- Nhánh thứ nhất tập trung vào phân đoạn cấu trúc tim trên bộ dữ liệu ACDC nhằm phục vụ trích xuất đặc trưng và phân loại bệnh tim mạch.
- Nhánh thứ hai tập trung vào phân đoạn đa lớp vùng tổn thương trên bộ dữ liệu EMIDEC, bao gồm buồng tim (cavity/LV), cơ tim và vùng nhồi máu cơ tim.

2.5 Tiền xử lý và tăng cường dữ liệu

Dữ liệu cộng hưởng từ y khoa nói chung và dữ liệu tim mạch nói riêng thường có sự khác biệt về kích thước ảnh, độ phân giải không gian, độ dày lát cắt và dải cường độ tín hiệu. Những khác biệt này xuất phát từ thiết bị chụp, giao thức thu nhận ảnh và đặc điểm giải phẫu của từng bệnh nhân. Vì vậy, bước tiền xử lý dữ liệu đóng vai trò quan trọng nhằm chuẩn hóa dữ liệu đầu vào và giúp mô hình học sâu hoạt động ổn định hơn.

Trong nghiên cứu này, toàn bộ quá trình tiền xử lý và tăng cường dữ liệu được xây dựng dựa trên thư viện MONAI [5], một thư viện chuyên dụng cho học sâu trong ảnh y tế.

2.5.1 Tiền xử lý dữ liệu

Chuẩn hóa không gian (Spacing): Các ảnh MRI gốc thường có voxel spacing khác nhau giữa các bệnh nhân. Do đó, dữ liệu được nội suy về cùng độ phân giải không gian trước khi đưa vào mô hình. Đối với ảnh cường độ, phương pháp nội suy tuyến tính được sử dụng nhằm giữ tính liên tục của tín hiệu ảnh. Đối với ảnh nhãn, nội suy điểm gần nhất được áp dụng để bảo toàn giá trị rời rạc của các lớp phân đoạn.

Chuẩn hóa cường độ ảnh: Ảnh MRI không có thang đo cường độ cố định như ảnh CT, do đó cường độ tín hiệu có thể thay đổi đáng kể giữa các ca bệnh. Hệ thống áp dụng kỹ thuật cắt xén theo phân vị để loại bỏ các giá trị ngoại lai, sau đó chuẩn hóa cường độ ảnh về miền giá trị ổn định nhằm giảm ảnh hưởng của nhiễu và hỗ trợ quá trình tối ưu hóa.

Điều chỉnh kích thước đầu vào: Để phù hợp với các kiến trúc mạng 3D, ảnh và nhãn được đưa về cùng kích thước không gian thông qua các phép cắt, đệm hoặc thay đổi kích thước. Việc đồng bộ kích thước giúp quá trình huấn luyện theo batch được thực hiện ổn định hơn.

Cắt vùng quan tâm (ROI Cropping): Đối với bộ dữ liệu EMIDEC, hệ thống sử dụng mặt nạ prior giải phẫu được tạo từ ground-truth để xác định vùng tim. Sau đó, thuật toán CropForegroundd được sử dụng để cắt vùng quan tâm quanh cơ tim và loại bỏ phần lớn vùng nền không liên quan.

Sau bước cắt ROI, ảnh MRI và mặt nạ prior được ghép thành đầu vào hai kênh trước khi đưa vào mô hình học sâu. Cách tiếp cận này giúp mô hình tập trung tốt hơn vào vùng giải phẫu quan trọng và giảm nhiễu nền trong quá trình học.

2.5.2 Tăng cường dữ liệu

Do dữ liệu ảnh y tế thường có số lượng hạn chế, mô hình học sâu dễ gặp hiện tượng quá khớp (Overfitting). Vì vậy, các kỹ thuật tăng cường dữ liệu được áp dụng trong quá trình huấn luyện nhằm tạo thêm các biến thể của dữ liệu đầu vào.

Lật ảnh ngẫu nhiên (Random Flip): Phép lật ảnh theo các trục không gian giúp mô hình học được các đặc trưng ổn định hơn trước sự thay đổi về vị trí và hướng của cơ quan.

Biến đổi Affine ngẫu nhiên (Random Affine): Các phép xoay, dịch chuyển và thay đổi tỉ lệ nhỏ được áp dụng nhằm mô phỏng sự thay đổi tư thế bệnh nhân hoặc sai lệch trong quá trình thu nhận ảnh. Điều này giúp mô hình giảm phụ thuộc vào vị trí tuyệt đối của cấu trúc tim và cải thiện khả năng tổng quát hóa.

2.6 Các mô hình phân đoạn ảnh y tế

Các mô hình phân đoạn ảnh y tế có nhiệm vụ dự đoán nhãn cho từng điểm ảnh hoặc voxel trong ảnh. Trong bài toán MRI tim mạch, phân đoạn đóng vai trò nền tảng vì kết quả phân đoạn không chỉ được sử dụng để đánh giá ranh giới giải phẫu mà còn là cơ sở để trích xuất các chỉ số hình thái học và chức năng tim mạch phục vụ cho giai đoạn phân loại bệnh lý.

Trong nghiên cứu này, bốn kiến trúc học sâu tiêu biểu được lựa chọn để đánh giá và so sánh bao gồm U-Net++, Attention U-Net, SegResNet và DynUNet. Các mô hình này đại diện cho nhiều hướng phát triển khác nhau của học sâu trong ảnh y tế, từ kiến trúc kinh điển đến các biến thể hiện đại có khả năng khai thác dữ liệu 3D hiệu quả hơn.

2.6.1 Kiến trúc mạng U-Net++

Tổng quan và cơ sở lý thuyết

U-Net++ (Nested U-Net) được Zhou và cộng sự đề xuất vào năm 2018 [37] nhằm cải thiện hiệu quả phân đoạn ảnh y tế so với kiến trúc U-Net truyền thống. Mô hình được phát triển dựa trên nhận định rằng các đặc trưng ở tầng nông và tầng sâu trong U-Net có sự khác biệt lớn về mức độ ngữ nghĩa, khiến quá trình kết hợp thông tin giữa Encoder và Decoder chưa thực sự tối ưu.

Để khắc phục hạn chế này, U-Net++ bổ sung hệ thống các đường dẫn tắt lồng nhau (Nested Dense Skip Pathways), giúp giảm khoảng cách ngữ nghĩa giữa các đặc trưng trước khi thực hiện quá trình hợp nhất trong Decoder. Nhờ đó, mô hình có khả năng tái tạo chi tiết biên dạng đối tượng tốt hơn, đặc biệt trong các bài toán phân đoạn ảnh y tế có cấu trúc phức tạp.

Kiến trúc và nguyên lý hoạt động

Tương tự U-Net, U-Net++ vẫn được xây dựng theo cấu trúc Encoder–Decoder. Encoder thực hiện quá trình trích xuất đặc trưng và giảm kích thước không gian của ảnh đầu vào, trong khi Decoder thực hiện tăng kích thước đặc trưng để khôi phục mặt nạ phân đoạn.

Điểm khác biệt quan trọng nhất nằm ở các kết nối tắt lồng nhau giữa Encoder và Decoder. Thay vì kết nối trực tiếp như U-Net, U-Net++ sử dụng nhiều nút trung gian nhằm làm giàu đặc trưng trước khi truyền sang Decoder.

Các kết nối lồng nhau trong U-Net++ có thể được mô tả như sau [37]:

$$X^{i,j} = H\left(\left[X^{i,0}, X^{i,1}, \ldots, X^{i,j-1}, U(X^{i+1,j-1})\right]\right) \tag{2.2}$$

Trong đó:

- $X^{i,j}$ là đặc trưng tại mức i và chiều sâu j.

- $U(\cdot)$ là phép tăng mẫu (Upsampling).

- $H(\cdot)$ là chuỗi các phép convolution, normalization và activation.

Nhờ cơ chế này, các đặc trưng được tinh chỉnh nhiều lần trước khi kết hợp với Decoder, giúp giảm sự khác biệt ngữ nghĩa giữa các tầng và cải thiện khả năng nhận diện các cấu trúc có kích thước nhỏ hoặc biên không rõ ràng.

Ưu điểm và hạn chế

Ưu điểm:

- Giảm khoảng cách ngữ nghĩa giữa Encoder và Decoder.

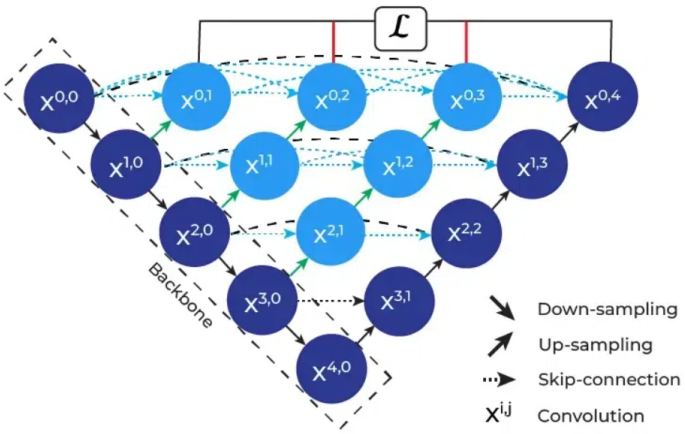
- Cải thiện chất lượng phân đoạn tại các vùng biên phức tạp.
- Khai thác hiệu quả thông tin đa mức thông qua các kết nối lồng nhau.
- Được ứng dụng rộng rãi trong nhiều bài toán phân đoạn ảnh y tế.

Hạn chế:

- Số lượng tham số lớn hơn U-Net truyền thống.
- Yêu cầu thời gian huấn luyện và bộ nhớ cao hơn.
- Độ phức tạp kiến trúc tăng do sử dụng nhiều kết nối trung gian.

Lý do lựa chọn trong nghiên cứu

U-Net++ đại diện cho hướng cải tiến kiến trúc U-Net thông qua việc tối ưu hóa hệ thống skip connection. Do đó, mô hình được lựa chọn trong nghiên cứu nhằm đánh giá mức độ ảnh hưởng của các kết nối tắt lồng nhau đối với bài toán phân đoạn ảnh MRI tim mạch và làm cơ sở so sánh với các kiến trúc hiện đại khác.



Hình 2.3: Kiến trúc mô hình U-Net++ [37]

2.6.2 Kiến trúc mạng Attention U-Net

Tổng quan và cơ sở lý thuyết

Attention U-Net được đề xuất bởi Oktay và cộng sự vào năm 2018 [26] nhằm cải thiện hiệu quả phân đoạn ảnh y tế bằng cách tích hợp cơ chế chú ý (Attention Mechanism) vào kiến trúc U-Net truyền thống. Ý tưởng chính của mô hình là cho phép mạng tự động tập trung vào các vùng ảnh quan trọng thay vì xử lý toàn bộ ảnh với mức độ ưu tiên như nhau.

Trong các bài toán ảnh y tế, vùng tổn thương hoặc cơ quan cần phân đoạn thường chỉ chiếm một phần nhỏ diện tích ảnh. Do đó, việc sử dụng cơ chế chú ý giúp mô hình giảm ảnh hưởng của vùng nền và tăng khả năng nhận diện các cấu trúc mục tiêu.

Kiến trúc và nguyên lý hoạt động

Attention U-Net vẫn giữ nguyên cấu trúc Encoder–Decoder của U-Net. Tuy nhiên, trước khi thực hiện quá trình kết hợp đặc trưng giữa Encoder và Decoder, mô hình bổ sung các khối Attention Gate (AG) để lựa chọn các đặc trưng quan trọng.

Thành phần cốt lõi của mô hình là Attention Gate. Với đặc trưng đầu vào x từ Encoder và tín hiệu ngữ cảnh g từ Decoder, hệ số chú ý được tính như sau [26]:

$$q = W_x x + W_g g + b \tag{2.3}$$

$$\alpha = \sigma(\psi^T ReLU(q)) \tag{2.4}$$

$$x' = \alpha \odot x \tag{2.5}$$

Trong đó:

- x là đặc trưng đầu vào từ Encoder.
- g là tín hiệu ngữ cảnh từ Decoder.
- α là bản đồ trọng số chú ý.
- σ là hàm sigmoid.
- $\odot$ là phép nhân từng phần tử.
- x' là đặc trưng sau khi được Attention Gate chọn lọc.

Các đặc trưng có giá trị chú ý cao sẽ được giữ lại và truyền sang Decoder, trong khi các đặc trưng ít quan trọng sẽ bị giảm trọng số. Nhờ đó, mô hình có thể tập trung nhiều hơn vào các vùng chứa thông tin bệnh lý hoặc cấu trúc giải phẫu quan trọng.

Ưu điểm và hạn chế

Ưu điểm:

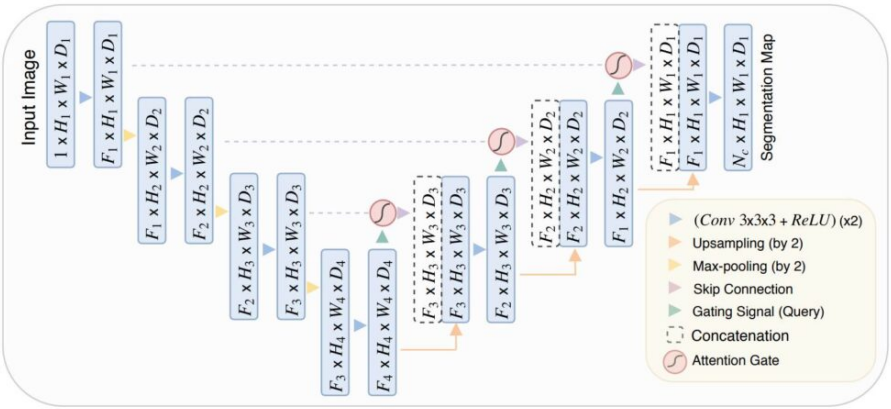
- Tăng khả năng tập trung vào các vùng quan trọng trong ảnh.
- Giảm ảnh hưởng của vùng nền và nhiễu.
- Cải thiện khả năng nhận diện các tổn thương nhỏ hoặc có độ tương phản thấp.
- Phù hợp với các bài toán phân đoạn ảnh y tế có vùng quan tâm nhỏ.

Hạn chế:

- Tăng độ phức tạp của kiến trúc mạng.
- Yêu cầu thời gian huấn luyện lớn hơn U-Net truyền thống.
- Hiệu quả phụ thuộc vào chất lượng đặc trưng được trích xuất từ Encoder.

Lý do lựa chọn trong nghiên cứu

Attention U-Net đại diện cho hướng tiếp cận tích hợp cơ chế chú ý vào bài toán phân đoạn ảnh y tế. Mô hình được lựa chọn nhằm đánh giá khả năng cải thiện hiệu quả phân đoạn khi tập trung vào các vùng giải phẫu hoặc tổn thương quan trọng trên ảnh MRI tim mạch, đặc biệt đối với các vùng có kích thước nhỏ hoặc độ tương phản thấp.



Hình 2.4: Kiến trúc mô hình Attention U-Net [26]

2.6.3 Kiến trúc mạng SegResNet

Tổng quan và cơ sở lý thuyết

SegResNet được phát triển bởi Myronenko [25] và được tích hợp trong thư viện MONAI như một kiến trúc chuyên biệt cho bài toán phân đoạn ảnh y tế 3D. Mô hình là sự kết hợp giữa kiến trúc Encoder–Decoder của U-Net và cơ chế Residual Learning của ResNet nhằm khai thác hiệu quả thông tin không gian trong dữ liệu ảnh y tế dạng khối (volumetric data).

Ý tưởng cốt lõi của SegResNet là thay vì học trực tiếp ánh xạ từ đầu vào đến đầu ra, mô hình học một hàm dư (Residual Function) và cộng trở lại với đầu vào ban đầu. Cơ chế này giúp duy trì dòng thông tin xuyên suốt mạng và giảm hiện tượng tiêu biến gradient khi huấn luyện các mạng sâu.

Kiến trúc và nguyên lý hoạt động

SegResNet được xây dựng theo cấu trúc Encoder–Decoder gồm hai thành phần chính:

- Encoder: thực hiện trích xuất đặc trưng và giảm kích thước không gian thông qua các Residual Block kết hợp với các lớp convolution 3D.

- Decoder: thực hiện tăng kích thước đặc trưng bằng các lớp upsampling và kết hợp thông tin từ Encoder thông qua skip connection để tái tạo mặt nạ phân đoạn cuối cùng.

Thành phần quan trọng nhất của mô hình là Residual Block. Đầu ra của mỗi khối được tính theo công thức [25]:

$$y = F(x) + x \tag{2.6}$$

Trong đó:

- x là đặc trưng đầu vào.

- $F(x)$ là hàm được học bởi các lớp convolution.

- y là đầu ra của Residual Block.

Nhờ kết nối residual, thông tin và gradient có thể được truyền trực tiếp giữa các tầng mạng, giúp mô hình học hiệu quả hơn khi số lượng tầng tăng lên.

Ngoài các Residual Block, SegResNet còn sử dụng Group Normalization thay cho Batch Normalization. Điều này đặc biệt phù hợp với dữ liệu ảnh y tế 3D do kích thước batch thường nhỏ và không đủ ổn định để sử dụng Batch Normalization.

Việc sử dụng các lớp convolution 3D cho phép mô hình khai thác đầy đủ mối quan hệ không gian giữa các lát cắt MRI, từ đó cải thiện khả năng nhận diện các cấu trúc giải phẫu như thất trái, thất phải và cơ tim.

Ưu điểm và hạn chế

Ưu điểm:

- Khai thác hiệu quả thông tin không gian 3D của ảnh MRI.

- Giảm hiện tượng tiêu biến gradient nhờ cơ chế Residual Learning.

- Huấn luyện ổn định trên dữ liệu y tế có kích thước batch nhỏ.

- Phù hợp với bài toán phân đoạn đa lớp trong ảnh y tế.

Hạn chế:

- Yêu cầu tài nguyên tính toán và bộ nhớ lớn do sử dụng convolution 3D.

- Thời gian huấn luyện dài hơn so với các mô hình 2D.
- Hiệu quả phụ thuộc vào chất lượng tiền xử lý dữ liệu.

Lý do lựa chọn trong nghiên cứu

SegResNet đại diện cho hướng tiếp cận kết hợp Residual Learning với phân đoạn ảnh y tế 3D. Mô hình được lựa chọn nhằm đánh giá khả năng khai thác thông tin không gian của dữ liệu MRI tim mạch và so sánh với các kiến trúc phân đoạn khác trong nghiên cứu.



Hình 2.5: Kiến trúc mô hình SegResNet [25]

2.6.4 Kiến trúc mạng DynUNet

Tổng quan và cơ sở lý thuyết

DynUNet (Dynamic U-Net) là một kiến trúc phân đoạn ảnh y tế hiện đại được phát triển dựa trên các nguyên lý tự cấu hình của nnU-Net [14]. Mô hình được thiết kế nhằm giải quyết hạn chế của các kiến trúc U-Net truyền thống khi phải xử lý các bộ dữ liệu có kích thước, độ phân giải và voxel spacing khác nhau.

Khác với các mô hình có cấu trúc cố định, DynUNet cho phép tự động điều chỉnh nhiều thành phần của mạng như số tầng, số lượng bộ lọc, kích thước kernel và chiến lược giảm mẫu dựa trên đặc điểm của dữ liệu đầu vào. Nhờ đó, mô hình có khả năng thích ứng tốt với nhiều loại ảnh y tế khác nhau mà không cần thiết kế thủ công cho từng bộ dữ liệu.

Kiến trúc và nguyên lý hoạt động

DynUNet vẫn kế thừa kiến trúc Encoder–Decoder đặc trưng của U-Net. Trong đó:

- Encoder thực hiện quá trình trích xuất đặc trưng thông qua các lớp convolution 3D và giảm dần kích thước không gian của dữ liệu.
- Decoder thực hiện quá trình khôi phục thông tin không gian bằng các lớp upsampling kết hợp với skip connection để tạo ra mặt nạ phân đoạn cuối cùng.

Điểm khác biệt quan trọng nhất của DynUNet nằm ở khả năng tự cấu hình kiến trúc. Thay vì sử dụng các kernel và stride cố định, mô hình có thể điều chỉnh:

- Số tầng Encoder và Decoder.
- Kích thước kernel convolution.
- Chiến lược giảm mẫu (Downsampling).
- Số lượng feature map tại từng mức.

Khả năng này giúp DynUNet tối ưu hóa việc khai thác thông tin từ dữ liệu đầu vào và duy trì hiệu quả trên nhiều loại ảnh y tế khác nhau.

Ngoài ra, DynUNet sử dụng các skip connection đa mức để kết hợp thông tin cục bộ và thông tin ngữ nghĩa toàn cục. Điều này giúp mô hình nhận diện tốt các cấu trúc hoặc tổn thương có kích thước và hình dạng khác nhau.

Việc sử dụng convolution 3D xuyên suốt kiến trúc cũng cho phép DynUNet khai thác đầy đủ mối quan hệ không gian giữa các lát cắt MRI thay vì xử lý từng lát cắt độc lập như các mô hình 2D.

Ưu điểm và hạn chế

Ưu điểm:

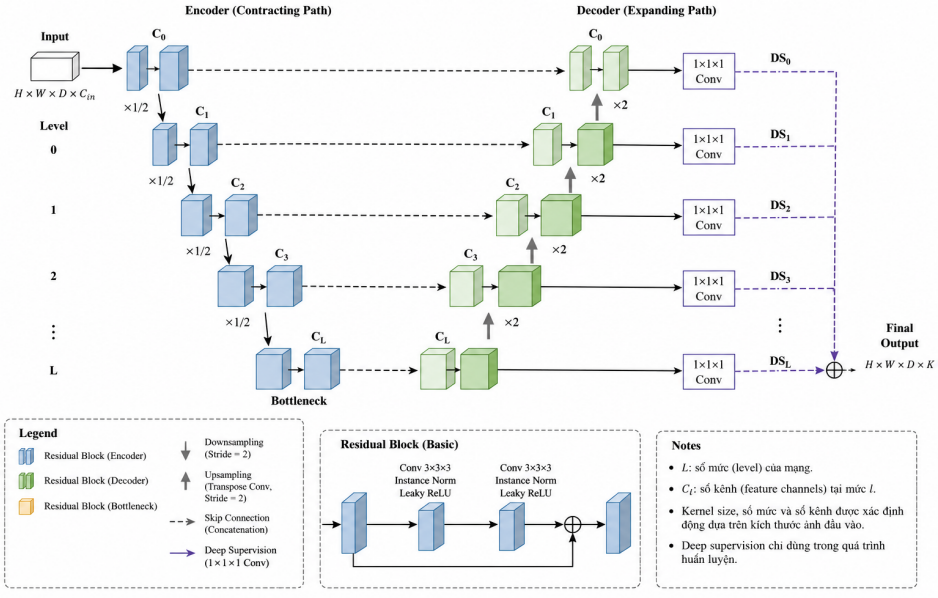
- Tự động thích ứng với đặc điểm của dữ liệu đầu vào.
- Khai thác hiệu quả đặc trưng đa tỷ lệ.
- Hỗ trợ dữ liệu ảnh y tế 3D.
- Nhận diện tốt các tổn thương có kích thước và hình dạng khác nhau.
- Giảm nhu cầu thiết kế thủ công kiến trúc cho từng bộ dữ liệu.

Hạn chế:

- Yêu cầu tài nguyên tính toán lớn do sử dụng convolution 3D.
- Thời gian huấn luyện và suy luận cao hơn các mô hình đơn giản.
- Quá trình cấu hình và tối ưu mô hình phức tạp hơn các kiến trúc U-Net truyền thống.

Lý do lựa chọn trong nghiên cứu

DynUNet đại diện cho hướng tiếp cận phân đoạn ảnh y tế hiện đại với khả năng tự cấu hình theo đặc điểm dữ liệu đầu vào. Mô hình được lựa chọn nhằm đánh giá khả năng phát hiện và phân đoạn vùng nhồi máu cơ tim trên ảnh LGE-MRI, đồng thời so sánh với các kiến trúc phân đoạn khác trong nghiên cứu.



Hình 2.6: Kiến trúc mô hình DynUNet [14]

2.7 Các thuật toán học máy cho phân loại bệnh tim

Sau khi hoàn thành bước phân đoạn ảnh MRI tim mạch, hệ thống tiến hành trích xuất các đặc trưng hình thái học và chức năng tim như thể tích thất trái, thể tích thất phải, phân suất tống máu và độ dày cơ tim. Các đặc trưng này sau đó được sử dụng làm đầu vào cho các thuật toán học máy nhằm thực hiện phân loại bệnh lý tim mạch trên bộ dữ liệu ACDC 2017.

Trong nghiên cứu này, các mô hình Random Forest, Support Vector Machine (SVM), Multi-Layer Perceptron (MLP) và Ensemble Voting được sử dụng để đánh giá khả năng phân loại bệnh tim từ các đặc trưng lâm sàng đã trích xuất.

2.7.1 Random Forest (RF)

Tổng quan và cơ sở lý thuyết

Random Forest được đề xuất bởi Breiman vào năm 2001 [3] và là một trong những thuật toán học máy phổ biến nhất cho các bài toán phân loại và hồi quy. Mô hình thuộc nhóm phương pháp học tổ hợp (Ensemble Learning), trong đó nhiều cây quyết định được kết hợp nhằm nâng cao hiệu quả dự đoán và giảm hiện tượng quá khớp.

Ý tưởng chính của Random Forest là xây dựng nhiều cây quyết định trên các tập dữ liệu con được tạo ngẫu nhiên từ tập huấn luyện ban đầu, sau đó tổng hợp kết quả từ các cây để đưa ra dự đoán cuối cùng.

Nguyên lý hoạt động

Quá trình xây dựng Random Forest gồm hai bước chính:

- Tạo nhiều tập dữ liệu con bằng kỹ thuật Bootstrap Sampling.

- Huấn luyện một cây quyết định trên mỗi tập dữ liệu con.

Trong giai đoạn dự đoán, kết quả cuối cùng được xác định thông qua cơ chế bỏ phiếu đa số [3]:

$$\hat{y} = \text{mode}(T_1(x), T_2(x), ..., T_n(x)) \tag{2.7}$$

Trong đó:

- $T_i(x)$ là kết quả dự đoán của cây quyết định thứ i.

- n là số lượng cây trong rừng.

- $\hat{y}$ là nhãn dự đoán cuối cùng.

Việc kết hợp nhiều cây quyết định giúp giảm sai số do từng cây riêng lẻ gây ra và tăng khả năng tổng quát hóa của mô hình.

Ưu điểm và hạn chế

Ưu điểm:

- Ít bị quá khớp hơn cây quyết định đơn lẻ.
- Hoạt động tốt trên dữ liệu có kích thước vừa và nhỏ.
- Có khả năng đánh giá mức độ quan trọng của các đặc trưng.
- Không yêu cầu nhiều giả định về dữ liệu đầu vào.

Hạn chế:

- Khó giải thích hơn cây quyết định đơn lẻ.
- Số lượng cây lớn có thể làm tăng thời gian huấn luyện và dự đoán.
- Hiệu quả giảm khi dữ liệu chứa nhiều nhiễu.

Lý do lựa chọn trong nghiên cứu

Random Forest đại diện cho nhóm thuật toán học tổ hợp dựa trên cây quyết định. Mô hình được sử dụng nhằm đánh giá khả năng phân loại bệnh tim dựa trên các đặc trưng hình thái học và chức năng tim được trích xuất từ kết quả phân đoạn MRI.

2.7.2 Support Vector Machine (SVM)

Tổng quan và cơ sở lý thuyết

Support Vector Machine (SVM) là một thuật toán học máy được đề xuất bởi Cortes và Vapnik vào năm 1995 [6]. SVM thuộc nhóm thuật toán học có giám sát và được sử dụng rộng rãi trong các bài toán phân loại nhờ khả năng tổng quát hóa tốt trên các tập dữ liệu có kích thước vừa và nhỏ.

Ý tưởng cốt lõi của SVM là tìm một siêu phẳng phân tách (Hyperplane) tối ưu giữa các lớp dữ liệu sao cho khoảng cách từ siêu phẳng đến các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất. Các điểm dữ liệu nằm gần siêu phẳng nhất được gọi là các vector hỗ trợ (Support Vectors).

Nguyên lý hoạt động

Cho tập dữ liệu huấn luyện gồm các mẫu (x_i, y_i), SVM tìm siêu phẳng phân tách có dạng [6]:

$$w^T x + b = 0 \tag{2.8}$$

Trong đó:

- w là vector trọng số xác định hướng của siêu phẳng.
- b là hệ số dịch chuyển.
- x là vector đặc trưng đầu vào.

Mục tiêu của SVM là cực đại hóa khoảng cách biên (Margin) giữa hai lớp dữ liệu. Khoảng cách biên càng lớn thì khả năng tổng quát hóa của mô hình càng cao.

Trong trường hợp dữ liệu không thể phân tách tuyến tính, SVM sử dụng các hàm kernel để ánh xạ dữ liệu sang không gian đặc trưng có chiều cao hơn. Một số kernel phổ biến gồm:

- Linear Kernel.
- Polynomial Kernel.
- Radial Basis Function (RBF) Kernel.

Nhờ cơ chế kernel, SVM có khả năng xử lý hiệu quả các bài toán phân loại phi tuyến mà không cần biểu diễn tường minh dữ liệu trong không gian mới.

Ưu điểm và hạn chế

Ưu điểm:

- Hoạt động hiệu quả trên các tập dữ liệu vừa và nhỏ.
- Khả năng tổng quát hóa tốt.
- Hiệu quả đối với dữ liệu có số chiều lớn.
- Hỗ trợ phân loại phi tuyến thông qua hàm kernel.

Hạn chế:

- Thời gian huấn luyện tăng khi kích thước dữ liệu lớn.
- Việc lựa chọn kernel và các siêu tham số ảnh hưởng đáng kể đến hiệu quả mô hình.
- Khó diễn giải hơn so với các mô hình cây quyết định.

Lý do lựa chọn trong nghiên cứu

SVM đại diện cho nhóm thuật toán học máy dựa trên tối ưu hóa siêu phẳng phân tách. Mô hình được sử dụng nhằm đánh giá khả năng phân loại bệnh tim dựa trên các đặc trưng hình thái học và chức năng tim được trích xuất từ kết quả phân đoạn MRI.

2.7.3 Multi-Layer Perceptron (MLP)

Tổng quan và cơ sở lý thuyết

Multi-Layer Perceptron (MLP) là một loại mạng nơ-ron nhân tạo truyền thẳng (Feedforward Neural Network) gồm nhiều lớp perceptron được kết nối đầy đủ với nhau [11]. MLP là một trong những kiến trúc nền tảng của học sâu và có khả năng học các mối quan hệ phi tuyến giữa dữ liệu đầu vào và đầu ra.

Khác với các mô hình học máy truyền thống, MLP có thể tự động học các đặc trưng ẩn thông qua nhiều tầng xử lý liên tiếp. Điều này giúp mô hình biểu diễn được các mối quan hệ phức tạp trong dữ liệu mà các phương pháp tuyến tính khó khai thác được.

Kiến trúc và nguyên lý hoạt động

Một mạng MLP cơ bản thường bao gồm ba thành phần chính:

- Lớp đầu vào (Input Layer): nhận các đặc trưng đầu vào.
- Một hoặc nhiều lớp ẩn (Hidden Layers): thực hiện quá trình học và trích xuất đặc trưng.
- Lớp đầu ra (Output Layer): đưa ra kết quả phân loại hoặc dự đoán.

Một neuron trong mạng MLP được mô tả như sau [11]:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right) \tag{2.9}$$

Trong đó:

- x_i là đặc trưng đầu vào.
- w_i là trọng số kết nối.
- b là hệ số bias.
- $f(\cdot)$ là hàm kích hoạt phi tuyến.
- y là đầu ra của neuron.

Trong quá trình huấn luyện, MLP sử dụng thuật toán lan truyền ngược sai số (Backpropagation) kết hợp với các thuật toán tối ưu như Gradient Descent hoặc Adam để cập nhật trọng số và giảm thiểu hàm mất mát.

Nhờ các hàm kích hoạt phi tuyến như ReLU, Sigmoid hoặc Tanh, MLP có khả năng học được các quan hệ phi tuyến giữa các đặc trưng đầu vào và nhãn đầu ra.

Ưu điểm và hạn chế

Ưu điểm:

- Khả năng học các mối quan hệ phi tuyến phức tạp.
- Linh hoạt trong nhiều bài toán phân loại và dự đoán.
- Có thể khai thác hiệu quả các đặc trưng lâm sàng đa chiều.
- Dễ dàng mở rộng bằng cách tăng số lớp hoặc số neuron.

Hạn chế:

- Dễ xảy ra hiện tượng quá khớp khi dữ liệu huấn luyện hạn chế.
- Hiệu quả phụ thuộc vào việc lựa chọn kiến trúc và siêu tham số.
- Thời gian huấn luyện có thể tăng khi số lớp và số neuron lớn.

Lý do lựa chọn trong nghiên cứu

MLP đại diện cho nhóm mô hình mạng nơ-ron có khả năng học các quan hệ phi tuyến giữa các đặc trưng. Mô hình được sử dụng nhằm đánh giá khả năng phân loại bệnh tim từ các đặc trưng hình thái học và chức năng tim được trích xuất từ kết quả phân đoạn MRI.

2.7.4 Ensemble Soft Voting

Tổng quan và cơ sở lý thuyết

Ensemble Learning là một hướng tiếp cận trong học máy nhằm nâng cao hiệu quả dự đoán bằng cách kết hợp nhiều mô hình khác nhau [7]. Thay vì phụ thuộc vào một bộ phân loại đơn lẻ, Ensemble Learning tận dụng ưu điểm của nhiều mô hình để đưa ra quyết định cuối cùng, từ đó cải thiện khả năng tổng quát hóa và tăng độ ổn định của hệ thống.

Một trong những phương pháp Ensemble phổ biến là Voting Ensemble, trong đó kết quả dự đoán từ nhiều bộ phân loại được tổng hợp để xác định nhãn cuối cùng. Voting Ensemble thường được chia thành hai loại chính gồm Hard Voting và Soft Voting.

- Hard Voting sử dụng trực tiếp nhãn dự đoán của từng mô hình để thực hiện bỏ phiếu đa số.
- Soft Voting sử dụng xác suất dự đoán của từng lớp từ các mô hình thành phần và tính xác suất trung bình trước khi đưa ra quyết định cuối cùng.

Trong nghiên cứu này, phương pháp Soft Voting được lựa chọn nhằm tận dụng thông tin xác suất dự đoán từ nhiều bộ phân loại khác nhau.

Nguyên lý hoạt động

Ba bộ phân loại gồm Random Forest, Support Vector Machine (SVM) và Multi-Layer Perceptron (MLP) được huấn luyện độc lập trên cùng tập đặc trưng lâm sàng. Mỗi mô hình sẽ đưa ra xác suất dự đoán cho từng lớp bệnh tim.

Giả sử có N mô hình thành phần, xác suất cuối cùng của lớp c được tính như sau [7]:

$$P(y = c) = \frac{1}{N} \sum_{i=1}^{N} P_i(y = c) \tag{2.10}$$

Trong đó:

- $P_i(y = c)$ là xác suất dự đoán lớp c của mô hình thứ i.
- N là số lượng mô hình thành phần.

Sau khi tính xác suất trung bình cho tất cả các lớp, nhãn dự đoán cuối cùng được xác định bởi [7]:

$$\hat{y} = \arg\max_{c} P(y = c) \tag{2.11}$$

Nhờ sử dụng xác suất thay vì nhãn dự đoán trực tiếp, Soft Voting có khả năng khai thác mức độ tin cậy của từng mô hình, từ đó đưa ra quyết định chính xác và ổn định hơn.

Ưu điểm và hạn chế

Ưu điểm:

- Tận dụng ưu điểm của nhiều mô hình học máy khác nhau.
- Giảm ảnh hưởng của sai số từ từng mô hình riêng lẻ.
- Cải thiện khả năng tổng quát hóa và độ ổn định của hệ thống.
- Thường đạt hiệu quả cao hơn so với việc sử dụng từng bộ phân loại đơn lẻ.

Hạn chế:

- Thời gian huấn luyện và suy luận lớn hơn do phải sử dụng nhiều mô hình.
- Hiệu quả phụ thuộc vào chất lượng của các mô hình thành phần.

- Việc kết hợp các mô hình có hiệu suất thấp có thể làm giảm hiệu quả chung của hệ thống.

Lý do lựa chọn trong nghiên cứu

Soft Voting đại diện cho hướng tiếp cận học tổ hợp trong bài toán phân loại bệnh tim. Phương pháp này được lựa chọn nhằm đánh giá khả năng cải thiện hiệu quả phân loại thông qua việc kết hợp các ưu điểm của Random Forest, SVM và MLP. Đồng thời, đây cũng là cơ sở để xây dựng bộ phân loại cuối cùng cho hệ thống hỗ trợ chẩn đoán bệnh tim trong nghiên cứu.

2.8 Hàm mất mát, thuật toán tối ưu và chỉ số đánh giá

2.8.1 Thuật toán tối ưu AdamW

AdamW là biến thể cải tiến của Adam, trong đó cơ chế suy giảm trọng số được tách khỏi bước cập nhật gradient [19]. Điều này giúp kiểm soát độ phức tạp của mô hình hiệu quả hơn và giảm hiện tượng quá khớp.

Công thức cập nhật trọng số có thể được biểu diễn như sau [19]:

$$\theta_{t+1} = \theta_t - \eta_t \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_t \right) \tag{2.12}$$

Trong đó η_t là tốc độ học, $\hat{m}_t$ và $\hat{v}_t$ là ước lượng moment bậc nhất và bậc hai, λ là hệ số suy giảm trọng số.

2.8.2 Lịch trình tốc độ học Cosine Annealing

Cosine Annealing là chiến lược điều chỉnh tốc độ học theo hàm cosin [18]. Tốc độ học giảm dần từ giá trị ban đầu về giá trị nhỏ hơn ở cuối quá trình huấn luyện [18]:

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left(1 + \cos \left(\frac{T_{cur}}{T_{max}} \pi \right) \right) \tag{2.13}$$

Cách điều chỉnh này giúp mô hình học nhanh ở giai đoạn đầu và tinh chỉnh ổn định ở giai đoạn cuối.

2.8.3 Dice Loss

Dice Loss được xây dựng dựa trên hệ số Dice, tập trung tối ưu hóa độ chồng lấp giữa vùng dự đoán và vùng nhãn thực tế [23]. Công thức Dice Loss được biểu diễn

như sau [23]:

$$L_{Dice} = 1 - \frac{2\sum_{i=1}^{N} y_i p_i + \epsilon}{\sum_{i=1}^{N} y_i + \sum_{i=1}^{N} p_i + \epsilon} \tag{2.14}$$

Trong đó y_i là nhãn thực tế, p_i là xác suất dự đoán và ϵ là hằng số nhỏ để tránh chia cho 0.

2.8.4 DiceCELoss

DiceCELoss là hàm mất mát kết hợp giữa Cross-Entropy và Dice Loss. Thành phần Cross-Entropy giúp tối ưu xác suất phân lớp tại từng voxel, trong khi Dice Loss tập trung vào độ chồng lấp không gian giữa vùng dự đoán và nhãn thật.

$$L_{DiceCE} = L_{CE} + L_{Dice} \tag{2.15}$$

Sự kết hợp này phù hợp với bài toán phân đoạn ảnh y tế vì vừa đảm bảo học đúng nhãn từng điểm ảnh, vừa cải thiện hình dạng tổng thể của vùng phân đoạn.

2.8.5 DiceFocalLoss

DiceFocalLoss kết hợp Dice Loss với Focal Loss. Focal Loss được đề xuất nhằm giảm ảnh hưởng của các mẫu dễ và tập trung nhiều hơn vào các mẫu khó [17]. Công thức Focal Loss được biểu diễn như sau [17]:

$$L_{Focal} = -(1 - p_t)^{\gamma} \log(p_t) \tag{2.16}$$

Trong bài toán EMIDEC, vùng nhồi máu thường nhỏ hơn nhiều so với vùng nền, do đó DiceFocalLoss giúp mô hình chú ý tốt hơn đến các lớp thiểu số.

Chỉ số đánh giá phân đoạn

Dice Similarity Coefficient (DSC):

Dice Similarity Coefficient (DSC) được sử dụng để đánh giá mức độ chồng lấp giữa vùng dự đoán và vùng ground-truth. Chỉ số này có giá trị trong khoảng từ 0 đến 1, trong đó giá trị càng gần 1 thể hiện kết quả phân đoạn càng chính xác [33]. DSC được tính theo công thức:

$$\text{Dice} = \frac{2TP}{2TP + FP + FN} \tag{2.17}$$

Trong đó, TP, FP và FN lần lượt là số điểm ảnh dự đoán đúng, dự đoán sai dương tính và dự đoán sai âm tính.

Intersection over Union (IoU):

Intersection over Union (IoU), còn được gọi là chỉ số Jaccard, đo tỷ lệ giữa phần giao và phần hợp của vùng dự đoán với vùng ground-truth. Chỉ số này được xác định theo công thức sau [33]:

$$\text{IoU} = \frac{TP}{TP + FP + FN} \tag{2.18}$$

Giá trị IoU càng lớn thì mức độ chồng lấp giữa hai vùng càng cao, cho thấy mô hình có khả năng phân đoạn tốt hơn.

Hausdorff Distance 95 (HD95):

Hausdorff Distance 95 (HD95) được sử dụng để đánh giá sai số khoảng cách giữa biên của vùng dự đoán và vùng ground-truth. Khác với Hausdorff Distance truyền thống, HD95 sử dụng phân vị thứ 95 của khoảng cách biên nhằm giảm ảnh hưởng của các điểm ngoại lai, nhờ đó phản ánh chính xác hơn chất lượng phân đoạn của mô hình [33]. Giá trị HD95 càng nhỏ thì ranh giới phân đoạn càng gần với ground-truth và kết quả phân đoạn càng chính xác.

Chỉ số đánh giá phân loại

Accuracy:

Accuracy được sử dụng để đo tỷ lệ mẫu được phân loại đúng trên toàn bộ tập dữ liệu. Chỉ số này phản ánh mức độ chính xác tổng thể của mô hình và được tính theo công thức sau [33]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.19}$$

Trong đó, TP, TN, FP và FN lần lượt là số mẫu dự đoán đúng dương tính, dự đoán đúng âm tính, dự đoán sai dương tính và dự đoán sai âm tính.

Recall:

Recall (Sensitivity) đo khả năng phát hiện đúng các mẫu thuộc lớp dương. Chỉ số này được xác định theo công thức sau [33]:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2.20}$$

Recall càng cao cho thấy mô hình càng ít bỏ sót các mẫu thuộc lớp dương.

F1-score:

F1-score là trung bình điều hòa giữa Precision và Recall, giúp đánh giá hiệu quả

của mô hình trong trường hợp dữ liệu mất cân bằng. Công thức được xác định như sau [33]:

$$\mathrm{F1} = \frac{2 \times \mathrm{Precision} \times \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}} \tag{2.21}$$

Giá trị F1-score càng lớn thì mô hình càng đạt sự cân bằng tốt giữa Precision và Recall.

ROC-AUC:

Đường cong ROC (Receiver Operating Characteristic) biểu diễn mối quan hệ giữa tỷ lệ dương tính thật (True Positive Rate – TPR) và tỷ lệ dương tính giả (False Positive Rate – FPR) tại nhiều ngưỡng phân loại khác nhau. Diện tích dưới đường cong ROC (Area Under the Curve – AUC) được sử dụng để đánh giá khả năng phân biệt giữa các lớp của mô hình. Đối với bài toán phân loại đa lớp, ROC-AUC thường được tính theo chiến lược One-vs-Rest (OvR), trong đó mỗi lớp lần lượt được xem là lớp dương và các lớp còn lại được xem là lớp âm [33].

2.9 Phương pháp trích xuất đặc trưng lâm sàng

Sau khi thu được kết quả phân đoạn từ các mô hình học sâu, hệ thống thực hiện trích xuất các thông số hình thái học và chức năng tim mạch. Đây là bước chuyển đổi dữ liệu ảnh thành các đặc trưng định lượng có ý nghĩa y khoa, phục vụ cho bài toán phân loại bệnh lý.

2.9.1 Chuẩn hóa theo diện tích bề mặt cơ thể

Để so sánh thể tích tim giữa các bệnh nhân có thể trạng khác nhau, các chỉ số thể tích được chuẩn hóa theo diện tích bề mặt cơ thể (Body Surface Area – BSA). Trong nghiên cứu này, diện tích bề mặt cơ thể được tính theo công thức Mosteller [24]:

$$BSA = \sqrt{\frac{H \times W}{3600}} \tag{2.22}$$

Trong đó, H là chiều cao (cm) và W là cân nặng (kg).

Sau khi tính được diện tích bề mặt cơ thể, các chỉ số thể tích được chuẩn hóa theo công thức sau [28]:

$$Volume_{Index} = \frac{Volume}{BSA} \tag{2.23}$$

Trong đó, $Volume$ là thể tích của cấu trúc tim được đo từ kết quả phân đoạn và

$Volume_{Index}$ là thể tích đã được chuẩn hóa theo diện tích bề mặt cơ thể.

2.9.2 Các đặc trưng lâm sàng sử dụng trong phân loại

Sau khi hoàn thành quá trình phân đoạn, hệ thống tiến hành trích xuất các đặc trưng hình thái học và chức năng tim mạch từ kết quả phân đoạn nhằm phục vụ cho bài toán phân loại bệnh lý. Các đặc trưng này phản ánh tình trạng giải phẫu và chức năng của tim, đồng thời được xem là những chỉ số có ý nghĩa lâm sàng trong hỗ trợ chẩn đoán bệnh tim mạch [28, 22]. Tùy theo từng bộ dữ liệu, các đặc trưng được sử dụng có sự khác nhau nhằm đáp ứng mục tiêu lâm sàng tương ứng.

Đặc trưng trên bộ dữ liệu ACDC 2017

Dựa trên kết quả phân đoạn các cấu trúc tim gồm thất trái (LV), thất phải (RV) và cơ tim (MYO), hệ thống trích xuất bảy đặc trưng chính như sau:

1. **LV_EDVi:** Thể tích cuối tâm trương của thất trái đã được chuẩn hóa theo diện tích bề mặt cơ thể (BSA).

2. **RV_EDVi:** Thể tích cuối tâm trương của thất phải đã được chuẩn hóa theo diện tích bề mặt cơ thể.

3. **Myo_EDVi:** Thể tích cơ tim cuối tâm trương đã được chuẩn hóa theo diện tích bề mặt cơ thể.

4. **EF:** Phân suất tống máu của thất trái (Ejection Fraction), được xác định theo công thức sau [28]:

$$EF = \frac{EDV - ESV}{EDV} \times 100\% \tag{2.24}$$

5. **LV_RV_Ratio:** Tỷ lệ giữa thể tích thất trái và thể tích thất phải.

6. **Myo_LV_Ratio:** Tỷ lệ giữa thể tích cơ tim và thể tích thất trái.

7. **Max_Thickness:** Độ dày lớn nhất của cơ tim, được ước lượng thông qua phép biến đổi khoảng cách Euclidean trên mặt nạ cơ tim.

Các đặc trưng trên phản ánh nhiều khía cạnh quan trọng của hình thái và chức năng tim, bao gồm mức độ giãn buồng tim, khả năng co bóp của thất trái và tình trạng phì đại cơ tim. Đây là những chỉ số thường được sử dụng trong đánh giá lâm sàng và hỗ trợ phân loại các bệnh lý tim mạch trên bộ dữ liệu ACDC 2017 [2, 22].

Đặc trưng trên bộ dữ liệu EMIDEC 2020

Đối với bộ dữ liệu EMIDEC 2020, sau khi phân đoạn các lớp Cavity, Myocardium và Myocardial Infarction (MI), hệ thống tiến hành trích xuất năm đặc trưng hình thái học phục vụ cho bài toán phân loại nhị phân giữa bệnh nhân bình thường và bệnh nhân mắc nhồi máu cơ tim. Các đặc trưng này được xây dựng dựa trên kết quả phân đoạn nhằm phản ánh mức độ tổn thương cơ tim và hỗ trợ quá trình chẩn đoán [16, 10].

1. **Cavity_Vol:** Thể tích buồng tim được tính từ vùng Cavity.
2. **Myo_Vol:** Thể tích cơ tim được tính từ vùng Myocardium.
3. **MI_Vol:** Thể tích vùng nhồi máu cơ tim được tính từ lớp Myocardial Infarction (MI).
4. **MI_Ratio:** Tỷ lệ thể tích vùng nhồi máu trên tổng thể tích cơ tim, được xác định theo công thức sau [16, 10]:

$$MI_{Ratio} = \frac{MI_{Vol}}{Myo_{Vol}} \tag{2.25}$$

5. **Max_MI_Thickness:** Độ dày lớn nhất của vùng nhồi máu cơ tim, được ước lượng thông qua phép biến đổi khoảng cách Euclidean trên mặt nạ MI.

Các đặc trưng trên phản ánh kích thước, mức độ lan rộng và tỷ lệ tổn thương của vùng nhồi máu cơ tim trên ảnh LGE-MRI. Đây là những chỉ số định lượng quan trọng, giúp các mô hình học máy phân biệt giữa bệnh nhân bình thường và bệnh nhân mắc nhồi máu cơ tim, đồng thời hỗ trợ đánh giá mức độ tổn thương cơ tim trong thực hành lâm sàng [16, 10].

2.10 Trí tuệ nhân tạo giải thích

Trí tuệ nhân tạo giải thích (Explainable Artificial Intelligence - XAI) là tập hợp các phương pháp giúp làm rõ cơ sở ra quyết định của mô hình AI. Trong y tế, XAI có vai trò đặc biệt quan trọng vì kết quả dự đoán cần có khả năng giải thích để hỗ trợ bác sĩ đánh giá mức độ tin cậy của hệ thống.

Trong đề tài này, XAI được triển khai theo hai hướng. Thứ nhất, Grad-CAM và MC Dropout được sử dụng để giải thích các mô hình phân đoạn ảnh. Thứ hai, SHAP được sử dụng để giải thích mô hình phân loại dựa trên đặc trưng lâm sàng.

2.10.1 Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping) là kỹ thuật trực quan hóa vùng ảnh có ảnh hưởng lớn đến quyết định của mô hình [31]. Phương pháp này sử dụng gradient của lớp mục tiêu đối với bản đồ đặc trưng của lớp tích chập cuối để xác định các vùng quan trọng.

Trọng số của kênh đặc trưng k đối với lớp c được tính như sau [31]:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \tag{2.26}$$

Bản đồ Grad-CAM được xác định bởi [31]:

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right) \tag{2.27}$$

Trong bài toán phân đoạn MRI tim mạch, Grad-CAM giúp quan sát mô hình đang tập trung vào vùng nào khi dự đoán cấu trúc tim hoặc vùng nhồi máu. Đối với EMIDEC, bản đồ Grad-CAM được sử dụng để kiểm tra liệu mô hình có chú ý đúng vào vùng cơ tim và vùng tổn thương hay không.

2.10.2 Monte Carlo Dropout

Monte Carlo Dropout (MC Dropout) là phương pháp ước lượng độ bất định của mô hình bằng cách duy trì Dropout trong giai đoạn suy luận [9]. Thay vì chỉ dự đoán một lần, mô hình được chạy nhiều lần trên cùng một đầu vào, từ đó thu được phân phối xác suất dự đoán.

Độ bất định tại mỗi voxel có thể được tính bằng Shannon Entropy [9]:

$$H = -\sum_{c=1}^{C} p_c \log(p_c) \tag{2.28}$$

Trong đó p_c là xác suất trung bình của lớp c sau nhiều lần suy luận. Vùng có entropy cao là vùng mô hình còn phân vân, thường xuất hiện tại ranh giới mờ hoặc vùng tổn thương khó phân biệt. Trong đề tài này, MC Dropout được sử dụng để tạo bản đồ độ bất định cho kết quả phân đoạn vùng nhồi máu cơ tim.

2.10.3 SHAP

SHAP (SHapley Additive exPlanations) là phương pháp giải thích mô hình dựa trên lý thuyết giá trị Shapley trong lý thuyết trò chơi [20]. Phương pháp này định lượng mức độ đóng góp của từng đặc trưng đầu vào vào kết quả dự đoán cuối cùng.

Giá trị Shapley của đặc trưng i được tính như sau [20]:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \left[f(S \cup \{i\}) - f(S) \right] \tag{2.29}$$

Trong bài toán phân loại bệnh lý tim mạch, SHAP được sử dụng để giải thích ảnh hưởng của các đặc trưng như EF, LV_EDVi, RV_EDVi, Myo_LV_Ratio và Max_Thickness đến quyết định của mô hình. Nhờ đó, hệ thống không chỉ đưa ra nhãn bệnh mà còn cho biết yếu tố lâm sàng nào đóng vai trò quan trọng nhất trong quá trình chẩn đoán.

Sự kết hợp giữa Grad-CAM, MC Dropout và SHAP giúp hệ thống đạt được tính minh bạch ở cả hai cấp độ: cấp độ hình ảnh và cấp độ đặc trưng lâm sàng.

Chương 3. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày quy trình xây dựng và triển khai hệ thống hỗ trợ chẩn đoán bệnh tim mạch từ ảnh cộng hưởng từ tim (Cardiac MRI). Trên cơ sở các phương pháp và mô hình đã được trình bày ở Chương 2, nghiên cứu tiến hành xây dựng quy trình thực nghiệm, tiền xử lý dữ liệu, phân đoạn ảnh MRI tim mạch, phân loại bệnh lý tim mạch và phát hiện vùng nhồi máu cơ tim. Bên cạnh đó, các kỹ thuật Explainable AI cũng được tích hợp nhằm hỗ trợ giải thích kết quả dự đoán và đánh giá độ tin cậy của mô hình.

3.1 Thiết lập thực nghiệm

3.1.1 Thiết lập môi trường phần cứng và phần mềm

Toàn bộ quá trình huấn luyện và đánh giá mô hình được thực hiện trên nền tảng Kaggle Notebook. Môi trường này cung cấp tài nguyên tính toán phù hợp cho các bài toán xử lý ảnh y tế 3D và cho phép triển khai đồng bộ toàn bộ quy trình nghiên cứu.

Bảng 3.1 trình bày cấu hình phần cứng và phần mềm được sử dụng trong nghiên cứu.

Bảng 3.1: Cấu hình phần cứng và phần mềm

Thành phần	**Cấu hình**
Nền tảng	Kaggle Notebook
GPU	NVIDIA Tesla T4 (16GB VRAM)
Ngôn ngữ lập trình	Python
Framework học sâu	PyTorch, MONAI
Machine Learning	Scikit-learn
Xử lý dữ liệu	NumPy, Pandas
Đọc dữ liệu MRI	NiBabel
Trực quan hóa dữ liệu	Matplotlib, Seaborn
Xử lý ảnh	OpenCV

Trong đó, PyTorch được sử dụng để xây dựng và huấn luyện các mô hình học sâu, MONAI hỗ trợ các phép tiền xử lý và các kiến trúc chuyên dụng cho ảnh y tế, Scikit-learn được sử dụng cho các mô hình học máy và chỉ số đánh giá, trong khi

NiBabel hỗ trợ đọc dữ liệu ảnh định dạng NIfTI.

3.1.2 Chiến lược phân chia dữ liệu

Để tránh hiện tượng rò rỉ dữ liệu (Data Leakage), việc phân chia dữ liệu được thực hiện theo từng bệnh nhân. Toàn bộ ảnh của cùng một bệnh nhân luôn được giữ trong cùng một tập dữ liệu, không tách riêng theo từng lát cắt hoặc từng pha tim.

- **Đối với ACDC 2017:** Dữ liệu được chia theo tỷ lệ 80 bệnh nhân cho huấn luyện, 20 bệnh nhân cho xác thực và 50 bệnh nhân cho kiểm thử theo chiến lược phân tầng nhằm đảm bảo tỷ lệ các nhóm bệnh được giữ tương đối đồng đều giữa các tập dữ liệu.
- **Đối với EMIDEC 2020:** Dữ liệu được chia theo tỷ lệ 70 bệnh nhân cho huấn luyện, 15 bệnh nhân cho xác thực và 15 bệnh nhân cho kiểm thử.
- **Đối với các mô hình phân loại:** Dữ liệu đặc trưng được trích xuất từ kết quả phân đoạn được sử dụng trong quá trình 5-Fold Stratified Cross-Validation nhằm đánh giá hiệu quả của các mô hình Random Forest, SVM, MLP và Ensemble Voting. Chiến lược này được áp dụng cho cả bài toán phân loại bệnh lý tim mạch trên bộ dữ liệu ACDC 2017 và bài toán phân loại nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020.

3.1.3 Thiết lập siêu tham số

Các siêu tham số chính được lựa chọn dựa trên nhiều lần thử nghiệm nhằm đảm bảo mô hình hội tụ ổn định và phù hợp với giới hạn bộ nhớ GPU. Bảng 3.2 trình bày các giá trị được sử dụng trong quá trình huấn luyện.

Bảng 3.2: Các siêu tham số chính được sử dụng trong thực nghiệm

Siêu tham số	**Giá trị sử dụng**
Batch Size	2 đối với tập huấn luyện, 1 đối với tập xác thực và kiểm thử
Số Epoch	100 epoch
Optimizer	AdamW với Weight Decay = 1×10^{-4}
Learning Rate	1×10^{-4} đối với ACDC, 8×10^{-4} đối với EMIDEC
Learning Rate Scheduler	Cosine Annealing đối với EMIDEC
Kích thước đầu vào	$128 \times 128 \times 16$ đối với ACDC; $112 \times 112 \times 32$ đối với EMIDEC
Dropout Rate	0.2 đối với các mô hình có sử dụng Dropout

Do dữ liệu MRI 3D có kích thước lớn nên Batch Size được giữ ở mức nhỏ nhằm tránh vượt quá giới hạn bộ nhớ GPU. Bộ điều chỉnh tốc độ học Cosine Annealing giúp tốc độ học giảm dần theo quá trình huấn luyện, từ đó hỗ trợ mô hình hội tụ ổn định hơn.

3.1.4 Hàm mất mát và chỉ số đánh giá

Hàm mất mát

Trong nghiên cứu này, DiceCELoss được sử dụng cho bài toán phân đoạn cấu trúc tim trên bộ dữ liệu ACDC 2017, trong khi DiceFocalLoss được sử dụng cho bài toán phân đoạn vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020 nhằm xử lý hiện tượng mất cân bằng lớp.

DiceCELoss kết hợp giữa Dice Loss và Cross-Entropy Loss nhằm cải thiện đồng thời khả năng phân loại voxel và độ chồng lấp không gian giữa vùng dự đoán và ground-truth.

Đối với bài toán phát hiện và phân đoạn vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020, nghiên cứu sử dụng DiceFocalLoss nhằm tăng khả năng học đối với các vùng tổn thương nhỏ và dữ liệu mất cân bằng. Tham số $\gamma = 2.0$ được sử dụng trong Focal Loss và trọng số lớp được thiết lập nhằm tăng mức độ chú ý đối với vùng nhồi máu cơ tim.

Chỉ số đánh giá

Hiệu quả của các mô hình phân đoạn được đánh giá thông qua các chỉ số:

- Dice Similarity Coefficient (DSC)
- Intersection over Union (IoU)
- Hausdorff Distance 95 (HD95)

Đối với bài toán phân loại bệnh lý tim mạch, nghiên cứu sử dụng các chỉ số:

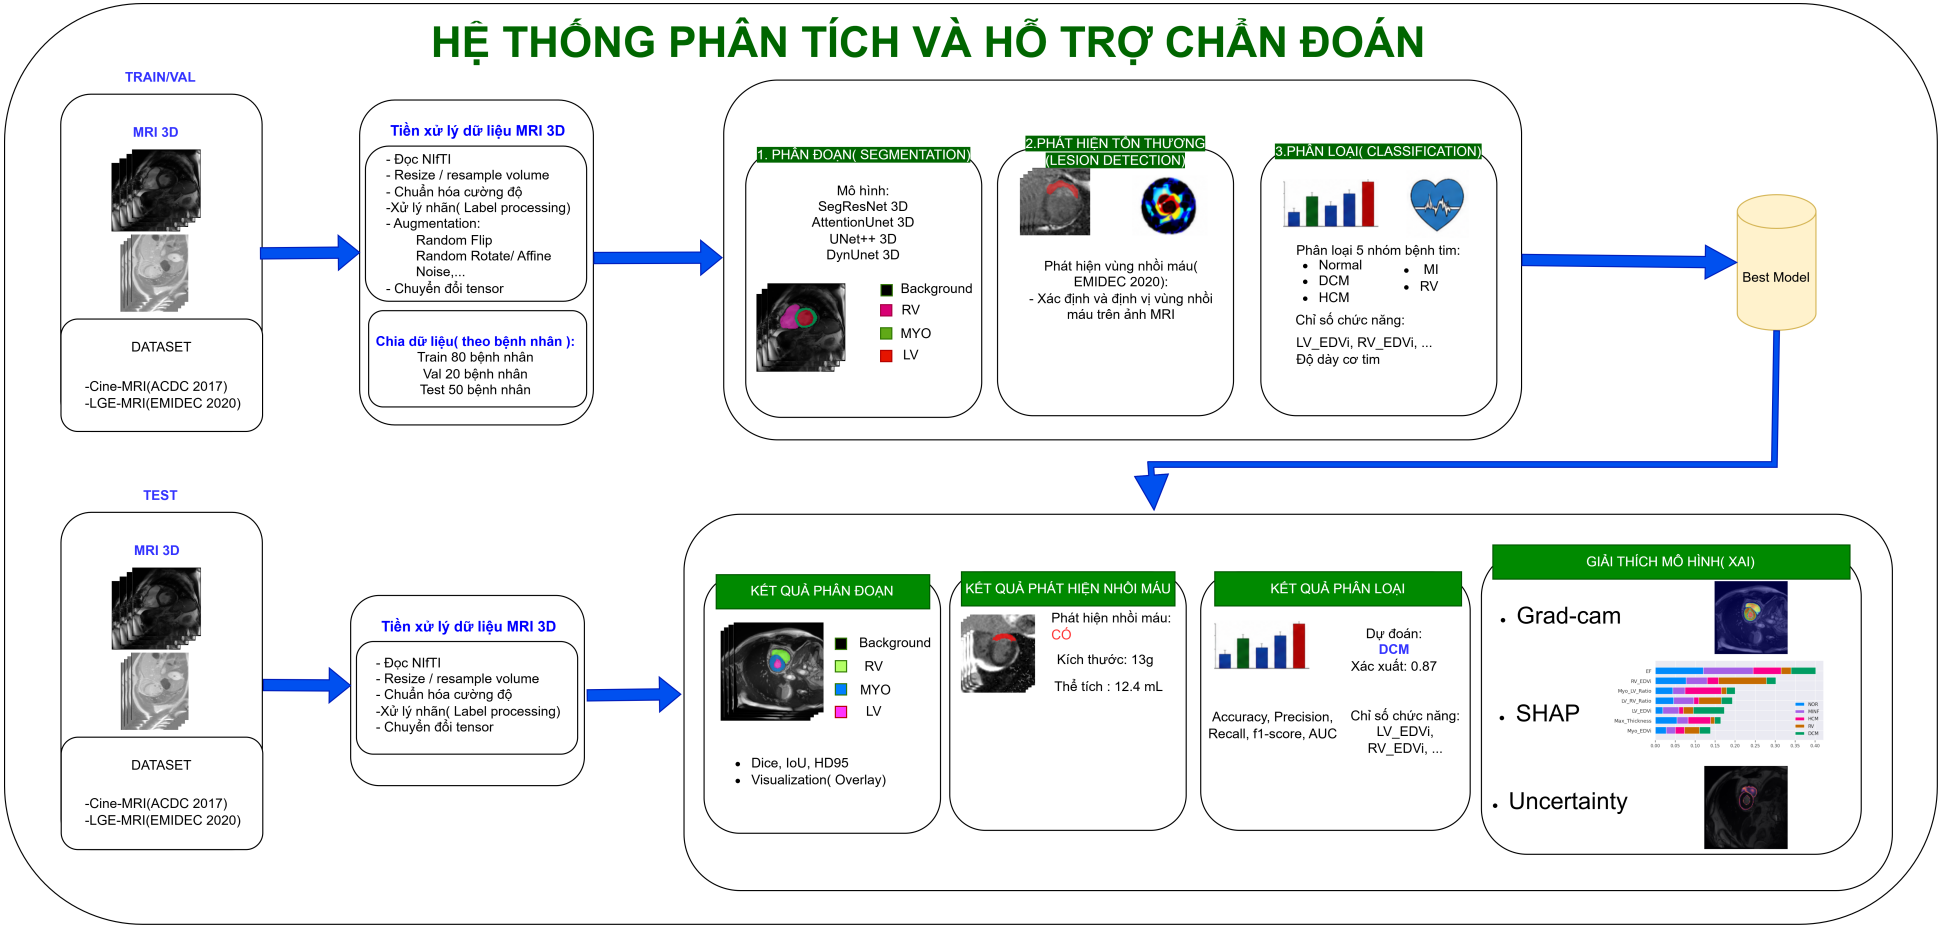
- Accuracy
- Recall
- F1-score
- ROC-AUC

Trong bài toán hỗ trợ chẩn đoán bệnh, Recall được đặc biệt quan tâm vì phản ánh khả năng phát hiện đúng các trường hợp bệnh, từ đó góp phần giảm nguy cơ bỏ sót bệnh nhân.

Các chỉ số trên được sử dụng nhằm đánh giá toàn diện hiệu quả của hệ thống ở cả hai bài toán phân đoạn ảnh MRI tim mạch và phân loại bệnh lý tim mạch, đồng thời phản ánh khả năng tổng quát hóa của mô hình trên các bộ dữ liệu thử nghiệm.

3.2 Sơ đồ tổng quát hệ thống

Nghiên cứu đề xuất một hệ thống hỗ trợ chẩn đoán bệnh tim mạch từ ảnh cộng hưởng từ tim (Cardiac MRI) 3D có khả năng giải thích. Hệ thống tích hợp các nhiệm vụ phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch và phát hiện vùng nhồi máu cơ tim. Hệ thống bao gồm hai nhánh xử lý chính tương ứng với hai bộ dữ liệu ACDC 2017 và EMIDEC 2020. Nhánh ACDC tập trung vào phân đoạn cấu trúc tim và phân loại bệnh lý tim mạch dựa trên các đặc trưng hình thái học và chức năng tim. Nhánh EMIDEC tập trung vào phân đoạn vùng nhồi máu cơ tim, phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim, đồng thời hỗ trợ phát hiện và định lượng vùng tổn thương trên ảnh LGE-MRI.



Hình 3.1: Sơ đồ tổng quát hệ thống hỗ trợ chẩn đoán bệnh tim mạch

Kiến trúc hệ thống bao gồm sáu thành phần chính:

1. **Tiền xử lý dữ liệu (Preprocessing):**

   Dữ liệu MRI được chuẩn hóa cường độ, chuẩn hóa kích thước không gian và áp dụng các kỹ thuật tăng cường dữ liệu nhằm cải thiện khả năng tổng quát hóa của mô hình trong quá trình huấn luyện.

2. **Phân đoạn ảnh MRI tim mạch (Segmentation):**

   Các mô hình học sâu gồm Attention U-Net, U-Net++, SegResNet và DynUNet được sử dụng để phân đoạn các cấu trúc tim hoặc vùng tổn thương trên ảnh MRI. Các mô hình này được sử dụng để đánh giá và so sánh hiệu suất, từ đó lựa chọn mô hình phù hợp cho từng bài toán. Đối với bộ dữ liệu EMIDEC, thông tin giải phẫu tim được sử dụng như một mặt nạ prior giải phẫu nhằm hỗ trợ quá trình nhận diện vùng nhồi máu cơ tim.

3. **Trích xuất đặc trưng lâm sàng (Clinical Feature Extraction):**

   Từ kết quả phân đoạn, hệ thống tiến hành trích xuất các đặc trưng hình thái học và chức năng tim phục vụ cho các bài toán phân loại. Đối với bộ dữ liệu ACDC 2017, các đặc trưng như LV_EDVi, RV_EDVi, Myo_EDVi, EF, LV_RV_Ratio, Myo_LV_Ratio và Max_Thickness được sử dụng để phân loại bệnh lý tim mạch. Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng gồm Cavity_Vol, Myo_Vol, MI_Vol, MI_Ratio và Max_MI_Thickness được sử dụng để phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.

4. **Phân loại bệnh lý (Classification):**

   Các đặc trưng trích xuất từ kết quả phân đoạn được đưa vào các mô hình học máy như Random Forest, Support Vector Machine (SVM) và Multi-Layer Perceptron (MLP). Kết quả dự đoán cuối cùng được tổng hợp thông qua cơ chế Ensemble Voting. Trên bộ dữ liệu ACDC 2017, hệ thống thực hiện phân loại đa lớp các bệnh lý tim mạch, trong khi trên bộ dữ liệu EMIDEC 2020, hệ thống thực hiện phân loại nhị phân giữa bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.

5. **Phát hiện vùng nhồi máu cơ tim (Myocardial Infarction Detection):**

   Đối với bộ dữ liệu EMIDEC, kết quả phân đoạn được sử dụng để xác định vị trí, phạm vi và thể tích vùng nhồi máu cơ tim. Các kết quả này hỗ trợ đánh giá mức độ tổn thương và cung cấp thông tin định lượng phục vụ chẩn đoán lâm sàng.

6. **Giải thích mô hình (Explainable AI – XAI):**

   Các kỹ thuật Explainable AI được tích hợp nhằm tăng khả năng giải thích và độ tin cậy của hệ thống. Grad-CAM được sử dụng để trực quan hóa vùng ảnh quan trọng đối với mô hình, SHAP được áp dụng để đánh giá mức độ ảnh hưởng của các đặc trưng lâm sàng trong bài toán phân loại, trong khi Monte Carlo Dropout được sử dụng để ước lượng độ bất định của kết quả phân đoạn.

Kiến trúc trên cho phép kết hợp hiệu quả các phương pháp học sâu, học máy và Explainable AI trong cùng một hệ thống hỗ trợ chẩn đoán. Các bước tiền xử lý, huấn luyện mô hình và triển khai chi tiết sẽ được trình bày trong các mục tiếp theo.

3.2.1 Thu thập và phân tích dữ liệu

Nghiên cứu sử dụng hai bộ dữ liệu công khai là ACDC 2017 và EMIDEC 2020. Đây đều là các bộ dữ liệu chuẩn trong lĩnh vực phân tích ảnh cộng hưởng từ tim mạch và đã được các chuyên gia tim mạch gán nhãn thủ công.

Hai bộ dữ liệu được sử dụng cho các nhiệm vụ khác nhau. Bộ dữ liệu ACDC 2017 phục vụ bài toán phân đoạn cấu trúc tim và phân loại bệnh lý tim mạch, trong khi bộ dữ liệu EMIDEC 2020 được sử dụng cho bài toán phát hiện, phân đoạn vùng nhồi máu cơ tim và phân loại bệnh nhân bình thường, bệnh nhân có nhồi máu cơ tim trên ảnh MRI tăng cường trễ.

Dữ liệu ACDC 2017

Tập dữ liệu Automated Cardiac Diagnosis Challenge (ACDC) 2017 gồm 150 bệnh nhân [2], được chia thành năm nhóm bệnh lý tim mạch:

- NOR (Normal): Tim bình thường.
- DCM (Dilated Cardiomyopathy): Bệnh cơ tim giãn.
- HCM (Hypertrophic Cardiomyopathy): Bệnh cơ tim phì đại.
- MINF (Myocardial Infarction): Nhồi máu cơ tim.
- RV (Abnormal Right Ventricle): Bất thường thất phải.

Mỗi bệnh nhân được cung cấp ảnh MRI tim ở hai thời điểm:

- End-Diastole (ED): Cuối tâm trương.
- End-Systole (ES): Cuối tâm thu.

Ngoài ảnh MRI gốc, bộ dữ liệu còn cung cấp nhãn phân đoạn thủ công cho ba cấu trúc chính gồm:

- Left Ventricle (LV): Thất trái.
- Right Ventricle (RV): Thất phải.
- Myocardium (MYO): Cơ tim.

Bộ dữ liệu này được sử dụng để xây dựng và đánh giá các mô hình phân đoạn cấu trúc tim. Kết quả phân đoạn sau đó được sử dụng để trích xuất các đặc trưng lâm sàng phục vụ cho bài toán phân loại bệnh lý tim mạch.

Dữ liệu EMIDEC 2020

Bộ dữ liệu Evaluation of Myocardial Infarction from Delayed-Enhancement Cardiac MRI (EMIDEC) 2020 [16] được xây dựng cho bài toán phát hiện và phân đoạn vùng nhồi máu cơ tim trên ảnh MRI tăng cường trễ (Late Gadolinium Enhancement – LGE).

Dữ liệu bao gồm ảnh MRI 3D cùng các nhãn phân đoạn cho:

- Buồng tim (Cavity).
- Cơ tim (Myocardium).
- Vùng nhồi máu cơ tim (Myocardial Infarction – MI).

Bộ dữ liệu này được sử dụng để xây dựng và đánh giá các mô hình phân đoạn vùng nhồi máu cơ tim, phát hiện tổn thương nhồi máu cơ tim và phân loại bệnh nhân bình thường (Normal) và bệnh nhân có nhồi máu cơ tim (Infarcted) trên ảnh LGE-MRI.

Việc sử dụng đồng thời hai bộ dữ liệu ACDC 2017 và EMIDEC 2020 giúp hệ thống được đánh giá trên nhiều nhiệm vụ khác nhau, bao gồm phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch, phát hiện và định lượng vùng nhồi máu cơ tim, cũng như phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim trên ảnh MRI tim mạch.

3.2.2 Tiền xử lý và tăng cường dữ liệu

Dữ liệu cộng hưởng từ tim (Cardiac MRI) thường có sự khác biệt về độ phân giải không gian, kích thước ảnh và cường độ tín hiệu giữa các bệnh nhân. Những khác biệt này có thể xuất phát từ thiết bị chụp, giao thức thu nhận ảnh hoặc đặc điểm giải phẫu

của từng trường hợp. Do đó, bước tiền xử lý dữ liệu đóng vai trò quan trọng nhằm chuẩn hóa đầu vào và giúp các mô hình học sâu huấn luyện ổn định hơn.

Trong nghiên cứu này, quy trình tiền xử lý được xây dựng dựa trên thư viện MONAI [5] và bao gồm các bước chính sau:

Chuẩn hóa không gian

Các ảnh MRI được chuẩn hóa về cùng độ phân giải không gian $1.5 \times 1.5 \times 5.0$ mm nhằm giảm sự khác biệt giữa các bệnh nhân. Đối với ảnh cường độ, phương pháp nội suy tuyến tính được sử dụng để đảm bảo tính liên tục của tín hiệu ảnh. Đối với ảnh nhãn, phương pháp nội suy điểm gần nhất được áp dụng nhằm bảo toàn giá trị rời rạc của các lớp phân đoạn.

Chuẩn hóa cường độ ảnh

Dải cường độ tín hiệu được cắt trong khoảng phân vị từ 1% đến 99% nhằm giảm ảnh hưởng của các giá trị nhiễu bất thường. Sau đó, dữ liệu được đưa về khoảng giá trị $[0, 1]$ và tiếp tục chuẩn hóa theo Z-score trên các vùng khác không để hỗ trợ quá trình hội tụ của mô hình trong quá trình huấn luyện.

Cắt vùng quan tâm và chuẩn hóa kích thước

Ảnh MRI và nhãn phân đoạn được đệm hoặc cắt để đưa về kích thước không gian thống nhất.

Đối với bộ dữ liệu EMIDEC 2020, nghiên cứu sử dụng mặt nạ prior giải phẫu để xác định vùng tim trước khi thực hiện cắt vùng quan tâm bằng phép biến đổi CropForegroundd. Sau bước cắt ROI, dữ liệu tiếp tục được chuẩn hóa về kích thước $112 \times 112 \times 32$ voxel trước khi đưa vào các mô hình học sâu.

Cách tiếp cận này giúp mô hình tập trung tốt hơn vào vùng giải phẫu quan trọng, đồng thời giảm ảnh hưởng của các vùng nền không liên quan.

Tăng cường dữ liệu 3D

Do dữ liệu ảnh y tế thường có số lượng hạn chế, các kỹ thuật tăng cường dữ liệu được áp dụng trong quá trình huấn luyện nhằm giảm hiện tượng quá khớp và cải thiện khả năng tổng quát hóa của mô hình.

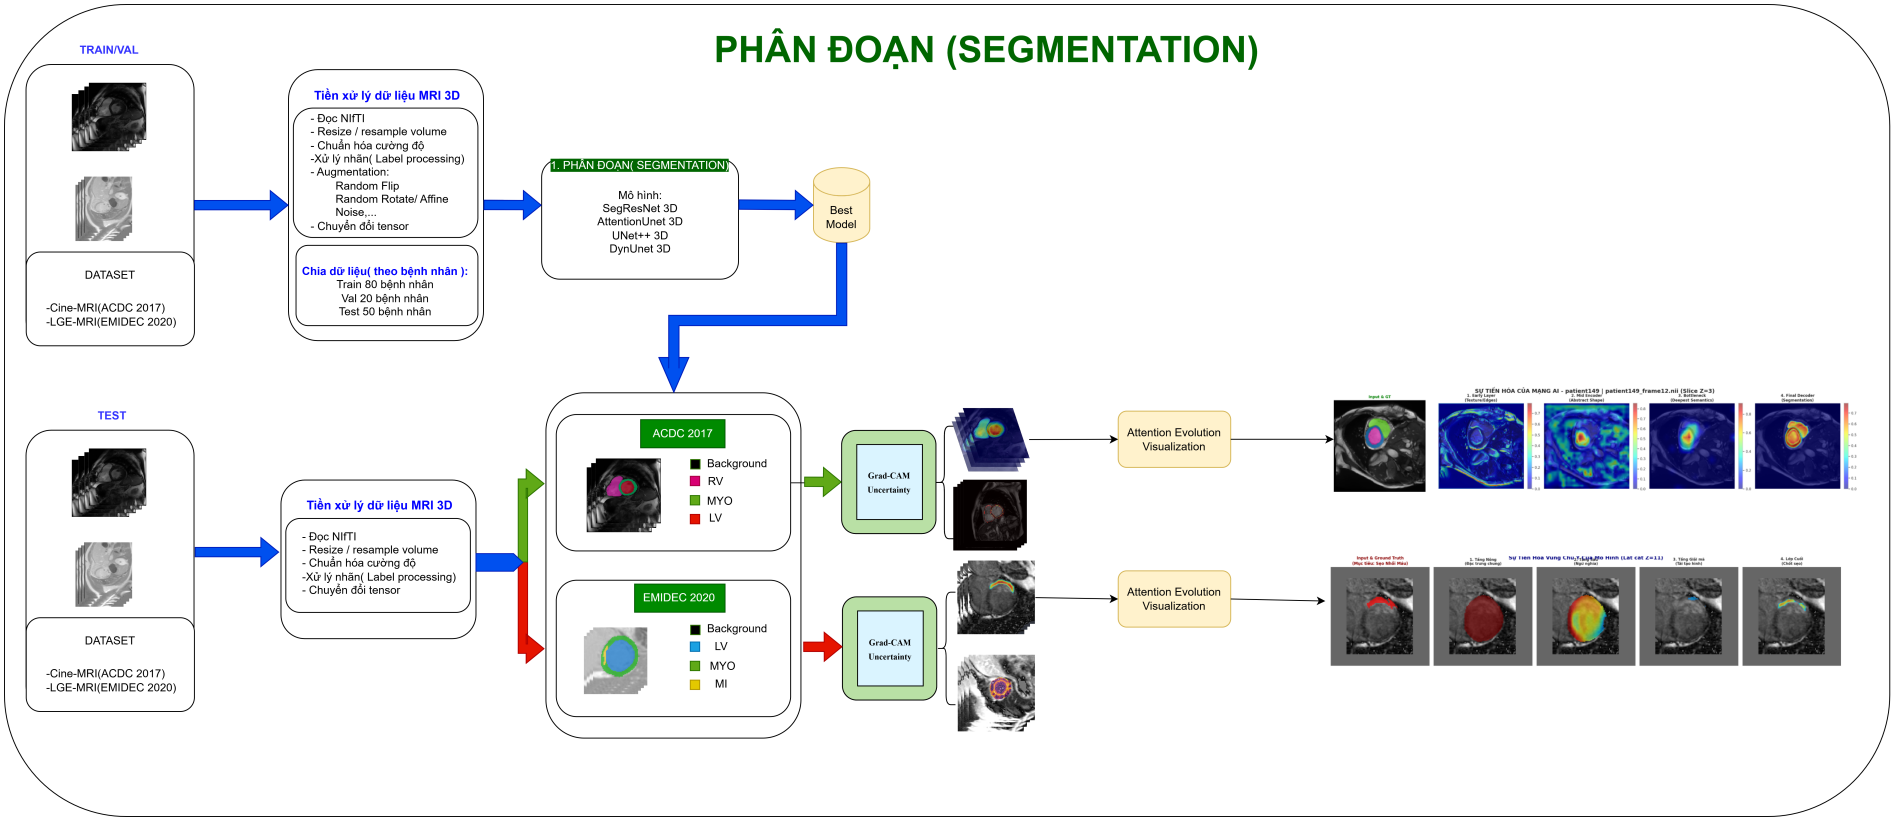
- **Random Flip:** Áp dụng phép lật ảnh theo các trục không gian với xác suất $p = 0.5$.

- **Random Affine:** Áp dụng các phép xoay, co giãn và biến đổi affine ngẫu nhiên nhằm mô phỏng sự thay đổi vị trí của bệnh nhân trong quá trình chụp MRI.

Quy trình tiền xử lý và tăng cường dữ liệu giúp chuẩn hóa dữ liệu đầu vào, giảm sự khác biệt giữa các bệnh nhân và hỗ trợ các mô hình học sâu khai thác hiệu quả đặc trưng không gian trong ảnh MRI tim mạch.

3.2.3 Phân đoạn ảnh MRI tim mạch

Trong nghiên cứu này, các mô hình học sâu 3D được huấn luyện để thực hiện bài toán phân đoạn cấu trúc tim trên bộ dữ liệu ACDC 2017 và phân đoạn vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020.



Hình 3.2: Quy trình phân đoạn ảnh MRI tim mạch

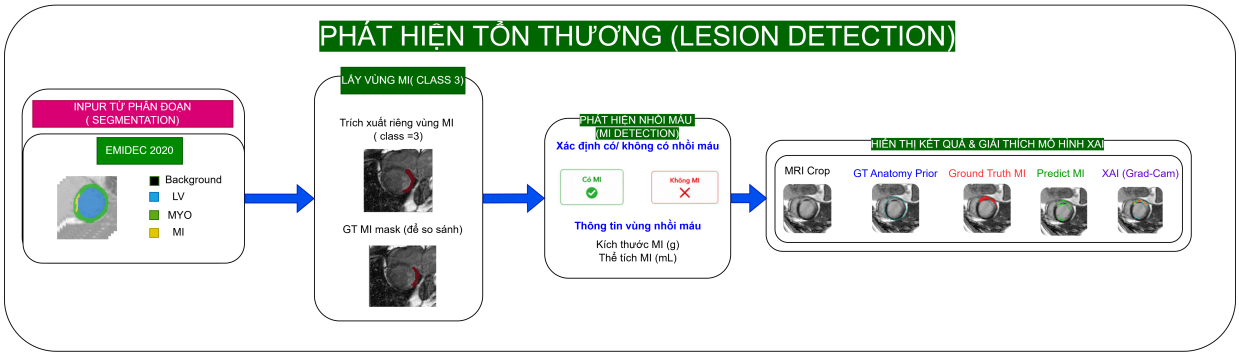
Đối với bộ dữ liệu ACDC 2017, các mô hình được huấn luyện để phân đoạn ba cấu trúc chính gồm thất trái (LV), thất phải (RV) và cơ tim (MYO). Bốn kiến trúc được khảo sát bao gồm 3D U-Net++, 3D Attention U-Net, 3D SegResNet và 3D DynUNet. Các mô hình được huấn luyện và đánh giá nhằm so sánh khả năng phân đoạn các cấu trúc tim trên bộ dữ liệu ACDC 2017. Kết quả phân đoạn sau đó được sử dụng để tính toán các đặc trưng hình thái học và chức năng tim phục vụ cho bài toán phân loại bệnh lý tim mạch.

Đối với bộ dữ liệu EMIDEC 2020, nghiên cứu thực hiện phân đoạn đa lớp trên ảnh LGE-MRI nhằm xác định buồng tim, cơ tim và vùng nhồi máu cơ tim. Bốn kiến trúc được khảo sát bao gồm 3D U-Net++, 3D Attention U-Net, 3D SegResNet và 3D DynUNet. Các mô hình này được sử dụng để đánh giá và so sánh khả năng phát hiện, phân đoạn và định lượng vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020. Kết quả phân đoạn sau đó được sử dụng để trích xuất các đặc trưng hình thái học như Cavity_Vol, Myo_Vol, MI_Vol, MI_Ratio và Max_MI_Thickness phục vụ cho bài toán phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim. Kết quả so sánh chi tiết giữa các mô hình sẽ được trình bày trong Chương 4.

Trong quá trình huấn luyện, hệ thống sử dụng thêm mặt nạ prior giải phẫu và ghép với ảnh MRI thành đầu vào hai kênh nhằm hỗ trợ mô hình tập trung tốt hơn vào vùng tim và giảm ảnh hưởng của các vùng nền không liên quan.

3.2.4 Phát hiện và phân tích vùng nhồi máu cơ tim

Sau khi mô hình hoàn thành phân đoạn đa lớp trên bộ dữ liệu EMIDEC 2020, hệ thống tiến hành trích xuất riêng vùng nhồi máu cơ tim (MI) từ kết quả dự đoán. Các thông tin định lượng thu được từ mặt nạ phân đoạn đồng thời được sử dụng cho bài toán phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.



Hình 3.3: Quy trình phân tích và phát hiện vùng tổn thương nhồi máu cơ tim

Trong nghiên cứu này, vùng nhồi máu cơ tim được xác định từ lớp MI trong kết quả phân đoạn đa lớp. Sau đó, hệ thống thực hiện phân tích nhằm xác định sự hiện

diện của tổn thương nhồi máu cơ tim (MI Detection) và tính toán thể tích vùng tổn thương dựa trên số voxel được dự đoán cùng thông tin độ phân giải không gian của ảnh MRI.

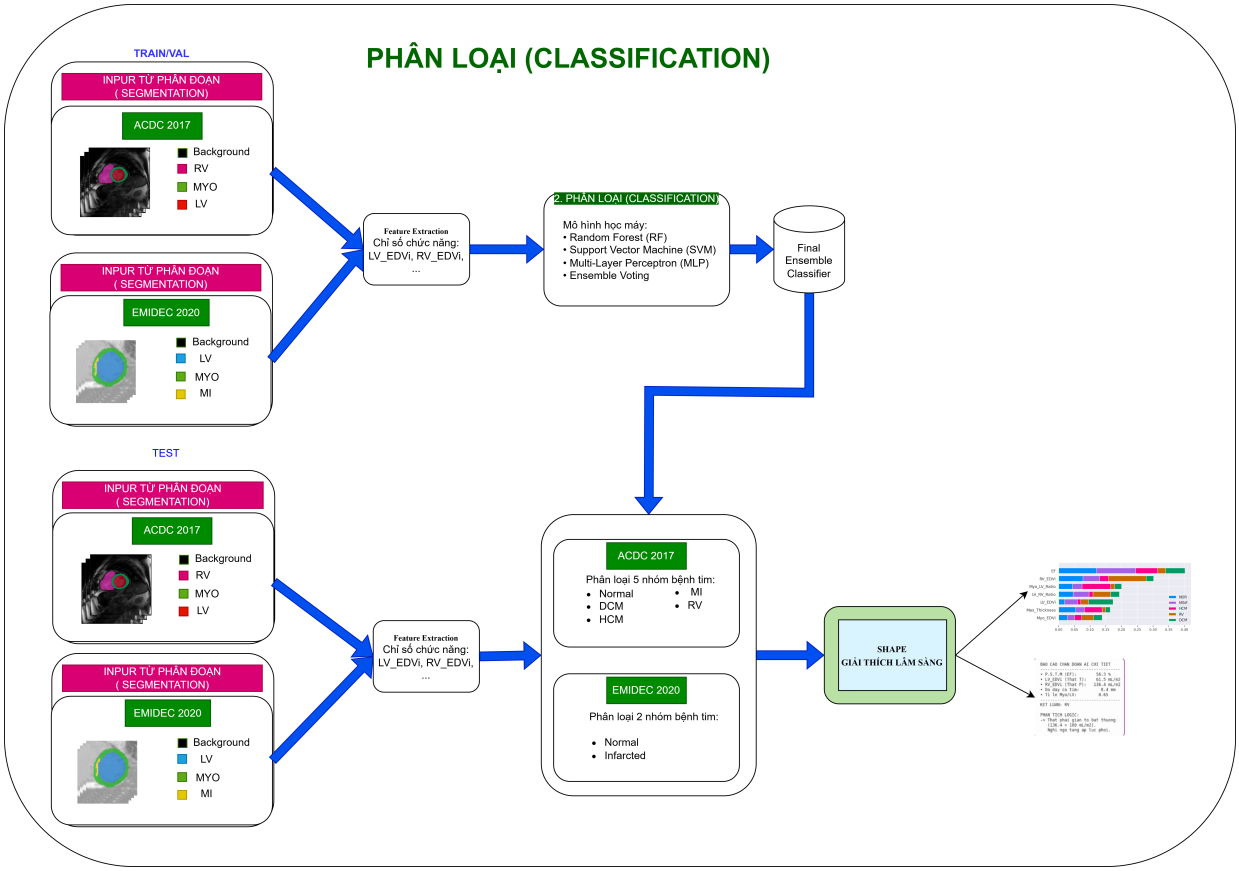
Kết quả được biểu diễn dưới dạng phát hiện có/không có nhồi máu cơ tim (MI Yes/No), cung cấp giá trị thể tích vùng tổn thương (mL) phục vụ cho quá trình đánh giá định lượng và hỗ trợ trích xuất đặc trưng cho bài toán phân loại bệnh nhân.

Kết quả dự đoán được đối chiếu với ground-truth nhằm đánh giá khả năng phát hiện và phân đoạn vùng nhồi máu cơ tim của mô hình.

Thông qua cách tiếp cận này, hệ thống không chỉ xác định vị trí vùng nhồi máu cơ tim mà còn cung cấp các thông tin định lượng phục vụ cho quá trình đánh giá tổn thương trên ảnh MRI.

3.2.5 Trích xuất đặc trưng và phân loại bệnh lý

Sau khi hoàn thành quá trình phân đoạn, hệ thống tiến hành trích xuất các đặc trưng hình thái học và chức năng từ mặt nạ phân đoạn để phục vụ cho bài toán phân loại.



Hình 3.4: Quy trình trích xuất đặc trưng và phân loại bệnh lý

Đối với bộ dữ liệu ACDC 2017, các đặc trưng được tính toán từ kết quả phân

đoạn thất trái (LV), thất phải (RV) và cơ tim (MYO), bao gồm:

- Thể tích thất trái cuối tâm trương chuẩn hóa (LV_EDVi)
- Thể tích thất phải cuối tâm trương chuẩn hóa (RV_EDVi)
- Thể tích cơ tim chuẩn hóa (Myo_EDVi)
- Phân suất tống máu thất trái (EF)
- Tỷ lệ thể tích thất trái trên thất phải (LV_RV_Ratio)
- Tỷ lệ thể tích cơ tim trên thất trái (Myo_LV_Ratio)
- Độ dày cơ tim lớn nhất (Max_Thickness)

Các đặc trưng này phản ánh đồng thời đặc điểm hình thái học và chức năng tim mạch của bệnh nhân, hỗ trợ nhận diện các nhóm bệnh lý tim mạch khác nhau.

Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng được trích xuất từ kết quả phân đoạn buồng tim, cơ tim và vùng nhồi máu cơ tim, bao gồm:

- Thể tích buồng tim (Cavity_Vol)
- Thể tích cơ tim (Myo_Vol)
- Thể tích vùng nhồi máu cơ tim (MI_Vol)
- Tỷ lệ thể tích nhồi máu trên thể tích cơ tim (MI_Ratio)
- Độ dày tối đa của vùng nhồi máu cơ tim (Max_MI_Thickness)

Các đặc trưng này phản ánh mức độ tổn thương cơ tim và được sử dụng để phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.

Sau bước tiền xử lý và chuẩn hóa đặc trưng, dữ liệu được đưa vào các mô hình học máy gồm:

- Random Forest (RF)
- Support Vector Machine (SVM)
- Multi-Layer Perceptron (MLP)

Nghiên cứu sử dụng phương pháp Ensemble Voting, trong đó cơ chế Soft Voting được áp dụng để kết hợp xác suất dự đoán từ các mô hình Random Forest, SVM và MLP nhằm tăng độ ổn định và cải thiện hiệu quả phân loại tổng thể [7].

Đối với bộ dữ liệu ACDC 2017, kết quả phân loại cuối cùng được sử dụng để nhận diện năm nhóm bệnh lý tim mạch gồm NOR, DCM, HCM, MINF và RV. Đối với bộ dữ liệu EMIDEC 2020, hệ thống thực hiện phân loại nhị phân giữa bệnh nhân bình thường (Normal) và bệnh nhân có nhồi máu cơ tim (Infarcted).

3.2.6 Giải thích mô hình bằng Explainable AI

Sau khi hoàn thành các nhiệm vụ phân đoạn và phân loại, nghiên cứu áp dụng các phương pháp Explainable AI (XAI) nhằm phân tích cơ sở đưa ra quyết định của mô hình.

Các kỹ thuật XAI được sử dụng gồm:

- **Grad-CAM:** Được sử dụng để trực quan hóa các vùng ảnh có ảnh hưởng lớn đến quyết định dự đoán của mô hình trong quá trình phát hiện tổn thương.
- **Monte Carlo Dropout:** Được sử dụng để đánh giá độ bất định của mô hình thông qua nhiều lần suy luận với cơ chế dropout được giữ hoạt động trong giai đoạn kiểm thử.
- **SHAP:** Được áp dụng cho các mô hình học máy nhằm phân tích mức độ đóng góp của từng đặc trưng lâm sàng đối với kết quả phân loại bệnh lý tim mạch trên bộ dữ liệu ACDC 2017 và phân loại bệnh nhân bình thường, nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020.

Các phương pháp này giúp hỗ trợ giải thích kết quả dự đoán và tăng tính minh bạch của hệ thống trong bài toán hỗ trợ chẩn đoán bệnh tim mạch.

Trên cơ sở các quy trình và cấu hình đã trình bày, chương tiếp theo sẽ tiến hành đánh giá thực nghiệm, so sánh các mô hình và phân tích kết quả trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020.

Chương 4. KẾT QUẢ THỰC NGHIỆM

Chương này trình bày kết quả thực nghiệm và đánh giá hiệu quả của hệ thống trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020. Các mô hình được so sánh thông qua các chỉ số đánh giá, kết quả trực quan và các phương pháp Explainable AI nhằm phân tích khả năng hỗ trợ chẩn đoán bệnh tim mạch từ ảnh MRI.

Ngoài các chỉ số định lượng, chương này còn trình bày kết quả trực quan hóa phân đoạn, kết quả phân loại trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020, phân tích vùng tổn thương nhồi máu cơ tim cũng như các kết quả giải thích mô hình bằng Grad-CAM, Monte Carlo Dropout và SHAP nhằm đánh giá tính chính xác, khả năng tổng quát hóa và độ tin cậy của hệ thống hỗ trợ chẩn đoán.

4.1 Kết quả phân đoạn ảnh MRI tim mạch

4.1.1 Kịch bản thực nghiệm

Để đánh giá hiệu quả của các mô hình phân đoạn trên ảnh MRI tim mạch, nghiên cứu tiến hành thực nghiệm trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020. Bốn kiến trúc học sâu gồm SegResNet, U-Net++, Attention U-Net và DynUNet được huấn luyện và đánh giá trên cả hai bộ dữ liệu nhằm khảo sát khả năng phân đoạn cấu trúc tim và vùng nhồi máu cơ tim.

Đối với bộ dữ liệu ACDC 2017, các mô hình được sử dụng để phân đoạn ba cấu trúc chính gồm thất phải (RV), cơ tim (MYO) và thất trái (LV). Ảnh MRI được chuẩn hóa về kích thước $128 \times 128 \times 16$, sử dụng learning rate 1×10^{-4} và huấn luyện trong 100 epoch.

Đối với bộ dữ liệu EMIDEC 2020, các mô hình được sử dụng để phân đoạn vùng nhồi máu cơ tim trên ảnh LGE-MRI. Ảnh đầu vào được chuẩn hóa về kích thước $112 \times 112 \times 32$, sử dụng learning rate 8×10^{-4} và huấn luyện trong 100 epoch.

Hiệu quả của các mô hình được đánh giá thông qua các chỉ số Dice Score, IoU, HD95 và thời gian huấn luyện. Các tham số thực nghiệm được trình bày trong Bảng 4.1.

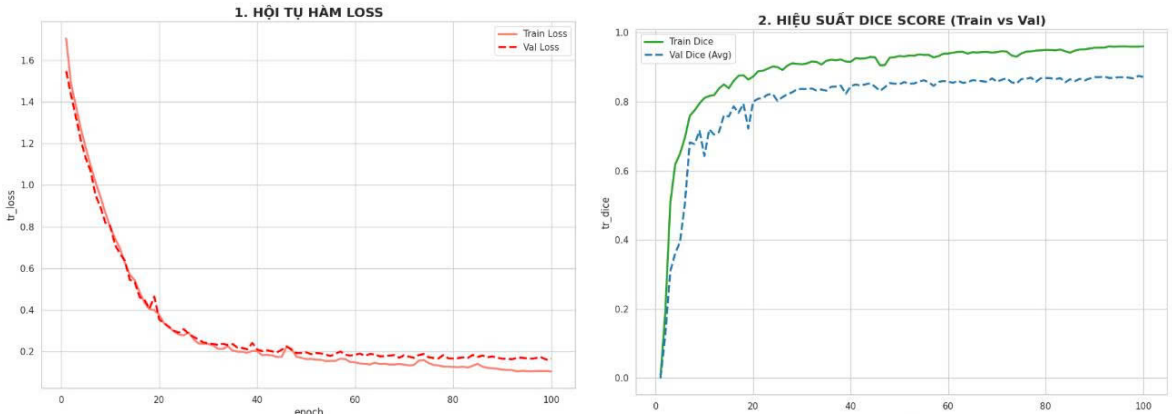
Bảng 4.1: Các kịch bản thực nghiệm cho bài toán phân đoạn ảnh MRI tim mạch

Kịch bản	Bộ dữ liệu	Mô hình	Epoch	Learning Rate	Image Size
1	ACDC 2017	SegResNet	100	1×10^{-4}	$128 \times 128 \times 16$
2	ACDC 2017	U-Net++	100	1×10^{-4}	$128 \times 128 \times 16$
3	ACDC 2017	Attention U-Net	100	1×10^{-4}	$128 \times 128 \times 16$
4	ACDC 2017	DynUNet	100	1×10^{-4}	$128 \times 128 \times 16$
5	EMIDEC 2020	SegResNet	100	8×10^{-4}	$112 \times 112 \times 32$
6	EMIDEC 2020	U-Net++	100	8×10^{-4}	$112 \times 112 \times 32$
7	EMIDEC 2020	Attention U-Net	100	8×10^{-4}	$112 \times 112 \times 32$
8	EMIDEC 2020	DynUNet	100	8×10^{-4}	$112 \times 112 \times 32$

Bốn mô hình được lựa chọn đại diện cho các hướng tiếp cận phổ biến trong phân đoạn ảnh y tế. Attention U-Net khai thác cơ chế chú ý nhằm tăng khả năng tập trung vào các vùng quan trọng, U-Net++ cải tiến các kết nối skip connection để giảm khoảng cách ngữ nghĩa giữa encoder và decoder, SegResNet kết hợp kiến trúc residual learning với mạng phân đoạn 3D, trong khi DynUNet sử dụng cơ chế tự cấu hình kiến trúc dựa trên đặc điểm dữ liệu đầu vào. Việc đánh giá các mô hình trên cả hai bộ dữ liệu ACDC 2017 và EMIDEC 2020 cho phép phân tích khả năng tổng quát hóa và lựa chọn mô hình phân đoạn phù hợp nhất cho hệ thống.

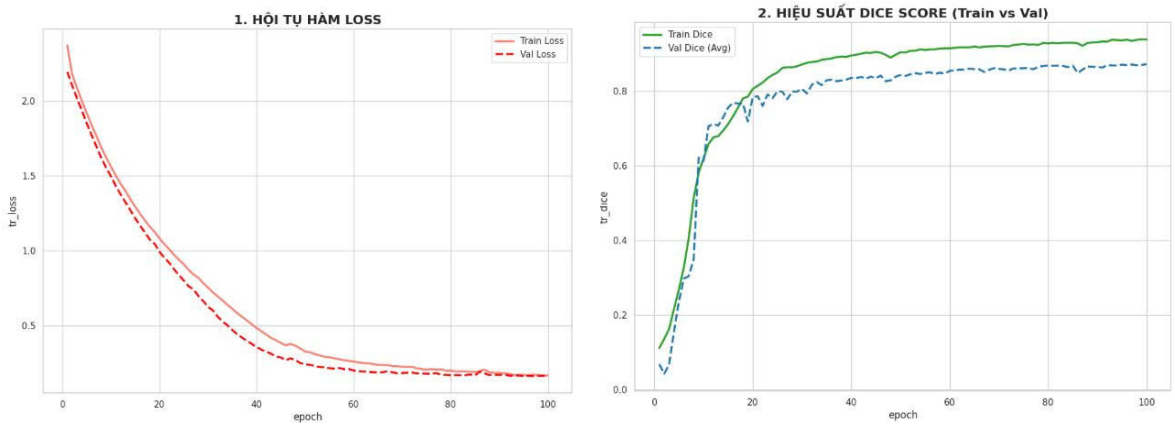
4.1.2 Đánh giá quá trình huấn luyện và hiệu quả phân đoạn

a. Đánh giá quá trình huấn luyện



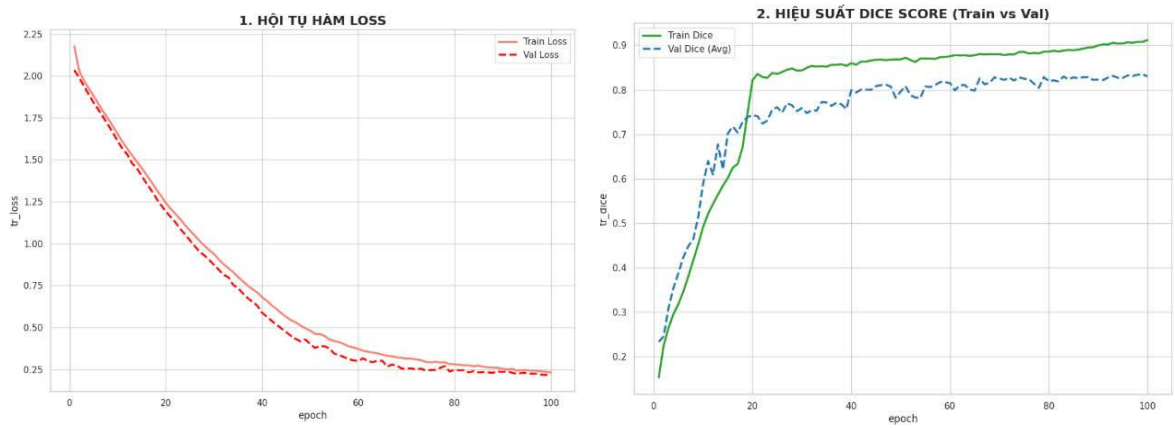
(a) Loss (b) Dice Score

Hình 4.1: Kết quả huấn luyện của kịch bản 1 (SegResNet)



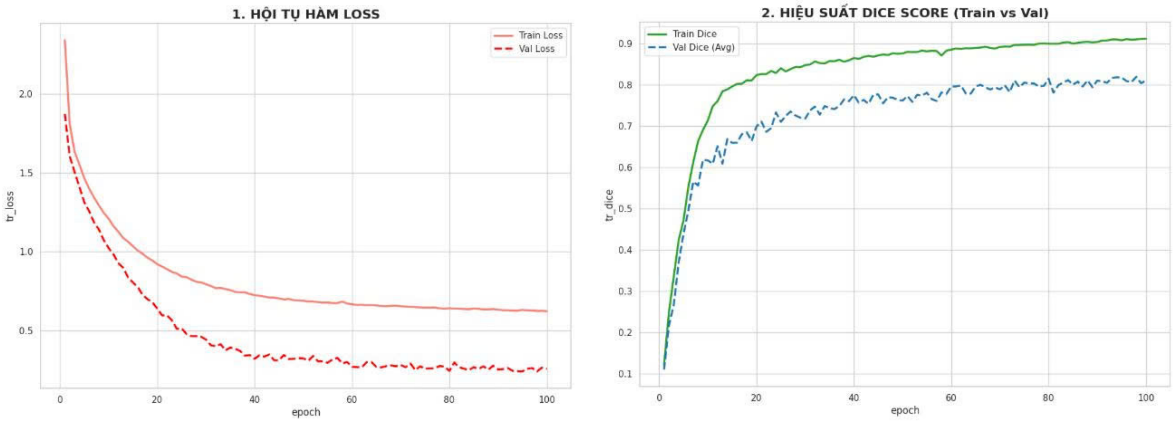
(a) Loss (b) Dice Score

Hình 4.2: Kết quả huấn luyện của kịch bản 2 (U-Net++)



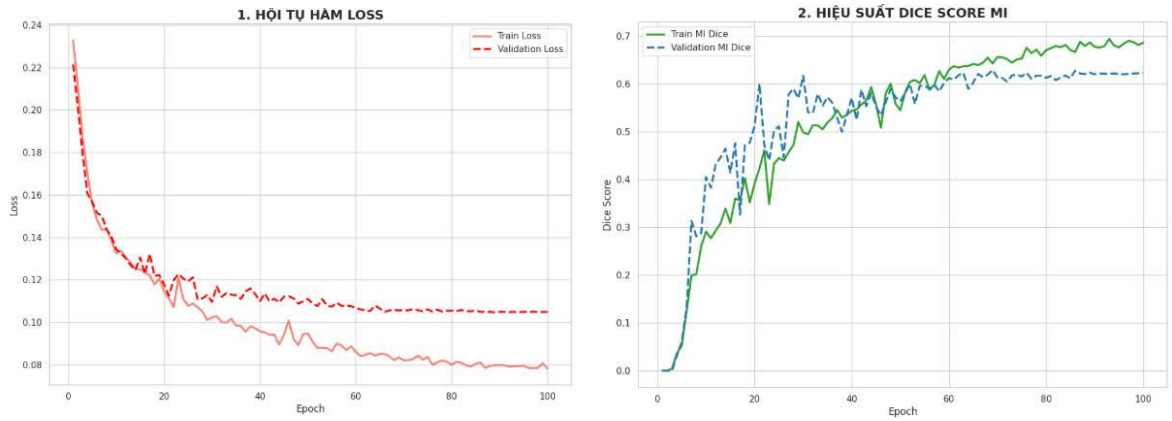
(a) Loss (b) Dice Score

Hình 4.3: Kết quả huấn luyện của kịch bản 3 (Attention U-Net)



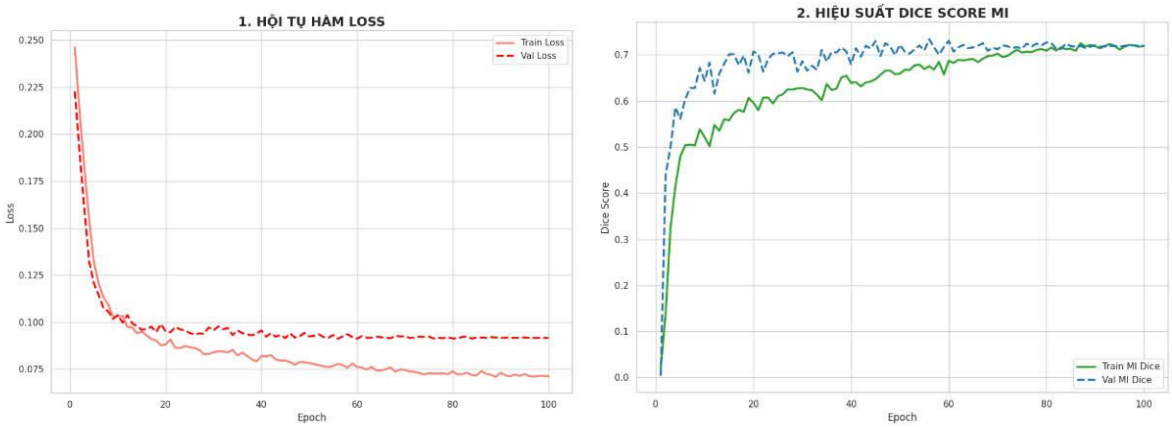
(a) Loss (b) Dice Score

Hình 4.4: Kết quả huấn luyện của kịch bản 4 (DynUNet)



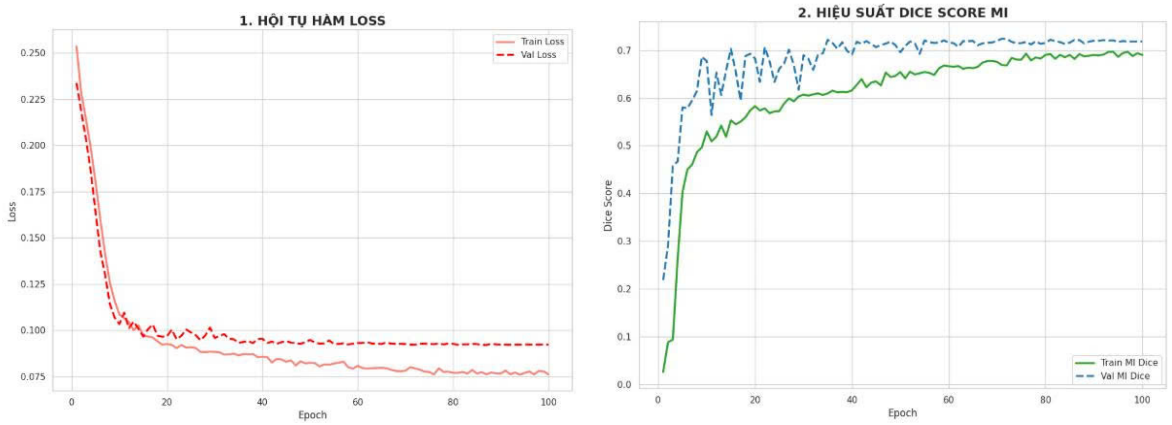
(a) Loss (b) Dice Score

Hình 4.5: Kết quả huấn luyện của kịch bản 5 (SegResNet)



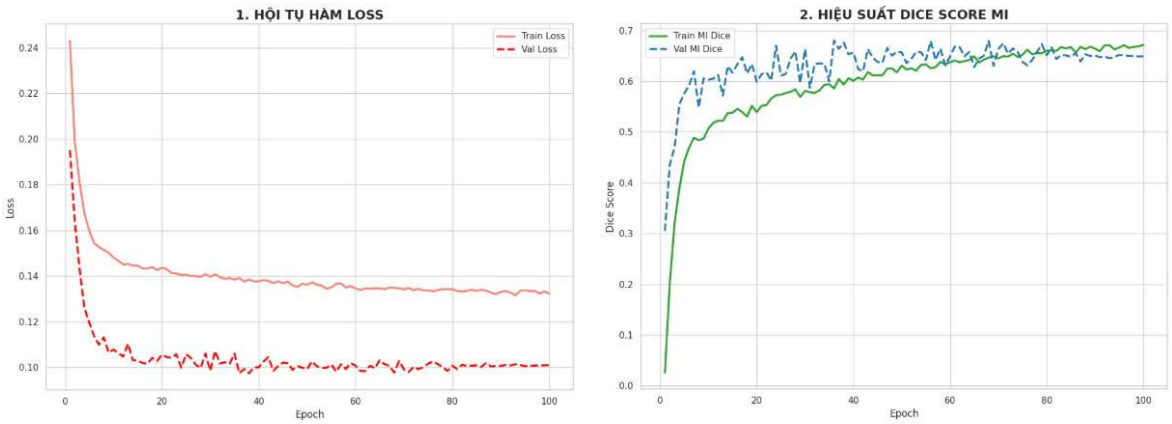
(a) Loss (b) Dice Score

Hình 4.6: Kết quả huấn luyện của kịch bản 6 (U-Net++)



(a) Loss (b) Dice Score

Hình 4.7: Kết quả huấn luyện của kịch bản 7 (Attention U-Net)



(a) Loss (b) Dice Score

Hình 4.8: Kết quả huấn luyện của kịch bản 8 (DynUNet)

Nhận xét tổng quát:

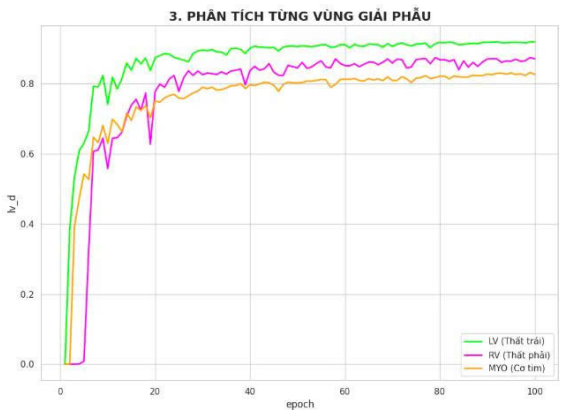
Kết quả huấn luyện trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020 cho thấy cả bốn mô hình SegResNet, U-Net++, Attention U-Net và DynUNet đều hội tụ thành công. Train Loss và Validation Loss có xu hướng giảm dần theo số epoch, trong khi Dice Score tăng ổn định và đạt trạng thái hội tụ ở giai đoạn cuối của quá trình huấn luyện. Điều này cho thấy các mô hình đều học được các đặc trưng quan trọng của cấu trúc tim và vùng tổn thương nhồi máu cơ tim trên ảnh MRI.

Trên bộ dữ liệu ACDC 2017, U-Net++ và SegResNet cho quá trình hội tụ ổn định hơn với khoảng cách nhỏ giữa tập huấn luyện và tập xác thực. Trong khi đó, Attention U-Net và DynUNet xuất hiện nhiều dao động hơn, đặc biệt ở giai đoạn đầu của quá trình huấn luyện. Kết quả này phản ánh khả năng học và tổng quát hóa tốt của U-Net++ và SegResNet đối với bài toán phân đoạn các cấu trúc tim.

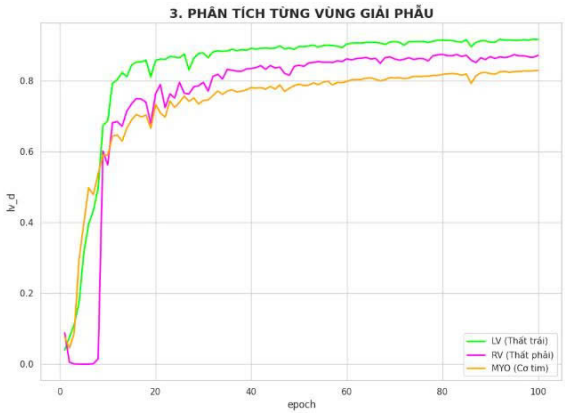
Đối với bộ dữ liệu EMIDEC 2020, U-Net++, Attention U-Net và DynUNet đạt Dice Score cao hơn trong quá trình huấn luyện, cho thấy khả năng học đặc trưng tổn thương hiệu quả. SegResNet vẫn duy trì quá trình hội tụ ổn định nhưng đạt hiệu suất thấp hơn so với các mô hình còn lại. Trong số các mô hình được khảo sát, U-Net++ duy trì sự cân bằng tốt giữa tốc độ hội tụ, độ ổn định và khả năng tổng quát hóa trên cả hai bộ dữ liệu.

Nhìn chung, các kết quả thực nghiệm cho thấy U-Net++ là một trong những mô hình có quá trình huấn luyện ổn định và hiệu quả nhất, trong khi DynUNet thể hiện tiềm năng tốt trên bài toán phát hiện vùng nhồi máu cơ tim. Những kết quả này tạo nền tảng cho các đánh giá chi tiết hơn thông qua các chỉ số Dice Score, IoU, HD95 và thời gian huấn luyện ở các phần tiếp theo.

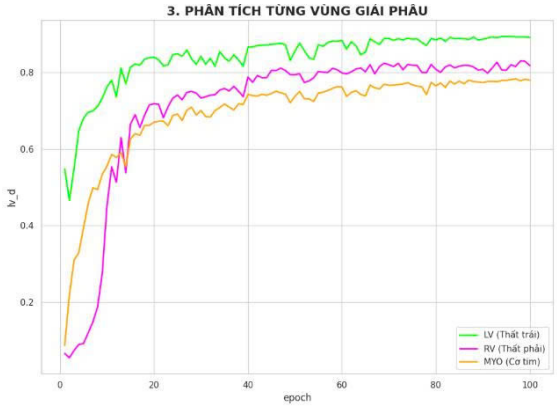
b. Độ đo Dice Score từng vùng giải phẫu



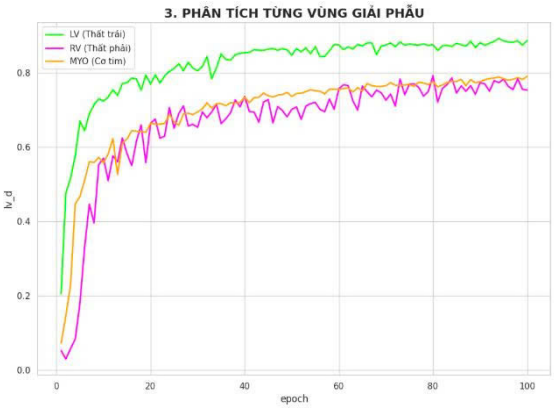
(a) SegResNet



(b) U-Net++

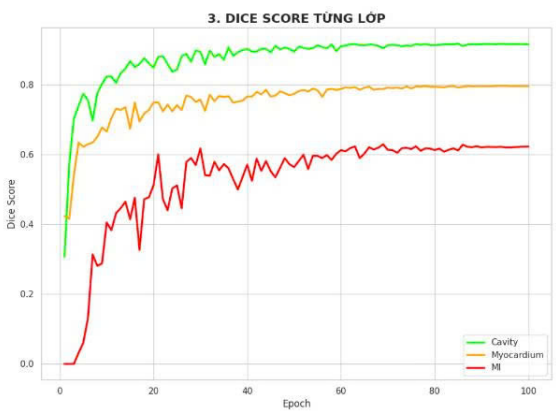


(c) Attention U-Net

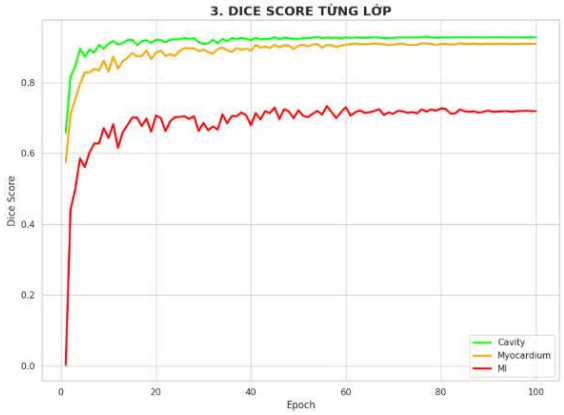


(d) DynUNet

Hình 4.9: Dice Score trên bộ dữ liệu ACDC 2017



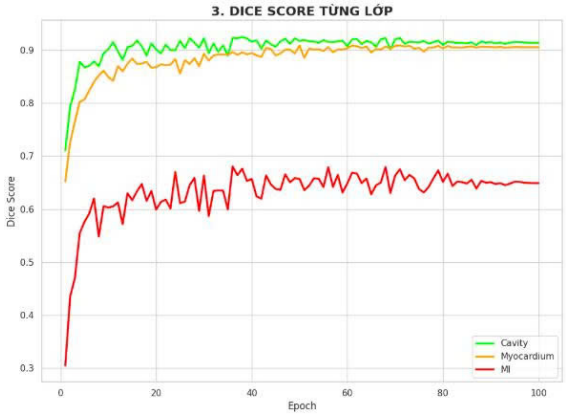
(a) SegResNet



(b) U-Net++



(c) Attention U-Net



(d) DynUNet

Hình 4.10: Dice Score trên bộ dữ liệu EMIDEC 2020

Nhận xét:

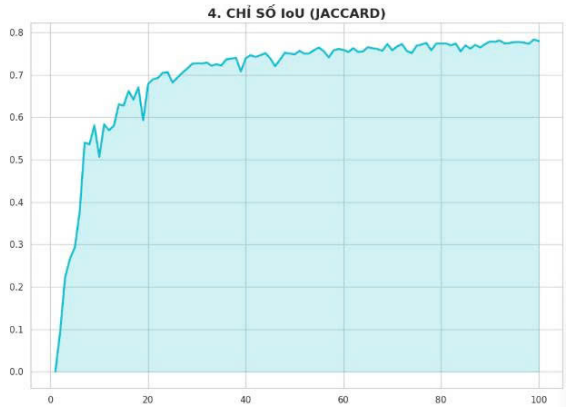
Kết quả Dice Score theo từng vùng giải phẫu và từng lớp cho thấy các mô hình đều đạt hiệu suất cao đối với các cấu trúc có kích thước lớn và hình dạng rõ ràng. Trên bộ dữ liệu ACDC 2017, vùng thất trái (LV) luôn đạt Dice Score cao nhất, tiếp theo là thất phải (RV) và cơ tim (MYO). Điều này cho thấy LV là cấu trúc dễ nhận diện hơn trên ảnh MRI, trong khi MYO có hình dạng phức tạp và biên không rõ ràng hơn nên thường đạt Dice Score thấp hơn.

Đối với bộ dữ liệu EMIDEC 2020, các mô hình đều phân đoạn tốt lớp Cavity và Myocardium với Dice Score cao hơn đáng kể so với lớp MI. Ngược lại, lớp nhồi máu cơ tim có Dice Score thấp hơn và xuất hiện nhiều dao động hơn trong quá trình huấn luyện. Điều này phản ánh độ khó của bài toán phát hiện tổn thương nhồi máu cơ tim do vùng tổn thương thường có kích thước nhỏ, hình dạng không đồng nhất và phân bố mất cân bằng trong dữ liệu.

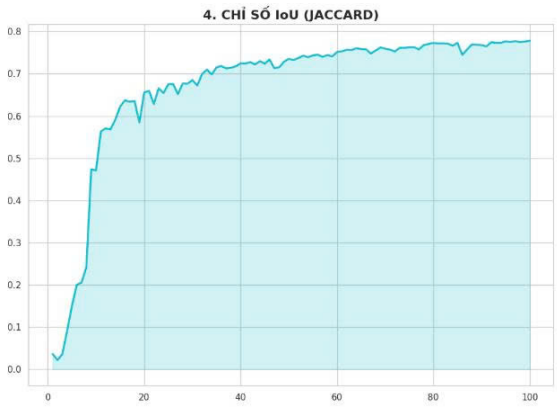
Trong số các mô hình được khảo sát, U-Net++ và SegResNet duy trì Dice Score cao và ổn định trên các cấu trúc giải phẫu của bộ dữ liệu ACDC 2017, trong khi U-Net++, Attention U-Net và DynUNet đạt hiệu suất tốt hơn đối với lớp MI trên bộ dữ

liệu EMIDEC 2020. Nhìn chung, kết quả cho thấy các mô hình đều có khả năng học hiệu quả đặc trưng giải phẫu tim, tuy nhiên việc phân đoạn vùng nhồi máu cơ tim vẫn là bài toán khó hơn so với phân đoạn các cấu trúc tim thông thường.

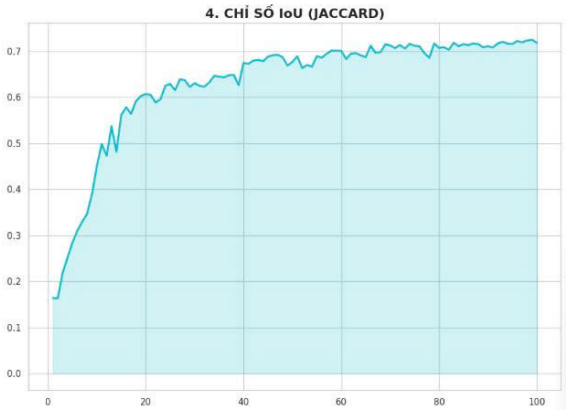
c. Độ đo IoU



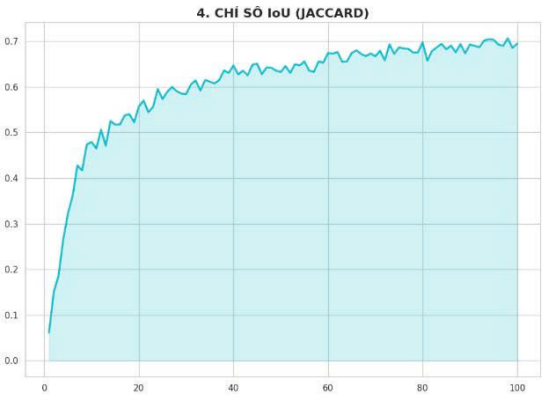
(a) SegResNet



(b) U-Net++

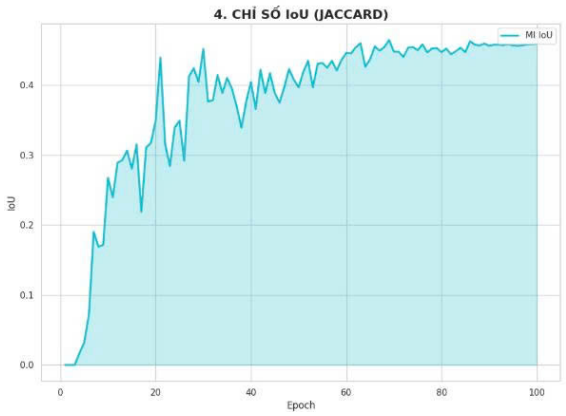


(c) Attention U-Net

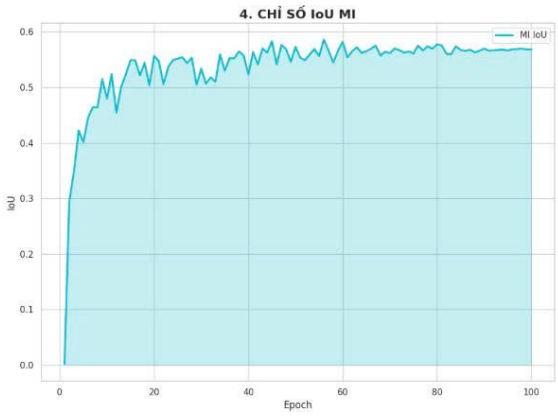


(d) DynUNet

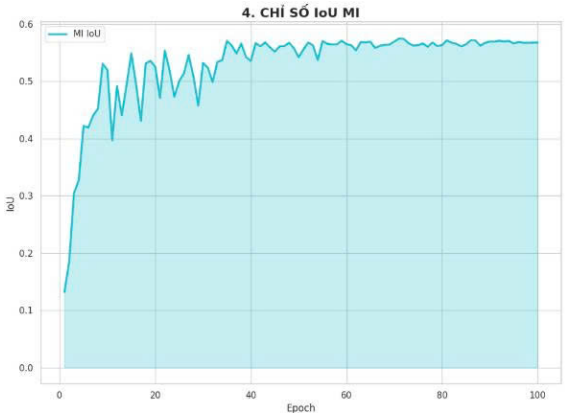
Hình 4.11: Chỉ số IoU của bốn mô hình trên bộ dữ liệu ACDC 2017



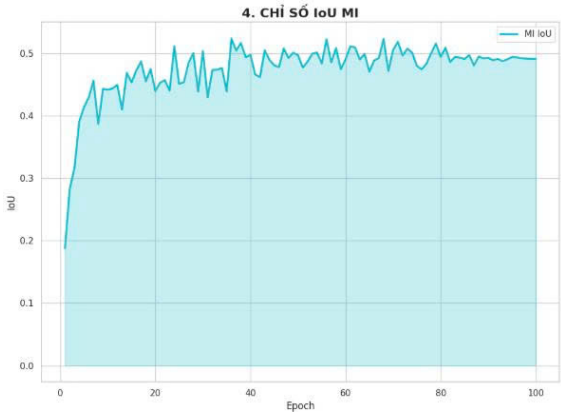
(a) SegResNet



(b) U-Net++



(c) Attention U-Net



(d) DynUNet

Hình 4.12: Chỉ số IoU của bốn mô hình trên bộ dữ liệu EMIDEC 2020

Nhận xét:

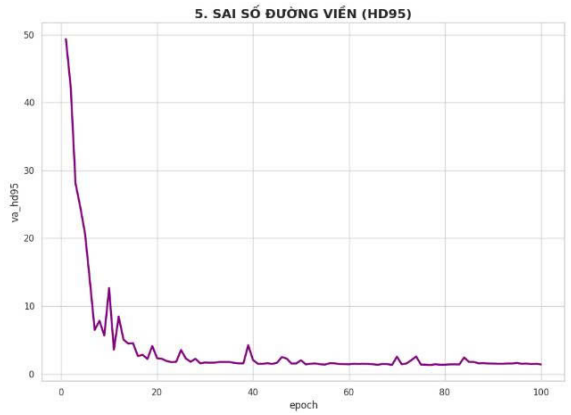
Kết quả IoU cho thấy cả bốn mô hình đều cải thiện khả năng phân đoạn theo thời gian huấn luyện, thể hiện qua xu hướng tăng dần của chỉ số IoU và đạt trạng thái ổn định ở các epoch cuối. Điều này phản ánh mức độ chồng lấp giữa vùng dự đoán và nhãn thực tế ngày càng được cải thiện trong quá trình học.

Trên bộ dữ liệu ACDC 2017, U-Net++ và SegResNet duy trì giá trị IoU cao và ổn định hơn so với Attention U-Net và DynUNet. Khoảng cách giữa tập huấn luyện và tập xác thực tương đối nhỏ, cho thấy hai mô hình có khả năng tổng quát hóa tốt và ít xảy ra hiện tượng quá khớp. Trong khi đó, Attention U-Net và DynUNet xuất hiện nhiều dao động hơn trên tập xác thực và đạt giá trị IoU thấp hơn.

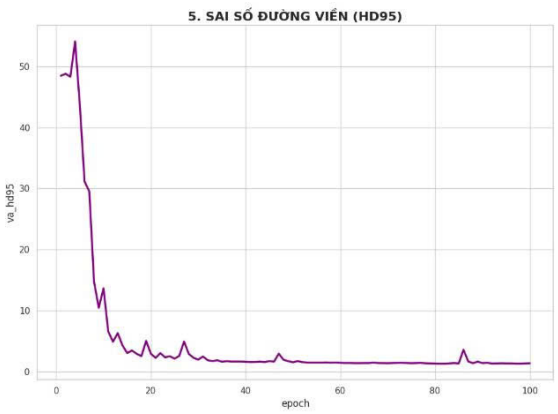
Đối với bộ dữ liệu EMIDEC 2020, tất cả các mô hình đều cải thiện đáng kể khả năng phát hiện vùng nhồi máu cơ tim trong quá trình huấn luyện. U-Net++, Attention U-Net và DynUNet đạt giá trị IoU cao hơn, phản ánh khả năng nhận diện vùng tổn thương hiệu quả. DynUNet duy trì xu hướng ổn định và đạt hiệu quả tốt trên tập kiểm thử, trong khi SegResNet có giá trị IoU thấp hơn nhưng vẫn đảm bảo khả năng phân đoạn nhất quán.

Nhìn chung, U-Net++ cho thấy hiệu suất ổn định trên cả hai bộ dữ liệu, trong khi DynUNet nổi bật hơn ở bài toán phát hiện vùng nhồi máu cơ tim trên EMIDEC 2020. Kết quả này cho thấy các mô hình đều có khả năng học hiệu quả đặc trưng ảnh MRI tim, đồng thời phản ánh sự khác biệt về độ khó giữa bài toán phân đoạn cấu trúc tim và bài toán phát hiện tổn thương nhồi máu cơ tim.

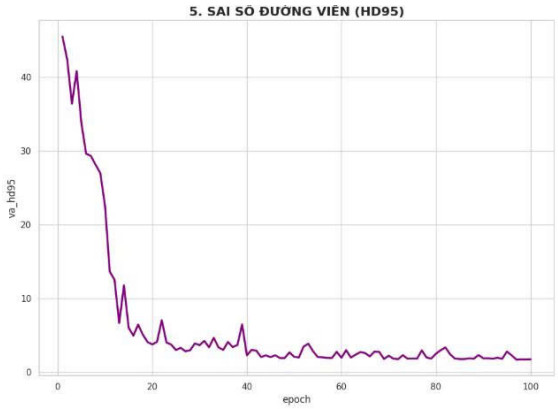
d. Độ đo HD95



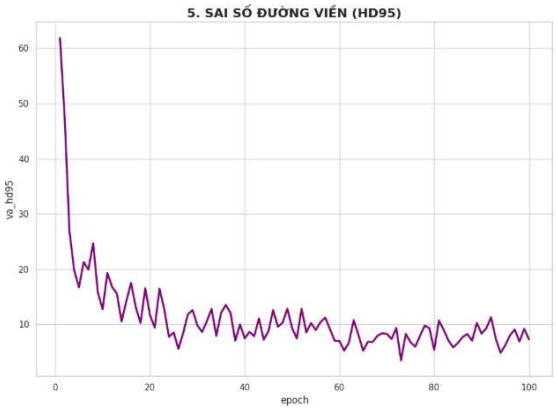
(a) SegResNet



(b) U-Net++

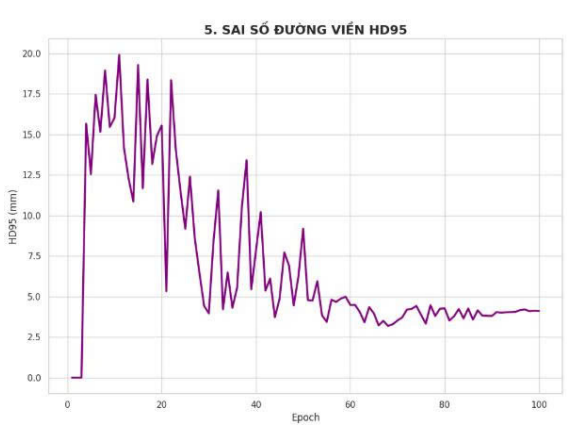


(c) Attention U-Net

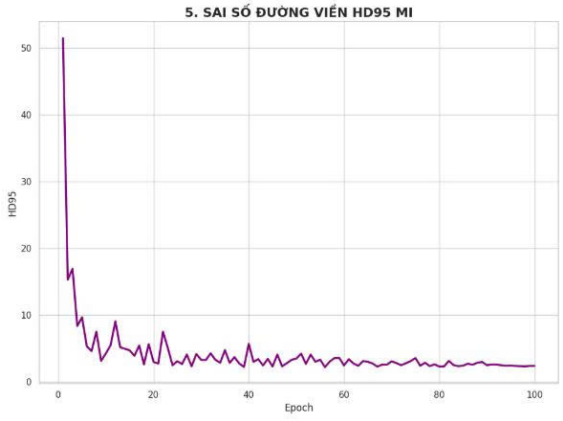


(d) DynUNet

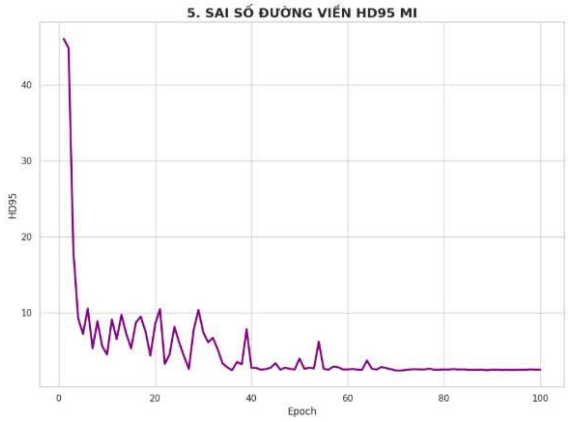
Hình 4.13: Chỉ số HD95 của bốn mô hình trên bộ dữ liệu ACDC 2017



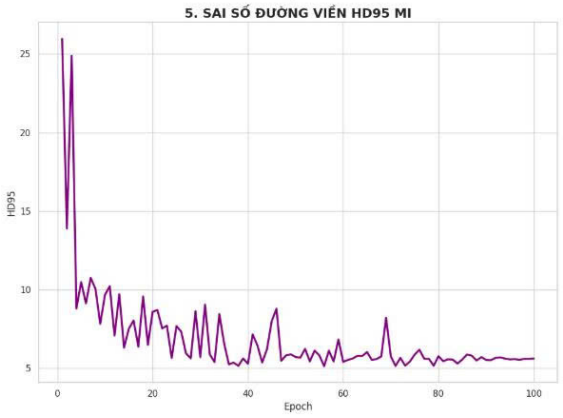
(a) SegResNet



(b) U-Net++



(c) Attention U-Net



(d) DynUNet

Hình 4.14: Chỉ số HD95 của bốn mô hình trên bộ dữ liệu EMIDEC 2020

Nhận xét:

Kết quả HD95 cho thấy cả bốn mô hình đều cải thiện khả năng xác định đường biên phân đoạn trong quá trình huấn luyện, thể hiện qua xu hướng giảm dần của chỉ số HD95 theo số epoch. Giá trị HD95 thấp phản ánh mức độ sai lệch giữa đường biên dự đoán và nhãn thực tế được giảm thiểu, cho thấy mô hình có khả năng xác định ranh giới đối tượng chính xác hơn.

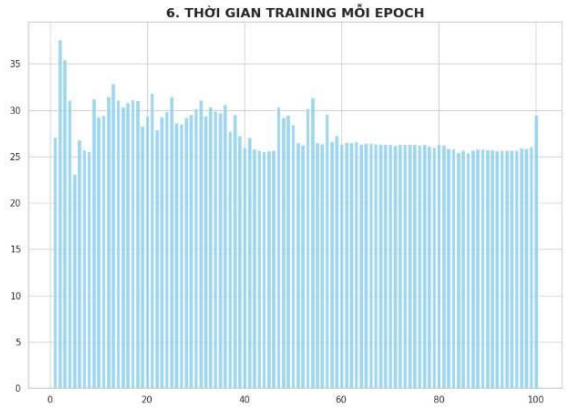
Trên bộ dữ liệu ACDC 2017, U-Net++ và SegResNet duy trì giá trị HD95 thấp và ổn định hơn so với Attention U-Net và DynUNet. Đặc biệt, U-Net++ cho thấy khả năng kiểm soát sai số biên tốt với quá trình hội tụ ổn định trong suốt quá trình huấn luyện. Điều này cho thấy mô hình không chỉ phân đoạn chính xác các cấu trúc tim mà còn xác định được ranh giới giải phẫu một cách nhất quán. Trong khi đó, Attention U-Net và DynUNet xuất hiện nhiều dao động hơn trên tập xác thực và đạt giá trị HD95 cao hơn.

Đối với bộ dữ liệu EMIDEC 2020, tất cả các mô hình đều cải thiện khả năng xác định đường biên vùng nhồi máu cơ tim theo thời gian huấn luyện. U-Net++ duy trì giá

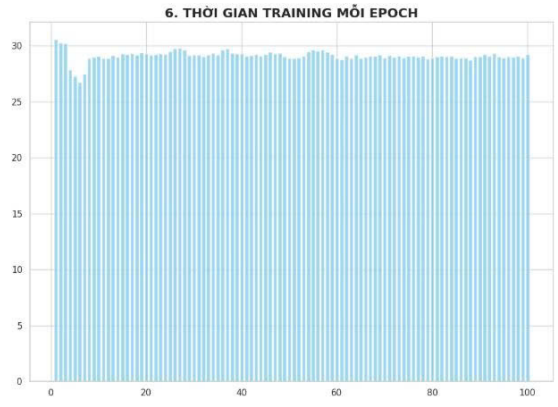
trị HD95 thấp và ổn định hơn, phản ánh khả năng xác định biên tổn thương chính xác. DynUNet đạt Dice Score và IoU cao nhất nhưng vẫn duy trì sai số biên nhất định, cho thấy mô hình nhận diện tốt vùng tổn thương nhưng việc xác định ranh giới tổn thương vẫn còn nhiều thách thức do hình dạng không đồng nhất của vùng nhồi máu cơ tim.

Nhìn chung, U-Net++ là mô hình có hiệu suất ổn định nhất về độ chính xác đường biên trên cả hai bộ dữ liệu, trong khi DynUNet cho thấy ưu thế về khả năng phát hiện tổn thương trên EMIDEC 2020. Kết quả HD95 cho thấy việc phân đoạn các cấu trúc tim trên ACDC 2017 dễ dàng hơn so với bài toán phát hiện vùng nhồi máu cơ tim trên EMIDEC 2020 do sự khác biệt về kích thước, hình dạng và độ phức tạp của đối tượng cần phân đoạn.

e. Thời gian huấn luyện



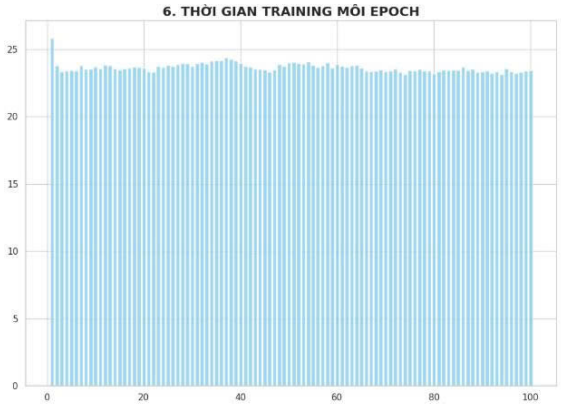
(a) SegResNet



(b) U-Net++



(c) Attention U-Net



(d) DynUNet

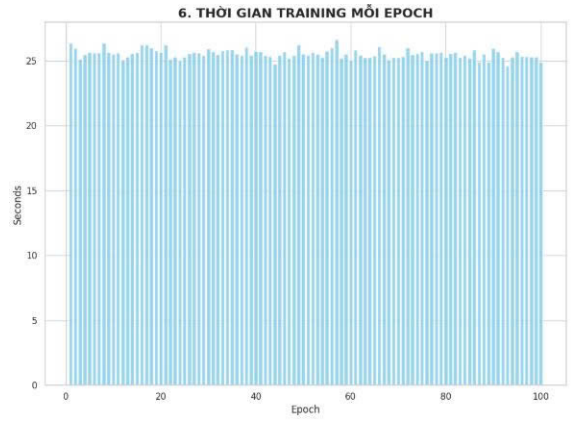
Hình 4.15: Thời gian huấn luyện của bốn mô hình trên bộ dữ liệu ACDC 2017



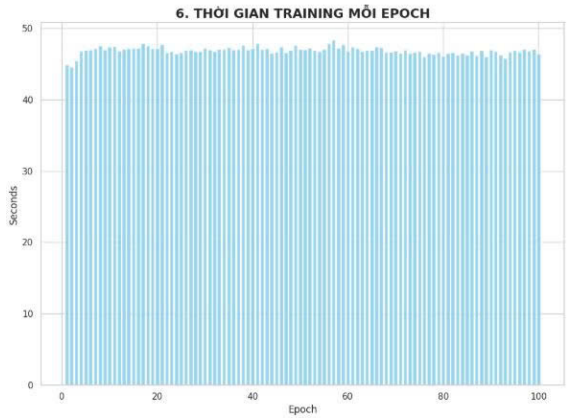
(a) SegResNet



(b) U-Net++



(c) Attention U-Net



(d) DynUNet

Hình 4.16: Thời gian huấn luyện của bốn mô hình trên bộ dữ liệu EMIDEC 2020

Nhận xét:

Kết quả cho thấy thời gian huấn luyện của các mô hình phụ thuộc đáng kể vào độ phức tạp của kiến trúc mạng và kích thước dữ liệu đầu vào. Trên cả hai bộ dữ liệu ACDC 2017 và EMIDEC 2020, thời gian huấn luyện của các mô hình tương đối ổn định sau các epoch đầu tiên và không xuất hiện hiện tượng tăng đột biến trong quá trình huấn luyện.

Đối với bộ dữ liệu ACDC 2017, Attention U-Net có thời gian huấn luyện ngắn nhất, tiếp theo là DynUNet. Trong khi đó, SegResNet và U-Net++ yêu cầu thời gian xử lý dài hơn do kiến trúc mạng phức tạp hơn và khả năng khai thác đặc trưng sâu hơn. Mặc dù U-Net++ có thời gian huấn luyện cao nhất, mô hình vẫn duy trì hiệu suất cao và ổn định trên các chỉ số Dice Score, IoU và HD95.

Trên bộ dữ liệu EMIDEC 2020, SegResNet và Attention U-Net có thời gian huấn luyện thấp hơn, trong khi DynUNet và U-Net++ yêu cầu chi phí tính toán lớn hơn do số lượng tham số và độ phức tạp của kiến trúc mạng. Tuy nhiên, sự gia tăng thời gian huấn luyện đi kèm với khả năng cải thiện hiệu quả phân đoạn, đặc biệt đối với các mô hình đạt kết quả cao trên các chỉ số Dice Score và IoU.

Nhìn chung, kết quả cho thấy tồn tại sự đánh đổi giữa chi phí tính toán và độ chính xác phân đoạn. U-Net++ cho hiệu suất ổn định trên cả hai bộ dữ liệu nhưng yêu cầu thời gian huấn luyện lớn hơn, trong khi DynUNet đạt hiệu quả cao trên bài toán phát hiện vùng nhồi máu cơ tim của bộ dữ liệu EMIDEC 2020. Mặc dù thời gian huấn luyện khác nhau, tất cả các mô hình đều có thể triển khai hiệu quả trên môi trường Kaggle Notebook sử dụng GPU NVIDIA Tesla T4.

4.1.3 So sánh kết quả các mô hình phân đoạn trên bộ dữ liệu ACDC 2017 và EMIDEC 2020

Sau khi đánh giá chi tiết quá trình huấn luyện và hiệu quả phân đoạn của từng mô hình trên bộ dữ liệu ACDC 2017 và EMIDEC 2020, nghiên cứu tiến hành tổng hợp các kết quả thực nghiệm nhằm so sánh hiệu suất giữa các kiến trúc và lựa chọn mô hình phù hợp nhất cho hệ thống đề xuất.

Các mô hình được đánh giá dựa trên các chỉ số Dice Score, IoU, HD95 và thời gian huấn luyện. Kết quả tổng hợp được trình bày trong Bảng 4.2.

Bảng 4.2: So sánh kết quả các mô hình phân đoạn trên ACDC 2017 và EMIDEC 2020

Kịch bản	**Bộ dữ liệu**	**Mô hình**	**Dice (%)**	**IoU (%)**	**HD95**	**Time**
1	ACDC 2017	SegResNet	86.80	77.58	1.37 mm	46.37 m
2	ACDC 2017	U-Net++	86.83	77.44	1.35 mm	48.52 m
3	ACDC 2017	Attention U-Net	83.53	72.85	1.82 mm	32.43 m
4	ACDC 2017	DynUNet	81.88	70.84	3.35 mm	39.34 m
5	EMIDEC 2020	SegResNet	61.62	45.68	5.9 mm	42.9 m
6	EMIDEC 2020	U-Net++	66.36	50.37	5.1 mm	83.7 m
7	EMIDEC 2020	Attention U-Net	66.34	49.96	7.3 mm	42.5 m
8	EMIDEC 2020	DynUNet	67.19	50.92	6.1 mm	78.0 m

Nhận xét:

Kết quả trong Bảng 4.2 cho thấy hiệu quả của các mô hình phụ thuộc vào đặc điểm của từng bộ dữ liệu.

Trên bộ dữ liệu ACDC 2017, U-Net++ và SegResNet đạt kết quả tốt nhất với Dice Score lần lượt đạt 86.83% và 86.80%. U-Net++ đạt HD95 thấp nhất (1.35 mm), trong khi SegResNet đạt IoU cao nhất (77.58%). Điều này cho thấy hai mô hình có khả năng phân đoạn cấu trúc tim ổn định và chính xác.

Trên bộ dữ liệu EMIDEC 2020, DynUNet đạt Dice Score và IoU cao nhất với giá trị lần lượt là 67.19% và 50.92%, cho thấy khả năng phát hiện vùng nhồi máu cơ tim

hiệu quả hơn các mô hình còn lại. Trong khi đó, U-Net++ đạt HD95 thấp nhất (5.1 mm), thể hiện khả năng xác định biên tổn thương chính xác hơn.

Nhìn chung, U-Net++ cho hiệu năng ổn định trên cả hai bộ dữ liệu, trong khi DynUNet cho kết quả tốt nhất trên bài toán phát hiện vùng nhồi máu cơ tim của bộ dữ liệu EMIDEC 2020.

4.1.4 Lựa chọn mô hình phân đoạn chính

Dựa trên kết quả thực nghiệm trên cả hai bộ dữ liệu ACDC 2017 và EMIDEC 2020, mô hình U-Net++ cho thấy hiệu suất ổn định và cân bằng nhất giữa các chỉ số Dice Score, IoU và HD95.

Trên bộ dữ liệu ACDC 2017, U-Net++ đạt Dice RV cao nhất (85.87%), Dice LV cao nhất (91.20%) và HD95 thấp nhất (1.35 mm), đồng thời duy trì hiệu suất tương đương SegResNet về chỉ số IoU. Trên bộ dữ liệu EMIDEC 2020, mặc dù DynUNet đạt Dice Score và IoU cao hơn một lượng nhỏ, U-Net++ lại đạt giá trị HD95 thấp nhất (5.1 mm) và duy trì hiệu suất ổn định trên cả hai bộ dữ liệu. Mặc dù DynUNet đạt Dice Score và IoU cao nhất trên bộ dữ liệu EMIDEC 2020, mức cải thiện không đáng kể so với U-Net++, trong khi U-Net++ cho thấy khả năng tổng quát hóa và tính ổn định tốt hơn trên cả hai bộ dữ liệu.

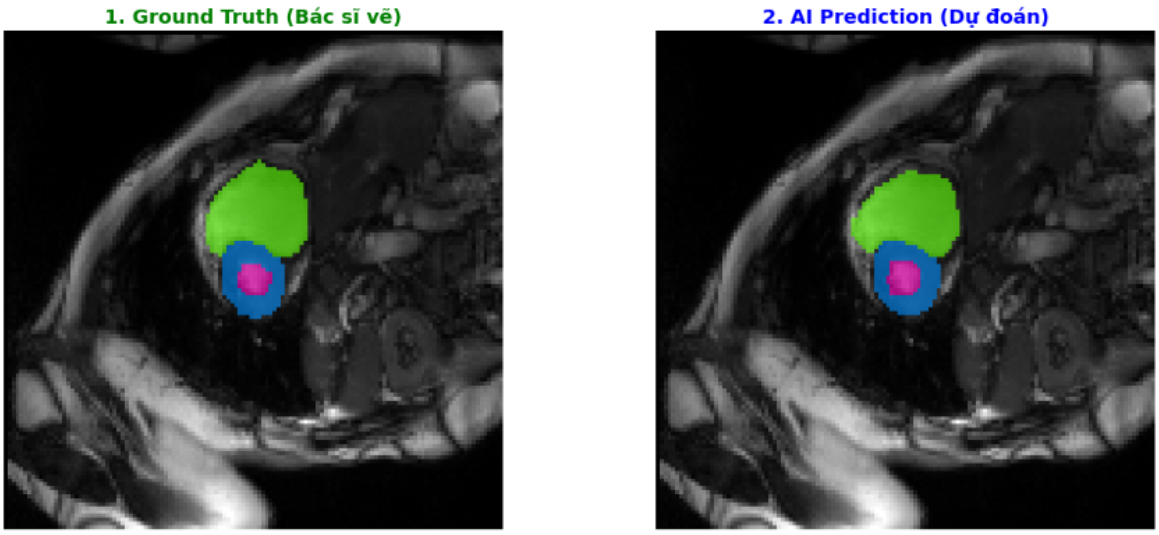
Xét tổng thể về khả năng tổng quát hóa, độ ổn định trong quá trình huấn luyện và chất lượng phân đoạn trên nhiều bài toán khác nhau, nghiên cứu lựa chọn U-Net++ làm mô hình phân đoạn chính của hệ thống. Mô hình này tiếp tục được sử dụng để thực hiện các phân tích trực quan, đánh giá khả năng giải thích và đánh giá độ bất định ở các mục tiếp theo.

4.1.5 Đánh giá độ bất định và giải thích mô hình phân đoạn

Sau khi hoàn thành quá trình đánh giá và lựa chọn mô hình phân đoạn, nghiên cứu tiến hành phân tích khả năng giải thích và độ tin cậy của mô hình U-Net++ thông qua các phương pháp Explainable AI. Các kỹ thuật được sử dụng bao gồm trực quan hóa kết quả phân đoạn, Grad-CAM, trực quan hóa quá trình học đặc trưng và Monte Carlo Dropout nhằm làm rõ cơ chế ra quyết định của mô hình trên ảnh MRI tim mạch.

Kết quả phân đoạn trực quan của mô hình U-Net++

Hình 4.17 minh họa kết quả phân đoạn của mô hình U-Net++ trên tập kiểm thử.

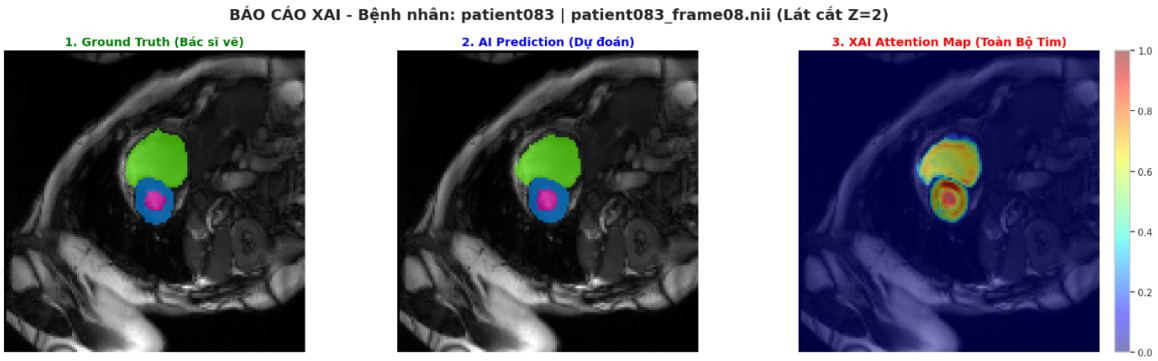


Hình 4.17: Kết quả phân đoạn của mô hình U-Net++

Nhận xét:

Kết quả dự đoán cho thấy mô hình U-Net++ có khả năng xác định chính xác các cấu trúc giải phẫu và vùng tổn thương trên ảnh MRI tim mạch. Các mặt nạ dự đoán có độ tương đồng cao với Ground Truth, đặc biệt tại các vùng giải phẫu chính của tim. Sai lệch chủ yếu xuất hiện tại các vùng biên phức tạp, tuy nhiên không ảnh hưởng đáng kể đến chất lượng phân đoạn tổng thể. Điều này cho thấy mô hình có khả năng học hiệu quả các đặc trưng không gian và hình thái học của cấu trúc tim trên ảnh MRI.

Grad-CAM



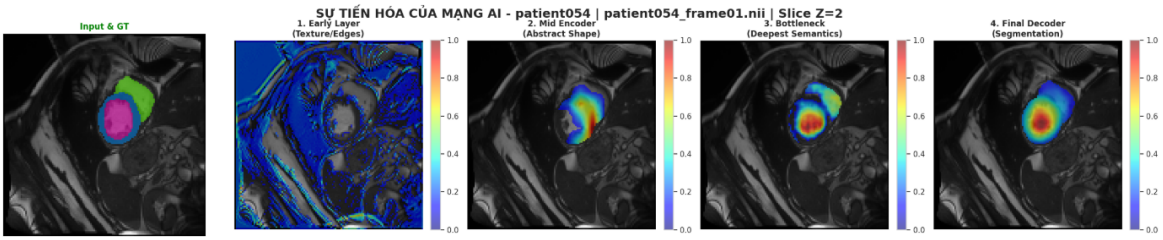
Hình 4.18: Kết quả Grad-CAM của mô hình U-Net++

Nhận xét:

Bản đồ Grad-CAM cho thấy mô hình tập trung chủ yếu vào các vùng giải phẫu quan trọng trong quá trình phân đoạn. Các vùng có cường độ kích hoạt cao trùng khớp với vị trí của các cấu trúc cần nhận diện, chứng tỏ mô hình học được các đặc trưng

có ý nghĩa lâm sàng thay vì dựa vào các vùng nền không liên quan. Kết quả này góp phần nâng cao tính minh bạch và khả năng giải thích của mô hình.

Trực quan hóa quá trình học đặc trưng

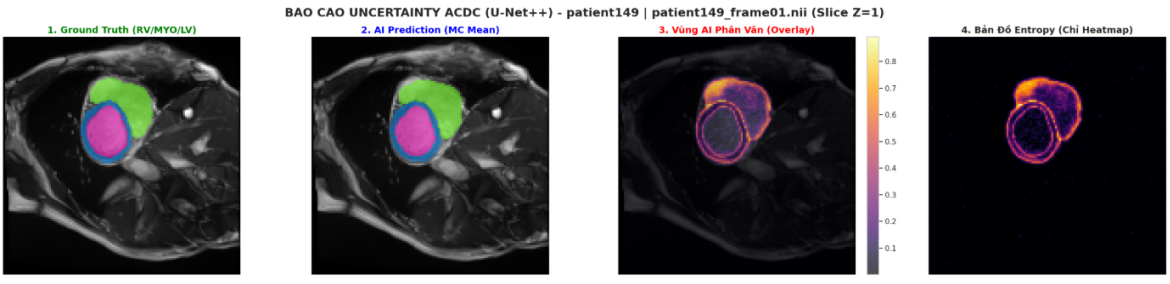


Hình 4.19: Sự tiến hóa đặc trưng qua các tầng của mô hình U-Net++

Nhận xét:

Hình 4.19 minh họa quá trình học đặc trưng của mô hình U-Net++ từ ảnh MRI đầu vào đến kết quả phân đoạn cuối cùng. Ở các tầng đầu, mô hình tập trung vào các đặc trưng mức thấp như biên và kết cấu ảnh. Tại các tầng giữa, mô hình bắt đầu học được hình dạng tổng quát của các cấu trúc tim. Khi đi sâu hơn vào mạng, vùng kích hoạt tập trung rõ ràng vào các vùng giải phẫu quan trọng, phản ánh khả năng trích xuất đặc trưng ngữ nghĩa hiệu quả. Cuối cùng, mô hình tái tạo mặt nạ phân đoạn với các cấu trúc được xác định rõ ràng.

Đánh giá độ bất định bằng Monte Carlo Dropout



Hình 4.20: Bản đồ độ bất định của mô hình U-Net++

Nhận xét:

Kết quả Monte Carlo Dropout cho thấy phần lớn các vùng nằm bên trong cấu trúc giải phẫu có độ tin cậy cao, trong khi độ bất định tập trung chủ yếu tại các vùng biên giữa các lớp. Điều này phù hợp với đặc điểm của bài toán phân đoạn ảnh y tế, khi ranh giới giữa các mô giải phẫu thường khó xác định chính xác tuyệt đối. Mức độ

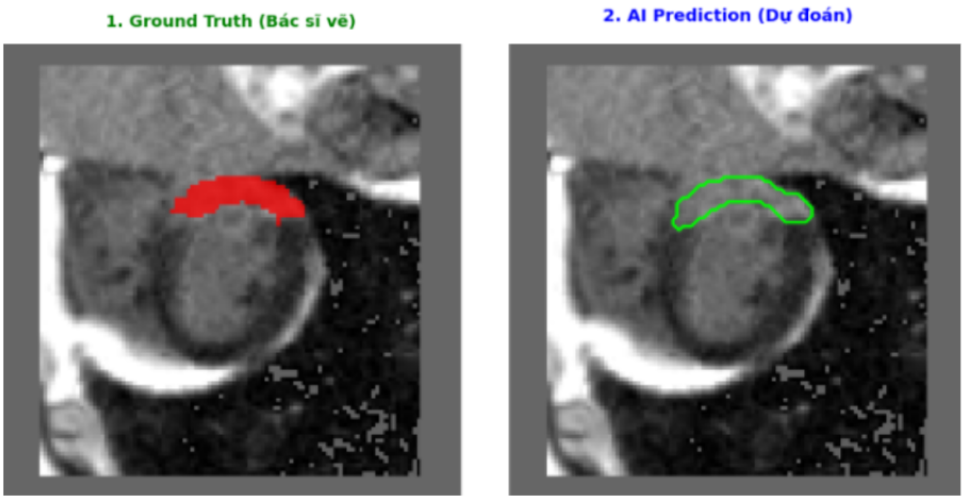
bất định thấp tại các vùng dự đoán chính cho thấy mô hình có độ tin cậy tốt trong quá trình phân đoạn.

Kết luận:

Các kết quả trực quan và phân tích Explainable AI cho thấy mô hình U-Net++ không chỉ đạt hiệu suất phân đoạn cao mà còn có khả năng giải thích tốt. Grad-CAM xác nhận mô hình tập trung đúng vào các vùng giải phẫu quan trọng, trong khi bản đồ độ bất định giúp nhận diện các khu vực có mức độ tin cậy thấp hơn. Những kết quả này góp phần nâng cao tính minh bạch và độ tin cậy của hệ thống trong các ứng dụng hỗ trợ chẩn đoán bệnh tim mạch dựa trên ảnh MRI.

4.2 Kết quả phát hiện và phân đoạn vùng nhồi máu cơ tim

Sau khi lựa chọn U-Net++ làm mô hình phân đoạn chính, mô hình được sử dụng để phát hiện và phân đoạn vùng nhồi máu cơ tim trên tập kiểm thử của bộ dữ liệu EMIDEC 2020. Hệ thống không chỉ xác định vị trí tổn thương mà còn hỗ trợ đánh giá trực quan vùng nhồi máu thông qua mặt nạ dự đoán và các phương pháp Explainable AI.



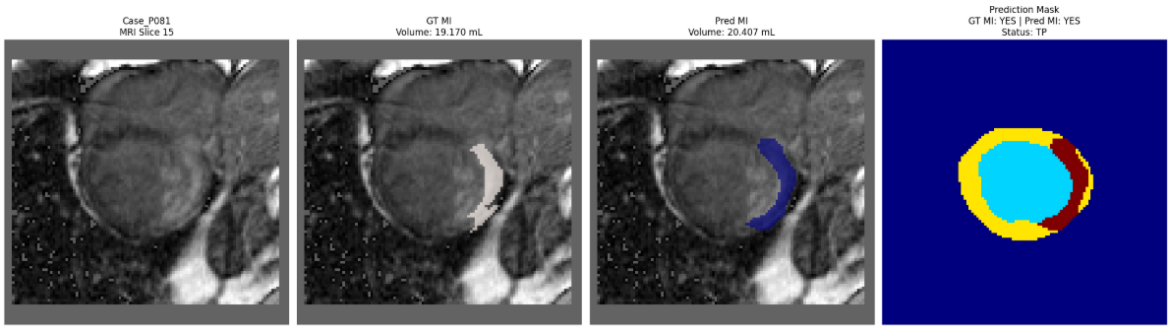
Hình 4.21: Kết quả phát hiện và phân đoạn vùng nhồi máu cơ tim bằng mô hình U-Net++

Nhận xét:

Hình 4.21 cho thấy vùng nhồi máu cơ tim được mô hình U-Net++ phát hiện tương đối chính xác và có mức độ tương đồng cao với Ground Truth. Đường biên dự đoán bao phủ phần lớn vùng tổn thương thực tế, đồng thời hạn chế được các vùng dự đoán sai bên ngoài cơ tim. Kết quả này cho thấy mô hình đã học được các đặc trưng cường độ tín hiệu đặc trưng của tổn thương nhồi máu trên ảnh LGE-MRI.

4.2.1 Kết quả phát hiện và định lượng vùng nhồi máu cơ tim

Sau khi hoàn thành quá trình phân đoạn đa lớp trên bộ dữ liệu EMIDEC 2020, vùng nhồi máu cơ tim được trích xuất từ lớp MI trong kết quả dự đoán. Từ mặt nạ phân đoạn, hệ thống tiến hành xác định sự hiện diện của tổn thương nhồi máu cơ tim và tính toán thể tích vùng tổn thương.



Hình 4.22: Ví dụ kết quả phát hiện và định lượng vùng nhồi máu cơ tim trên bộ dữ liệu EMIDEC 2020

Hình 4.22 minh họa một trường hợp trên bộ dữ liệu EMIDEC 2020. Cột thứ nhất là ảnh MRI gốc, cột thứ hai là vùng nhồi máu cơ tim theo Ground Truth, cột thứ ba là kết quả dự đoán của mô hình U-Net++ và cột cuối cùng là bản đồ phân đoạn đa lớp gồm buồng tim, cơ tim và vùng nhồi máu cơ tim.

Đối với trường hợp này, thể tích vùng nhồi máu cơ tim theo Ground Truth đạt 19.170 mL, trong khi mô hình dự đoán 20.407 mL. Sai lệch thể tích tương đối nhỏ cho thấy mô hình có khả năng định lượng vùng tổn thương tương đối chính xác.

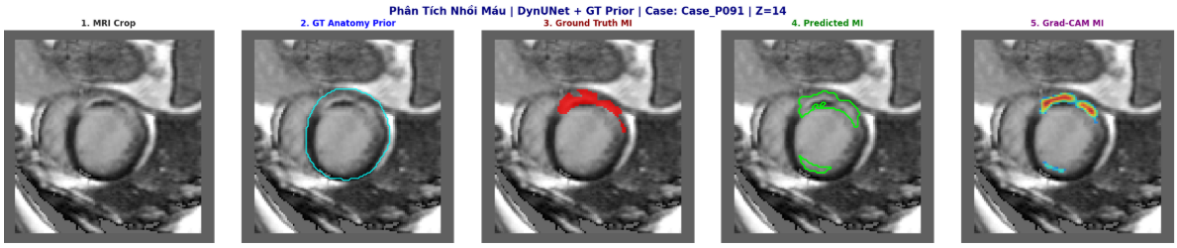
Ngoài việc phân đoạn vùng tổn thương, hệ thống còn hỗ trợ xác định sự hiện diện của nhồi máu cơ tim thông qua kết quả MI Yes/No. Trong ví dụ minh họa, cả Ground Truth và kết quả dự đoán đều xác nhận sự hiện diện của tổn thương nhồi máu cơ tim, tương ứng với trường hợp True Positive (TP).

Kết quả này cho thấy mô hình không chỉ hỗ trợ phát hiện vị trí vùng tổn thương mà còn cung cấp các thông tin định lượng hữu ích như thể tích vùng nhồi máu cơ tim, góp phần hỗ trợ quá trình đánh giá mức độ tổn thương trên ảnh MRI tim mạch.

4.2.2 Giải thích mô hình bằng Explainable AI

Nhằm tăng tính minh bạch và khả năng diễn giải của hệ thống, nghiên cứu sử dụng các phương pháp Explainable AI gồm Grad-CAM, trực quan hóa đặc trưng theo tầng và Monte Carlo Dropout để phân tích quá trình phát hiện vùng nhồi máu cơ tim của mô hình U-Net++.

a. Grad-CAM trên kết quả dự đoán

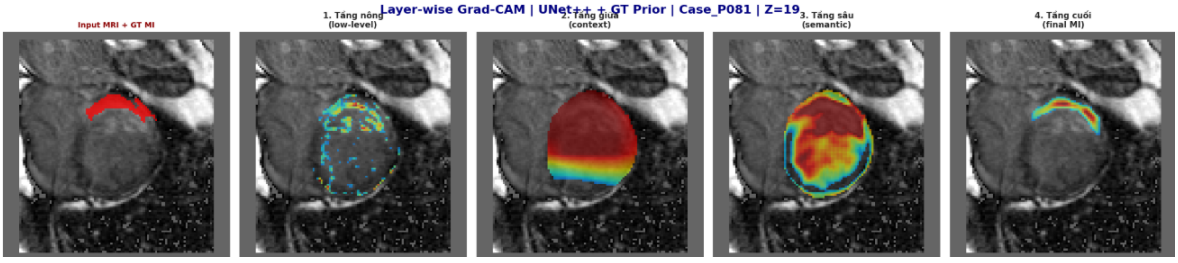


Hình 4.23: Grad-CAM trên kết quả phát hiện vùng nhồi máu cơ tim của mô hình U-Net++

Nhận xét:

Grad-CAM cho thấy mô hình tập trung chủ yếu vào vùng cơ tim có tín hiệu tăng sáng bất thường trên ảnh LGE-MRI. Các vùng kích hoạt mạnh có sự tương đồng cao với vùng nhồi máu được gán nhãn trong Ground Truth, chứng minh rằng mô hình đưa ra quyết định dựa trên các đặc trưng bệnh lý có ý nghĩa lâm sàng thay vì các vùng nền không liên quan.

b. Grad-CAM theo từng tầng của mạng

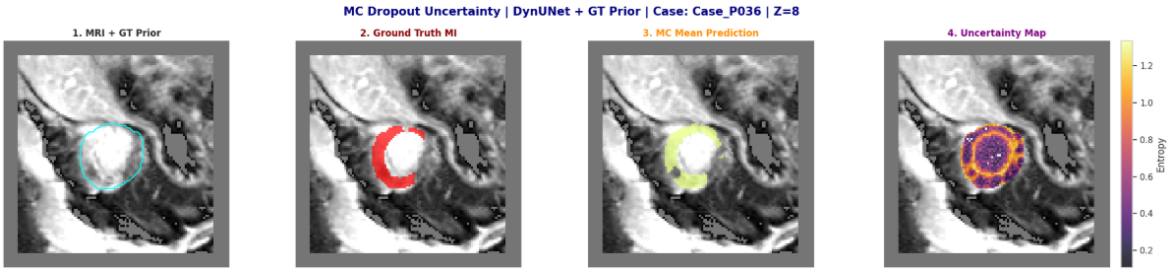


Hình 4.24: Grad-CAM theo từng tầng của mô hình U-Net++

Nhận xét:

Ở các tầng đầu, mô hình chủ yếu học các đặc trưng biên và kết cấu cường độ thấp của ảnh MRI. Khi đi sâu vào các tầng encoder và bottleneck, vùng kích hoạt dần tập trung vào khu vực cơ tim chứa tổn thương. Tại các tầng decoder cuối, Grad-CAM tập trung rõ hơn vào vùng nhồi máu, cho thấy quá trình học đặc trưng diễn ra hợp lý và hỗ trợ mô hình xác định vùng tổn thương.

d. Đánh giá độ bất định bằng Monte Carlo Dropout



Hình 4.25: Bản đồ độ bất định của mô hình U-Net++

Nhận xét:

Bản đồ Uncertainty cho thấy độ bất định tập trung chủ yếu tại các vùng ranh giới giữa mô tổn thương và mô cơ tim bình thường. Trong khi đó, vùng trung tâm của tổn thương có mức độ bất định thấp hơn, phản ánh sự tự tin cao của mô hình trong quá trình dự đoán. Kết quả này phù hợp với đặc điểm thực tế khi đường biên tổn thương thường khó xác định chính xác ngay cả đối với chuyên gia lâm sàng.

Nhận xét tổng quát:

Các kết quả Explainable AI cho thấy mô hình U-Net++ không chỉ đạt hiệu suất phân đoạn ổn định mà còn đưa ra các quyết định có khả năng diễn giải. Grad-CAM xác nhận mô hình tập trung vào các vùng tổn thương có ý nghĩa lâm sàng, trong khi bản đồ Uncertainty giúp nhận diện các khu vực dự đoán chưa chắc chắn. Điều này góp phần tăng tính minh bạch và độ tin cậy của hệ thống trong các ứng dụng hỗ trợ chẩn đoán nhồi máu cơ tim.

4.3 Kết quả phân loại bệnh lý tim mạch

Sau khi hoàn thành bước phân đoạn bằng mô hình U-Net++, các đặc trưng hình thái học và chức năng tim mạch được trích xuất từ mặt nạ phân đoạn để phục vụ cho bài toán phân loại.

Đối với bộ dữ liệu ACDC 2017, các đặc trưng LV_EDVi, RV_EDVi, Myo_EDVi, EF, LV_RV_Ratio, Myo_LV_Ratio và Max_Thickness được sử dụng để phân loại năm nhóm bệnh lý tim mạch gồm NOR, DCM, HCM, MINF và RV.

Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng Cavity_Vol, Myo_Vol, MI_Vol, MI_Ratio và Max_MI_Thickness được sử dụng để phân loại bệnh nhân bình thường (Normal) và bệnh nhân có nhồi máu cơ tim (Infarcted).

Nghiên cứu tiến hành đánh giá bốn mô hình phân loại gồm Random Forest (RF), Support Vector Machine (SVM), Multi-Layer Perceptron (MLP) và Ensemble Voting

nhằm lựa chọn mô hình phù hợp cho từng bài toán phân loại.

4.3.1 Kịch bản thực nghiệm

Để đánh giá hiệu quả của các mô hình phân loại, nghiên cứu xây dựng các kịch bản thực nghiệm dựa trên các đặc trưng hình thái học được trích xuất từ kết quả phân đoạn của mô hình U-Net++.

Đối với bộ dữ liệu ACDC 2017, các đặc trưng LV_EDVi, RV_EDVi, Myo_EDVi, EF, LV_RV_Ratio, Myo_LV_Ratio và Max_Thickness được sử dụng để phân loại năm nhóm bệnh lý tim mạch gồm NOR, DCM, HCM, MINF và RV.

Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng Cavity_Vol, Myo_Vol, MI_Vol, MI_Ratio và Max_MI_Thickness được sử dụng để phân loại bệnh nhân bình thường (Normal) và bệnh nhân có nhồi máu cơ tim (Infarcted).

Bốn mô hình học máy được khảo sát gồm Random Forest (RF), Support Vector Machine (SVM), Multi-Layer Perceptron (MLP) và Ensemble Voting.

Bảng 4.3: Kịch bản thực nghiệm cho bài toán phân loại

Kịch bản	**Bộ dữ liệu**	**Đặc trưng**	**Mô hình phân đoạn**	**Mô hình**
Kịch bản 9	ACDC 2017	Đặc trưng hình thái học	U-Net++	Random Forest
Kịch bản 10	ACDC 2017	Đặc trưng hình thái học	U-Net++	SVM
Kịch bản 11	ACDC 2017	Đặc trưng hình thái học	U-Net++	MLP
Kịch bản 12	ACDC 2017	Đặc trưng hình thái học	U-Net++	Ensemble Soft Voting
Kịch bản 13	EMIDEC 2020	Đặc trưng tổn thương MI	U-Net++	Random Forest
Kịch bản 14	EMIDEC 2020	Đặc trưng tổn thương MI	U-Net++	SVM
Kịch bản 15	EMIDEC 2020	Đặc trưng tổn thương MI	U-Net++	MLP
Kịch bản 16	EMIDEC 2020	Đặc trưng tổn thương MI	U-Net++	Ensemble Soft Voting

Bảng 4.3 trình bày các kịch bản thực nghiệm được sử dụng cho hai bài toán phân loại trên bộ dữ liệu ACDC 2017 và EMIDEC 2020. Đối với ACDC 2017, các đặc trưng hình thái học và chức năng tim được trích xuất từ kết quả phân đoạn của mô hình U-Net++ để phục vụ phân loại năm nhóm bệnh lý tim mạch. Đối với EMIDEC 2020, các đặc trưng liên quan đến vùng nhồi máu cơ tim được sử dụng để phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim. Các mô hình RF, SVM, MLP và Ensemble Voting được đánh giá nhằm lựa chọn phương pháp phân loại phù hợp.

4.3.2 So sánh kết quả các mô hình phân loại

Bảng 4.4: Kết quả phân loại trên bộ dữ liệu ACDC 2017 và EMIDEC 2020

Kịch bản	Bộ dữ liệu	Mô hình	Accuracy	Recall	F1-score	ROC-AUC
Kịch bản 9	ACDC	Random Forest	86%	86%	86%	98.5%
Kịch bản 10	ACDC	SVM	86%	86%	86%	98.3%
Kịch bản 11	ACDC	MLP	84%	84%	84%	96.9%
Kịch bản 12	ACDC	Ensemble Voting	86%	86%	86%	98.5%
Kịch bản 13	EMIDEC	Random Forest	96%	96%	96%	99.3%
Kịch bản 14	EMIDEC	SVM	97%	97%	97%	99.6%
Kịch bản 15	EMIDEC	MLP	95%	95%	95%	99.2%
Kịch bản 16	EMIDEC	Ensemble Voting	97%	99%	98%	99.7%

Nhận xét:

Kết quả trong Bảng 4.4 cho thấy các mô hình học máy đều đạt hiệu suất phân loại cao trên cả hai bộ dữ liệu ACDC 2017 và EMIDEC 2020.

Đối với bộ dữ liệu ACDC 2017, Random Forest, SVM và Ensemble Voting cùng đạt Accuracy, Recall và F1-score ở mức 86%, trong khi MLP đạt 84%. Random Forest và Ensemble Voting đạt ROC-AUC cao nhất với giá trị 98.5%.

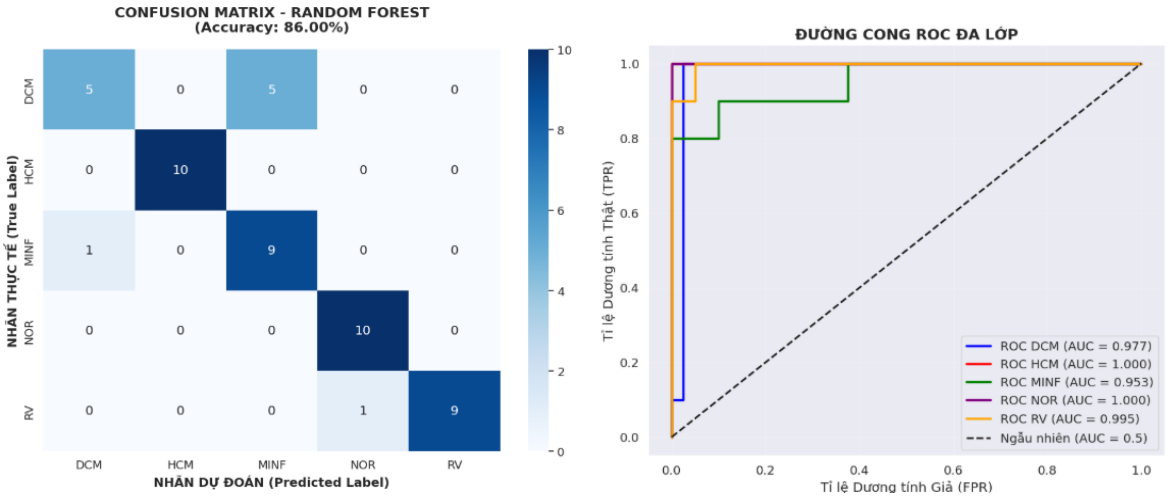
Đối với bộ dữ liệu EMIDEC 2020, hiệu suất phân loại cao hơn so với bộ dữ liệu ACDC 2017. Một nguyên nhân có thể là bài toán chỉ gồm hai lớp Normal và Infarcted, giúp quá trình phân biệt giữa các nhóm bệnh đơn giản hơn so với bài toán phân loại đa lớp trên ACDC. SVM và Ensemble Voting cùng đạt Accuracy 97%, trong đó Ensemble Voting đạt Recall cao nhất là 99% và F1-score 98%. Giá trị ROC-AUC cao nhất đạt 99.7%, cho thấy khả năng phân biệt rất tốt giữa bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim.

Các kết quả này được đánh giá bằng phương pháp 5-Fold Stratified Cross-Validation trên toàn bộ 100 bệnh nhân của bộ dữ liệu EMIDEC 2020 nhằm tận dụng tối đa số lượng mẫu hiện có và giảm ảnh hưởng của sự mất cân bằng dữ liệu giữa hai nhóm bệnh. Do đó, các chỉ số phản ánh hiệu quả tổng thể của mô hình trên toàn bộ tập dữ liệu thay vì trên một tập kiểm thử độc lập.

Nhìn chung, Ensemble Voting cho kết quả ổn định trên cả hai bộ dữ liệu, tận dụng được ưu điểm của các bộ phân loại thành phần và duy trì hiệu suất cao trên nhiều chỉ số đánh giá. Do đó, mô hình này được lựa chọn làm mô hình phân loại cuối cùng của hệ thống.

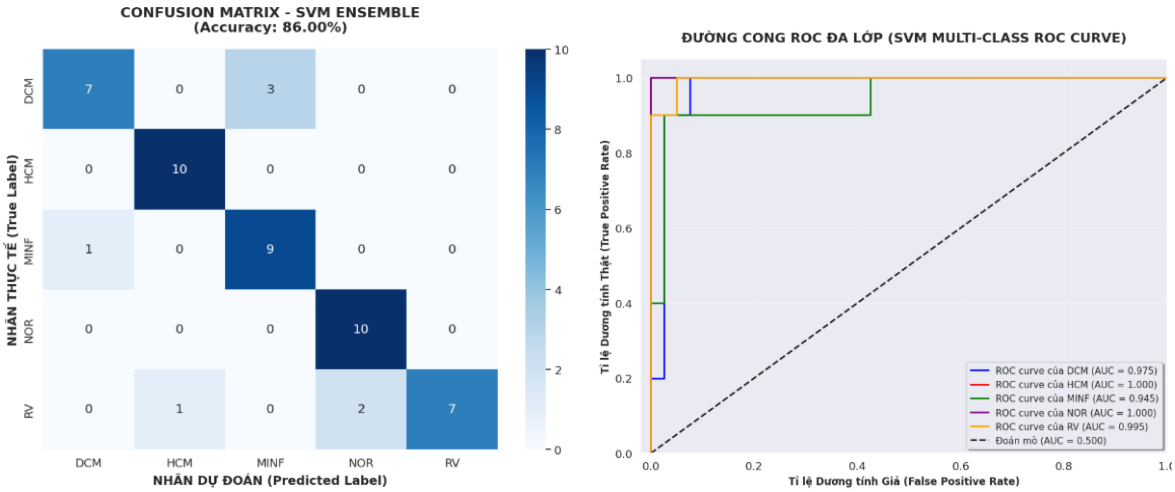
4.3.3 Đánh giá hiệu quả phân loại

a. Ma trận nhầm lẫn và đường cong ROC



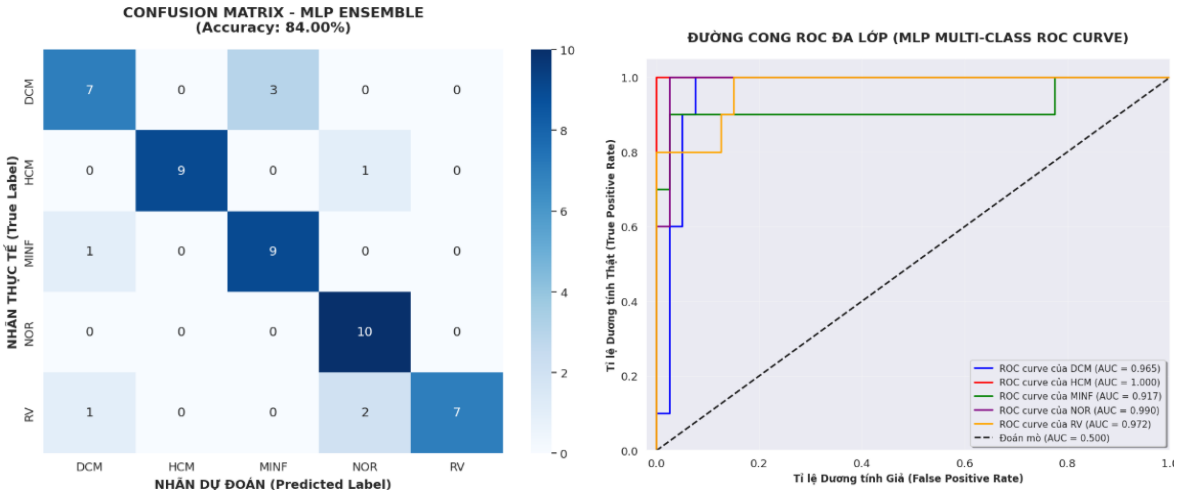
(a) Confusion Matrix (b) ROC Curve

Hình 4.26: Kết quả phân loại của kịch bản 9 (Random Forest trên bộ dữ liệu ACDC 2017)



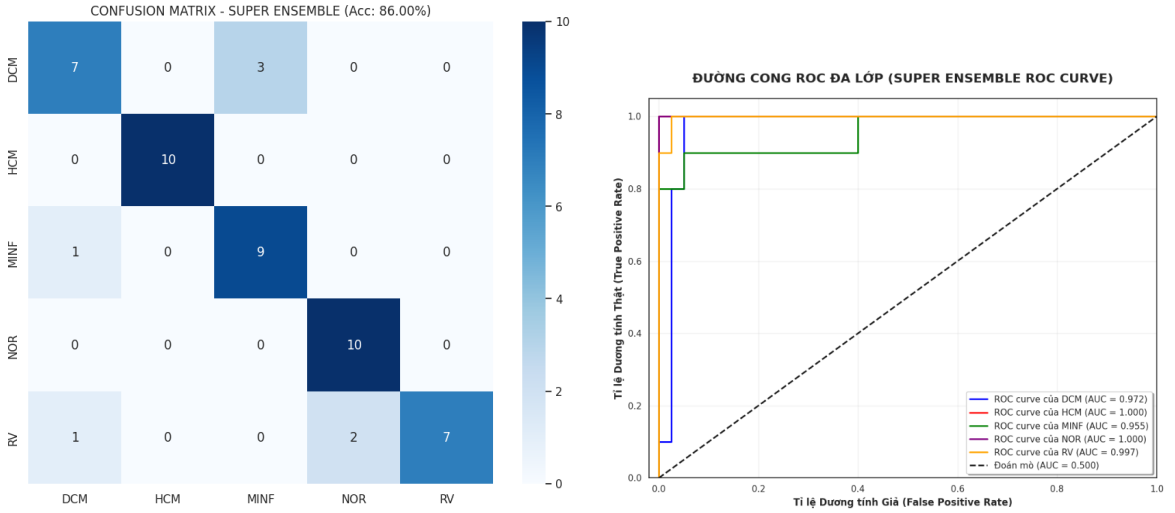
(a) Confusion Matrix (b) ROC Curve

Hình 4.27: Kết quả phân loại của kịch bản 10 (SVM trên bộ dữ liệu ACDC 2017)



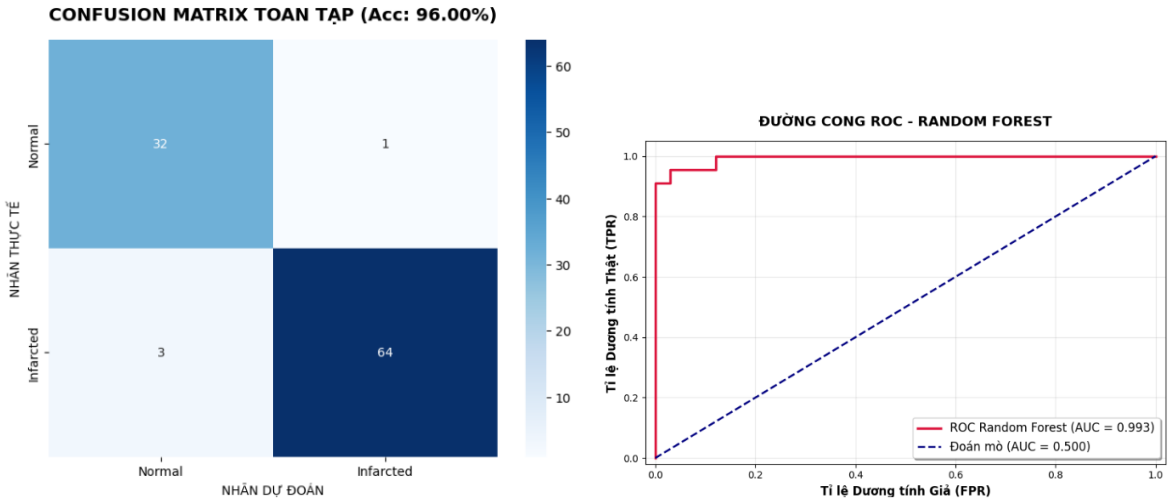
(a) Confusion Matrix (b) ROC Curve

Hình 4.28: Kết quả phân loại của kịch bản 11 (MLP trên bộ dữ liệu ACDC 2017)



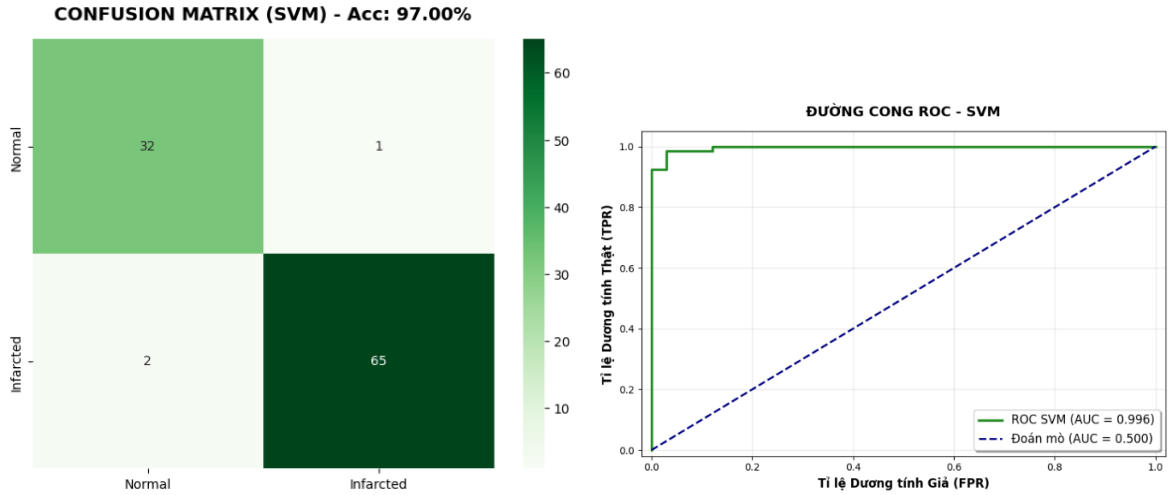
(a) Confusion Matrix (b) ROC Curve

Hình 4.29: Kết quả phân loại của kịch bản 12 (Ensemble Voting trên bộ dữ liệu ACDC 2017)



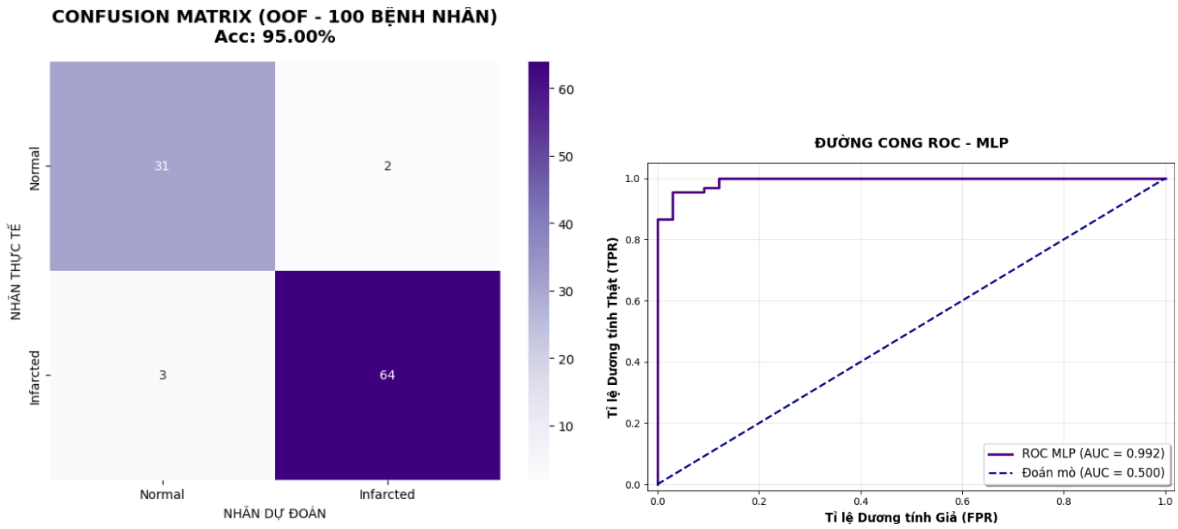
(a) Confusion Matrix (b) ROC Curve

Hình 4.30: Kết quả phân loại của kịch bản 13 (Random Forest trên bộ dữ liệu EMIDEC 2020)



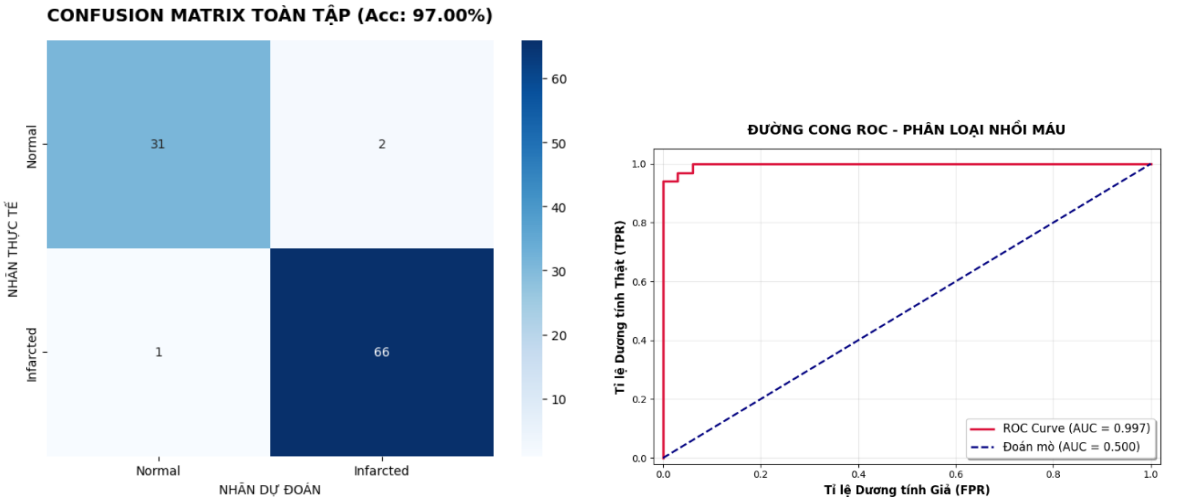
(a) Confusion Matrix (b) ROC Curve

Hình 4.31: Kết quả phân loại của kịch bản 14 (SVM trên bộ dữ liệu EMIDEC 2020)



(a) Confusion Matrix (b) ROC Curve

Hình 4.32: Kết quả phân loại của kịch bản 15 (MLP trên bộ dữ liệu EMIDEC 2020)



(a) Confusion Matrix (b) ROC Curve

Hình 4.33: Kết quả phân loại của kịch bản 16 (Ensemble Voting trên bộ dữ liệu EMIDEC 2020)

Nhận xét tổng quát:

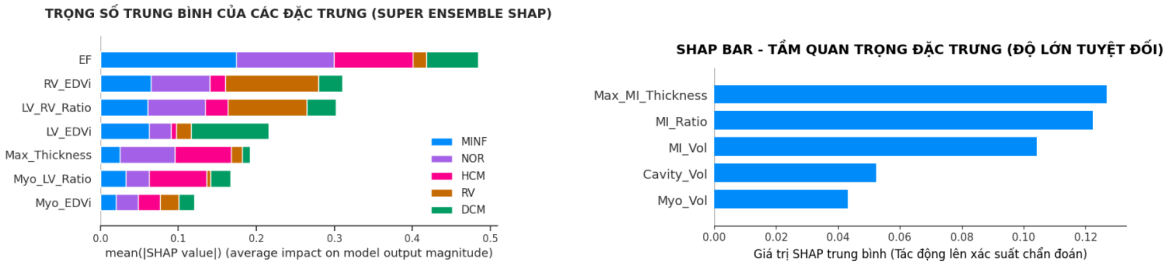
Kết quả ma trận nhầm lẫn và đường cong ROC cho thấy cả bốn mô hình đều đạt khả năng phân loại tốt trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020. Các phần tử trên đường chéo chính của ma trận nhầm lẫn chiếm tỷ lệ cao, phản ánh khả năng nhận diện chính xác các nhóm bệnh lý của các mô hình.

Đối với bộ dữ liệu ACDC 2017, các mô hình đều phân biệt tốt giữa năm nhóm bệnh lý NOR, DCM, HCM, MINF và RV. Một số trường hợp nhầm lẫn xuất hiện giữa các nhóm bệnh có đặc điểm hình thái tương đồng, tuy nhiên số lượng không đáng kể và không ảnh hưởng nhiều đến hiệu quả phân loại chung.

Trên bộ dữ liệu EMIDEC 2020, các đường cong ROC cho thấy khả năng phân biệt rất rõ giữa hai nhóm bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim. Điều này cho thấy các đặc trưng được trích xuất từ kết quả phân đoạn mang tính phân biệt cao và có giá trị trong quá trình chẩn đoán.

Nhìn chung, kết quả ma trận nhầm lẫn và ROC cho thấy các mô hình học máy đều có khả năng nhận diện bệnh lý tim mạch hiệu quả trên cả hai bộ dữ liệu. Các kết quả định lượng chi tiết sẽ được trình bày và phân tích trong phần so sánh kết quả các mô hình phân loại.

b. Giải thích mô hình bằng SHAP



(a) ACDC 2017 (b) EMIDEC 2020

Hình 4.34: Biểu đồ SHAP Summary của mô hình Ensemble Voting trên hai bộ dữ liệu ACDC 2017 và EMIDEC 2020

Nhận xét:

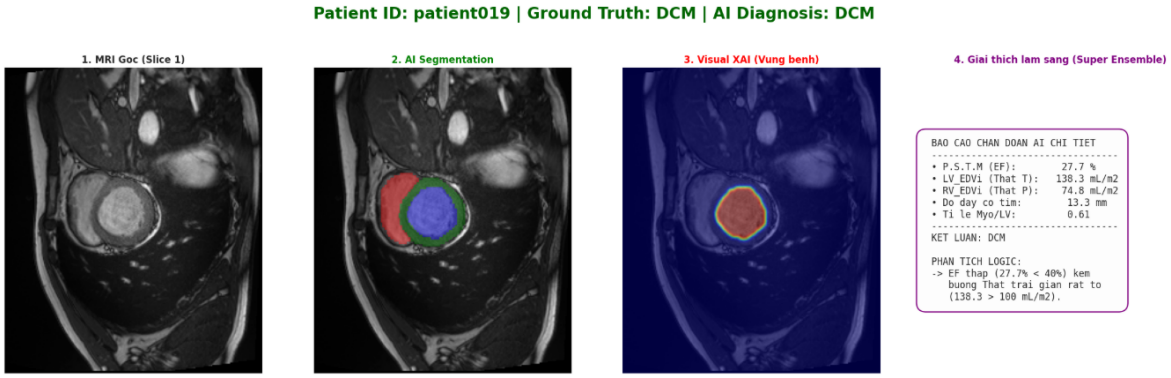
Kết quả SHAP cho thấy các đặc trưng được trích xuất từ kết quả phân đoạn đóng vai trò quan trọng trong quá trình phân loại trên cả hai bộ dữ liệu.

Đối với bộ dữ liệu ACDC 2017, các đặc trưng LV_EDVi, RV_EDVi, EF và Max_Thickness có mức độ ảnh hưởng lớn nhất tới quyết định phân loại bệnh lý tim mạch. Điều này phù hợp với các kiến thức lâm sàng vì các đặc trưng này phản ánh sự thay đổi về hình thái và chức năng tim ở các nhóm bệnh khác nhau.

Đối với bộ dữ liệu EMIDEC 2020, các đặc trưng MI_Vol, MI_Ratio và Max_MI_Thickness có mức độ ảnh hưởng cao nhất tới quyết định phân loại giữa bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim. Ngoài ra, các đặc trưng Cavity_Vol và Myo_Vol cũng góp phần mô tả những thay đổi cấu trúc tim liên quan đến tổn thương cơ tim.

Nhìn chung, kết quả SHAP cho thấy các đặc trưng được mô hình sử dụng đều có ý nghĩa lâm sàng rõ ràng, góp phần nâng cao khả năng giải thích của hệ thống đề xuất.

4.3.4 Ví dụ kết quả chẩn đoán



Hình 4.35: Ví dụ kết quả chẩn đoán bệnh cơ tim phì đại (HCM)

Nhận xét:

Hình 4.35 minh họa một trường hợp bệnh nhân thuộc nhóm HCM. Hệ thống dự đoán chính xác nhãn bệnh lý tương ứng với Ground Truth. Kết quả phân đoạn cho thấy cấu trúc tim được xác định rõ ràng, trong khi bản đồ XAI tập trung chủ yếu vào vùng cơ tim dày lên bất thường. Báo cáo lâm sàng cho thấy độ dày cơ tim đạt 14.9 mm và tỷ lệ Myo/LV tăng cao, phù hợp với đặc điểm điển hình của bệnh cơ tim phì đại.

4.4 Thảo luận và so sánh với các nghiên cứu liên quan

4.4.1 So sánh kết quả với các nghiên cứu liên quan

Bảng 4.5: So sánh kết quả của nghiên cứu đề xuất với các nghiên cứu liên quan

Nghiên cứu	ACDC Dice	ACDC HD95	Classification Accuracy	ROC-AUC	EMIDEC Dice	EMIDEC IoU
Bernard et al. (2018) [2]	89%	1.64	96.0%	–	–	–
Khened et al. (2019) [15]	90%	1.56	86.0%	96.0%	–	–
Baumgartner et al. (2017) [1]	89%	1.80	–	–	–	–
Painchaud et al. (2020) [27]	91%	1.49	–	–	–	–
Isensee et al. (2021) [14]	90%	1.50	–	–	65.0	49.0
Martin-Isla et al. (2020) [22]	–	–	87.0%	97.0%	–	–
Wolterink et al. (2017) [13]	–	–	91.0%	–	–	–
Zheng et al. (2019) [36]	–	–	88.0%	97.5%	–	–
Girum et al. (2021) [10]	–	–	–	–	61.5	44.8
Lalande et al. (2020) [16]	–	–	–	–	63.4	46.9
Zhang et al. (2020) [35]	–	–	–	–	64.2	48.5
Ma et al. (2020) [21]	–	–	–	–	64.8	48.7
Nghiên cứu đề xuất	**86.83%**	**1.35**	**86.0%**	**98.5%**	**66.36**	**50.37**

Nhận xét:

Kết quả so sánh cho thấy nghiên cứu đề xuất đạt hiệu suất cạnh tranh trên cả ba bài toán gồm phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch và phát hiện nhồi máu cơ tim. Mặc dù Dice Score trên bộ dữ liệu ACDC 2017 chưa phải cao nhất, mô hình đạt giá trị HD95 thấp nhất (1.35 mm), cho thấy khả năng xác định biên giải phẫu chính xác và ổn định. Trong bài toán phân loại bệnh lý tim mạch, hệ thống đạt Accuracy 86.0% và ROC-AUC 98.5%, cao hơn phần lớn các nghiên cứu được lựa chọn để so sánh. Đối với bộ dữ liệu EMIDEC 2020, mô hình đạt Dice Score 66.36% và IoU 50.37%, vượt qua nhiều nghiên cứu trước đây. Những kết quả này cho thấy hệ thống đề xuất có khả năng tổng quát hóa tốt trên nhiều nhiệm vụ khác nhau và đạt hiệu quả cạnh tranh so với các công trình liên quan.

4.4.2 So sánh điểm mới của nghiên cứu đề xuất với các nghiên cứu liên quan

Bảng 4.6: So sánh điểm mới của nghiên cứu đề xuất với các nghiên cứu liên quan

Nghiên cứu	**Phân đoạn tim**	**Phân loại bệnh**	**Phát hiện MI**	**Grad-CAM**	**SHAP**	**MC Dropout**	**Ước lượng MI**
Bernard et al. (2018) [2]	✓	✓	✗	✗	✗	✗	✗
Khened et al. (2019) [15]	✓	✓	✗	✗	✗	✗	✗
Baumgartner et al. (2017) [1]	✓	✗	✗	✗	✗	✗	✗
Painchaud et al. (2020) [27]	✓	✗	✗	✗	✗	✗	✗
Isensee et al. (2021) [14]	✓	✗	✗	✗	✗	✗	✗
Martin-Isla et al. (2020) [22]	✗	✓	✗	✗	✗	✗	✗
Wolterink et al. (2017) [13]	✗	✓	✗	✗	✗	✗	✗
Zheng et al. (2019) [36]	✗	✓	✗	✗	✗	✗	✗
Girum et al. (2021) [10]	✗	✗	✓	✗	✗	✗	✗
Lalande et al. (2020) [16]	✗	✗	✓	✗	✗	✗	✗
Zhang et al. (2020) [35]	✗	✗	✓	✗	✗	✗	✗
Ma et al. (2020) [21]	✗	✗	✓	✗	✗	✗	✗
Nghiên cứu đề xuất	✓	✓	✓	✓	✓	✓	✓

Nhận xét:

Các nghiên cứu trước đây chủ yếu tập trung vào từng bài toán riêng lẻ như phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch hoặc phát hiện nhồi máu cơ tim. Trong khi đó, nghiên cứu đề xuất xây dựng một hệ thống tích hợp trên cả hai bộ dữ liệu ACDC 2017 và EMIDEC 2020.

Trên bộ dữ liệu ACDC 2017, hệ thống thực hiện phân đoạn cấu trúc tim và phân loại năm nhóm bệnh lý tim mạch. Trên bộ dữ liệu EMIDEC 2020, hệ thống thực hiện phân đoạn vùng nhồi máu cơ tim, phân loại bệnh nhân bình thường và bệnh nhân có nhồi máu cơ tim, đồng thời hỗ trợ ước lượng thể tích vùng tổn thương.

Ngoài ra, nghiên cứu còn tích hợp các phương pháp Explainable AI như Grad-CAM, SHAP và Monte Carlo Dropout nhằm tăng khả năng giải thích và độ tin cậy của hệ thống.

Chương 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Trong nghiên cứu này, một hệ thống hỗ trợ chẩn đoán bệnh tim mạch trên ảnh cộng hưởng từ tim (Cardiac MRI) đã được xây dựng và đánh giá trên hai bộ dữ liệu công khai ACDC 2017 và EMIDEC 2020. Hệ thống được thiết kế theo hướng tích hợp nhiều nhiệm vụ gồm phân đoạn cấu trúc tim, phân loại bệnh lý tim mạch và phát hiện vùng nhồi máu cơ tim, đồng thời kết hợp các phương pháp Explainable AI nhằm tăng khả năng giải thích kết quả dự đoán.

Đối với bộ dữ liệu ACDC 2017, nghiên cứu đã đánh giá nhiều kiến trúc phân đoạn ảnh y tế 3D khác nhau. Kết quả cho thấy mô hình SegResNet đạt hiệu suất ổn định trên các cấu trúc tim gồm thất trái (LV), thất phải (RV) và cơ tim (MYO), với Dice Score trung bình đạt 0.8680 và HD95 đạt 1.37 mm. Kết quả phân đoạn được sử dụng để trích xuất các đặc trưng hình thái học và chức năng tim như thể tích thất trái, thể tích thất phải, phân suất tống máu và độ dày cơ tim.

Từ các đặc trưng đã trích xuất, nghiên cứu xây dựng hệ thống phân loại bệnh lý tim mạch sử dụng các mô hình Random Forest, Support Vector Machine và Multi-Layer Perceptron. Thông qua cơ chế Ensemble Voting theo phương pháp Soft Voting, hệ thống đạt Accuracy 88.0%, Recall 88.0%, F1-score 88.0% và ROC-AUC 98.4%, cho thấy khả năng hỗ trợ phân loại các nhóm bệnh lý tim mạch trên bộ dữ liệu ACDC 2017.

Đối với bộ dữ liệu EMIDEC 2020, nghiên cứu thực hiện bài toán phát hiện và phân đoạn vùng nhồi máu cơ tim trên ảnh LGE-MRI. Bốn kiến trúc gồm U-Net++, Attention U-Net, SegResNet và DynUNet được đánh giá và so sánh. Kết quả cho thấy DynUNet đạt hiệu suất tốt nhất với Dice Score 67.19%, IoU 50.92% và HD95 đạt 6.1 mm. Mặc dù U-Net++ đạt giá trị HD95 thấp hơn, DynUNet đạt Dice Score và IoU cao nhất, là các chỉ số phản ánh trực tiếp khả năng nhận diện và phân đoạn vùng tổn thương, do đó được lựa chọn làm mô hình chính cho bài toán phát hiện nhồi máu cơ tim.

Bên cạnh các kết quả định lượng, nghiên cứu còn tích hợp các phương pháp Explainable AI gồm Grad-CAM, SHAP và Monte Carlo Dropout nhằm hỗ trợ giải thích quyết định của mô hình, trực quan hóa vùng ảnh quan trọng và đánh giá độ bất định của kết quả dự đoán. Các phương pháp này góp phần tăng tính minh bạch và độ tin cậy của hệ thống trong bối cảnh hỗ trợ chẩn đoán y khoa.

Nhìn chung, kết quả thực nghiệm cho thấy hệ thống đề xuất có khả năng hỗ trợ hiệu quả trong các bài toán phân đoạn ảnh tim, phân loại bệnh lý tim mạch và phát

hiện vùng nhồi máu cơ tim trên ảnh MRI, đồng thời cung cấp các thông tin giải thích hữu ích phục vụ quá trình phân tích và ra quyết định lâm sàng.

5.2 Hạn chế của nghiên cứu

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế cần được xem xét trong các nghiên cứu tiếp theo.

- Kích thước dữ liệu còn tương đối hạn chế, đặc biệt đối với bộ dữ liệu EMIDEC 2020, làm giảm khả năng học được đầy đủ các biến thiên giải phẫu và bệnh lý trong thực tế.
- Dữ liệu sử dụng chủ yếu là các bộ dữ liệu công khai và chưa được đánh giá trên dữ liệu đa trung tâm hoặc dữ liệu thu nhận từ nhiều thiết bị MRI khác nhau.
- Hệ thống mới được đánh giá trong môi trường nghiên cứu và chưa được triển khai thử nghiệm trong quy trình lâm sàng thực tế.
- Nghiên cứu chỉ sử dụng dữ liệu ảnh MRI tim mạch. Các nguồn dữ liệu bổ sung như điện tâm đồ (ECG), hồ sơ bệnh án điện tử hoặc dữ liệu xét nghiệm chưa được tích hợp vào hệ thống.
- Hiệu suất phân đoạn vùng nhồi máu cơ tim vẫn còn thấp hơn so với bài toán phân đoạn cấu trúc tim do đặc điểm tổn thương có kích thước nhỏ, hình dạng phức tạp và mất cân bằng dữ liệu giữa vùng tổn thương và vùng nền.

5.3 Hướng phát triển

Trong tương lai, nghiên cứu có thể được mở rộng theo một số hướng sau:

- Thu thập và đánh giá trên các bộ dữ liệu có quy mô lớn hơn và đến từ nhiều trung tâm y tế khác nhau nhằm tăng khả năng tổng quát hóa của mô hình.
- Kết hợp dữ liệu đa phương thức như MRI tim mạch, tín hiệu ECG và hồ sơ bệnh án điện tử để nâng cao hiệu quả hỗ trợ chẩn đoán.
- Nghiên cứu và áp dụng các kiến trúc học sâu tiên tiến hơn như Vision Transformer, Swin Transformer hoặc các Foundation Models cho ảnh y tế.
- Tiếp tục cải thiện bài toán phát hiện và phân đoạn vùng nhồi máu cơ tim thông qua các kỹ thuật xử lý mất cân bằng dữ liệu, học bán giám sát hoặc học tự giám sát.

- Phát triển giao diện hỗ trợ bác sĩ với khả năng trực quan hóa vùng tổn thương, hiển thị bản đồ chú ý và đánh giá độ bất định theo thời gian thực.
- Thử nghiệm và đánh giá hệ thống trong môi trường lâm sàng nhằm xác định tính khả thi, hiệu quả và mức độ hỗ trợ của hệ thống đối với bác sĩ chuyên khoa tim mạch.

Tài liệu tham khảo

[1] Christian F. Baumgartner, Lisa M. Koch, Marc Pollefeys, and Ender Konukoglu. An exploration of 2d and 3d deep learning techniques for cardiac mr image segmentation. *arXiv preprint arXiv:1709.04496*, 2017.

[2] Olivier Bernard, Alain Lalande, Clement Zotti, Frederic Cervenansky, Xin Yang, Pheng-Ann Heng, Irem Cetin, Karim Lekadir, Oscar Camara, Miguel Angel Gonzalez-Ballester, et al. Deep learning techniques for automatic mri cardiac multi-structures segmentation and diagnosis: is the problem solved? *IEEE transactions on medical imaging*, 37(11):2514–2525, 2018.

[3] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

[4] Báo Thanh Niên. Dấu hiệu nào cảnh báo nhịp tim bất thường?, 2023. Truy cập ngày 01/06/2026.

[5] M Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, Benjamin Murrey, Andriy Myronenko, Can Zhao, Dong Yang, et al. Monai: An open-source framework for deep learning in healthcare. *arXiv preprint arXiv:2211.02701*, 2022.

[6] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.

[7] Thomas G Dietterich. Ensemble methods in machine learning. *Multiple Classifier Systems*, 2000.

[8] ELCOM. Deep learning là gì? Ứng dụng của học sâu trong thực tiễn, 2022.

[9] Yarin Gal and Zoubin Ghahramani. Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In *International Conference on Machine Learning*, 2016.

[10] Kibrom Berihu Girum, Youssef Skandarani, Raabid Hussain, Alexis Bozorg Grayeli, and Alain Lalande. Automatic myocardial infarction evaluation from delayed-enhancement cardiac mri using deep convolutional networks. *arXiv preprint arXiv:2010.16198*, 2020.

[11] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[12] W Gregory Hundley, David A Bluemke, J Paul Finn, Scott D Flamm, Mark A Fogel, Matthias G Friedrich, Vincent B Ho, Michael Jerosch-Herold, Christopher M Kramer, Warren J Manning, et al. Accf/acr/aha/nasci/scmr 2010 expert consensus document on cardiovascular magnetic resonance: a report of the american college of cardiology foundation task force on expert consensus documents. *Journal of the American College of Cardiology*, 55(23):2614–2662, 2010.

[13] Fabian Isensee, Paul F. Jaeger, Peter M. Full, Ivo Wolf, Sandy Engelhardt, and Klaus H. Maier-Hein. Automatic cardiac disease assessment on cine-mri via time-series segmentation and domain specific features. *arXiv preprint arXiv:1707.00587*, 2017.

[14] Fabian Isensee, Paul F Jaeger, Simon AA Kohl, Jakob Petersen, and Klaus H Maier-Hein. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature methods*, 18(2):203–211, 2021.

[15] Mahendra Khened, Varghese Alex Kollerathu, and Ganapathy Krishnamurthi. Fully convolutional multi-scale residual densenets for cardiac segmentation and automated cardiac diagnosis using ensemble of classifiers. *Medical image analysis*, 51:21–45, 2019.

[16] Alain Lalande, Zhaohan Chen, Thomas Decourselle, Abdul Qayyum, Thibaut Pommier, Luc Lorgis, E de la Rosa, A Cochet, Yves Cottin, and Fabrice Meriaudeau. Emidec: A database usable for the automatic evaluation of myocardial infarction from delayed-enhancement cardiac mri. *Data*, 5(4):89, 2020.

[17] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.

[18] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983*, 2016.

[19] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.

[20] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NIPS)*, volume 30, pages 4765–4774. Curran Associates, Inc., 2017.

[21] Jun Ma. Cascaded framework for automatic evaluation of myocardial infarction from delayed-enhancement cardiac mri. *arXiv preprint arXiv:2012.14556*, 2020.

[22] Carlos Martin-Isla, Víctor M Campello, Cristian Izquierdo, Zahra Raisi-Estabragh, Bettina Baeßler, Steffen E Petersen, and Karim Lekadir. Image-based cardiac diagnosis with machine learning: a review. *Frontiers in cardiovascular medicine*, 7:1, 2020.

[23] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation. In *2016 fourth international conference on 3D vision (3DV)*, pages 565–571. IEEE, 2016.

[24] Robert D Mosteller. Simplified calculation of body-surface area. *New England Journal of Medicine*, 317(17):1098, 1987.

[25] Andriy Myronenko. 3d mri brain tumor segmentation using autoencoder regularization. In *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries*, pages 311–320. Springer, 2019.

[26] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y Hammerla, Bernhard Kainz, et al. Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*, 2018.

[27] Nathan Painchaud, Youssef Skandarani, Thierry Judge, Olivier Bernard, Alain Lalande, and Pierre-Marc Jodoin. Cardiac segmentation with strong anatomical guarantees. *IEEE Transactions on Medical Imaging*, 2020.

[28] Dudley J Pennell. Cardiovascular magnetic resonance. *Circulation*, 2010.

[29] Piotr Ponikowski, Adriaan A Voors, Stefan D Anker, Héctor Bueno, John GF Cleland, Andrew JS Coats, Volkmar Falk, José Ramón González-Juanatey, Veli-Pekka Harjola, Ewa A Jankowska, et al. 2016 esc guidelines for the diagnosis and treatment of acute and chronic heart failure. *European heart journal*, 37(27):2129–2200, 2016.

[30] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015*, pages 234–241. Springer, 2015.

[31] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE international conference on computer vision*, pages 618–626, 2017.

[32] Muhammad Aamir Sohail. Harnessing ai and machine learning to combat trade-based money laundering, 2024.

[33] Abdel Aziz Taha and Allan Hanbury. Metrics for evaluating 3d medical image segmentation. *IEEE Transactions on Medical Imaging*, 2015.

[34] Kristian Thygesen, Joseph S Alpert, Allan S Jaffe, Bernard R Chaitman, Jeroen J Bax, David A Morrow, Harvey D White, et al. Fourth universal definition of myocardial infarction (2018). *European heart journal*, 40(3):237–269, 2019.

[35] Yichi Zhang. Cascaded convolutional neural network for automatic myocardial infarction segmentation from delayed-enhancement cardiac mri. *arXiv preprint arXiv:2012.14128*, 2020.

[36] Qi Zheng, Hervé Delingette, Nicolas Duchateau, and Nicholas Ayache. Explainable cardiac pathology classification on cine mri with motion characterization by semi-supervised learning of apparent flow. *Medical Image Analysis*, 56:80–95, 2019.

[37] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++: A nested u-net architecture for medical image segmentation. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, pages 3–11, 2018.